

Makine Öğrenmesi ve Derin Öğrenme ile Kısa Vadeli Hisse Senedi Yön Tahmini: Çoklu Sınıflandırma Yaklaşımı

Eren Atasoy¹, Ahmet Emin Gonultas² and Gulay Cicek³

^{1,2}Yazılım Mühendisliği Bölümü, Mühendislik-Mimarlık Fakültesi

İstanbul Beykent Üniversitesi, Sarıyer, İstanbul, Türkiye

¹2303013123@student.beykent.edu.tr, ²2103013243@student.beykent.edu.tr

³gulaycicek@beykent.edu.tr

Özet—Finansal piyasaların hızlı, karmaşık ve öngörülemez doğası, yatırımcıların ve analistlerin doğru kararlar almasını zorlaştırmaktadır. Bu nedenle, gelişmiş Makine Öğrenmesi (ML) ve Derin Öğrenme (DL) tekniklerinden yararlanarak hisse senedi yön tahmini yapabilen akıllı sistemlere olan ihtiyaç giderek artmaktadır. Bu bağlamda, çalışmada Borsa İstanbul (BIST100) verileri temel alınarak finansal piyasalarındaki dalgalandırmaların öngörlümesi amaçlanmıştır. Kullanılan veri seti, Yahoo Finance ve Kaggle platformlarından elde edilmiş olup, 4.587 satır ve 42 sütündan oluşmaktadır. Çalışmada, veriye ön işleme adımları uygulanmış olup, eksik veri temizleme, Min-Max normalizasyonu ve IQR (çeyrekler arası açılık) yöntemi ile aykırı değerlerin işlenmesi gerçekleştirilmiştir. Öz nitelik seçiminde Temel Bileşen Analizi (PCA) ve Lineer Ayırıcı Analiz (LDA) kullanılarak, verinin boyutu azaltılmış ve önemli özniteliklerin belirlenmesi sağlanmıştır. Sınıflandırma algoritmaları olarak K-Er Yakın Komşu (KNN), Rastgele Orman (Random Forest), XGBoost, Extra Trees, Destek Vektör Makineleri (SVM), Uzun Kısa Süreli Billek (LSTM), Çift Yönlü LSTM (Bi-LSTM), Konişyonel Sinir Ağ (CNN), Gated Recurrent Unit (GRU) ve Tekrarlayan Sinir Ağ (RNN) kullanılmıştır. Ayrıca, bu çalışmada daha önce literatürde kullanılmamış özgün bir hibrit model önerilmiştir. Modelin performansı doğruluk, F1-skoru, özgürlük, duyarlılık, AUC-ROC ve kesinlik gibi değerlendirme kriterleriyle ölçülmüş, 5 katlı çapraz doğrulama (K-Fold, k=5) yöntemi ile modelin genelleme yeteneği test edilmiştir. Yapılan analizler sonucunda, önerilen hibrit modelin ve çoklu sınıflandırma yaklaşımının diğer yöntemlere kıyasla daha yüksek doğruluk oranı sağladığı gözlemlenmiştir. Çalışma, yatırımcılara "al", "tut" ve "sat" önerileri sunarak karar alma süreçlerine katkı sağlamayı hedeflemektedir. En önemli katkısı, finansal piyasalarda daha önce kullanılmamış bir hibrit modelin geliştirilmesi ve çoklu sınıflandırma yaklaşımının uygulanmasıdır. Gelecek çalışmalar için öneriler arasında, modelin farklı finansal piyasalara uyarlanması ve sosyal medya verileri gibi ek değişkenlerin entegrasyonu bulunmaktadır.

Anahtar Kelimeler—Hisse senedi yön tahmini, Makine Öğrenmesi, Derin Öğrenme, LSTM, Extra Trees, Çoklu Sınıflandırma, BIST100

I. GİRİŞ

Borsalar, menkul kıymetlerin alıcı ve satıcılar arasında alım satım işlemlerinin düzenli olarak gerçekleştirildiği organize piyasalarıdır. Bu piyasalar, belirli kurallar çerçevesinde ve genellikle belli bir zaman ve mekânda faaliyet gösterir. Tarihsel olarak borsaların kökeni, 1531 yılında Belçika'nın Bruges veya Anvers kentinde, "Van Der Buers" ailesinin düzenlediği sürekli fuara dayanmaktadır. Bu oluşum, zamanla finansal merkezlerin temellerini atmış ve 16. yüzyıldan itibaren Paris ve Londra gibi şehirlerde borsaların ortayamasına zemin hazırlamıştır. İstanbul borsa faaliyetlerinin başlangıcı ise Osmanlı İmparatorluğu döneminde "Dersaadet Tahvilat Borsası" adıyla gerçekleşmiştir [1, 2]. Küresel ölçekte, borsalar zamanla yaygınlaşarak ekonominin dinamik bir parçası haline gelmiştir [3].

Borsa çok dinamik ve belirsiz bir alan olmasından ötürü borsanın tahmini doğal olarak popüler bir konu olmuştur [4]. Borsalardaki hisselerin genel trendlerinin takip edilmesinde ve performansının ölçülmesi adına hisse senedi endeksleri ortaya çıkmıştır. Hisse senedi endeksleri, finansal piyasaların genel eğilimlerini yansitan önemli göstergelerdir. Bu endekslerin gelecekteki hareketlerini öngörmek, yatırımcılara ve karar vericilere piyasayı değerlendirmede ve stratejik yatırım kararları almada büyük fayda sağlar. Aynı zamanda borsa endeks tahminleri, ekonomi yönetiminde maliye politikalarının şekillendirilmesi için de değerli bilgiler sunmaktadır. Bu doğrultuda, hisse senedi endekslerinin doğru bir şekilde tahmin edilmesi, finans dünyasında sıkça çalışılan konulardan biri olmuştur [5, 6]. Finansal piyasalarındaki hisse senedi fiyatları, şirketlerin performansları, sektörel gelişmeler, dünyada meydana gelen olaylar gibi birçok unsurdan etkilenmektedir [5, 7]. Politik gelişmeler, şirket politikaları, ekonomik ortamın genel durumu, yatırımcıların öngörülerı, kurumsal yatırımcı tercihlerinin etkisi, küresel piyasalarındaki dalgalandırmalar ve yatırımcı psikolojisi gibi faktörler, hisse fiyatı tahminini daha karmaşık ve zorlu bir süreç haline getirmektedir. [8, 9].

Piyasanın gidişatını anlamlandırmak adına çeşitli kuramlar ve hipotezler ortaya atılmıştır. Bunlardan birkaçı Etkin Piyasa Hipotezi, Rastgele Yürüyüş Teorisi ve Davranışsal Finans Teorisidir. Etkin Piyasa Hipotezi, piyasada oluşan her fiyatın mevcut tüm bilgilerin yansısını sonucunda oluşmasına denir [10]. Bu hipoteze göre yeni oluşan her fiyat bilinmeyen ve yeni bir bilgiden kaynaklanacaktır. Aslında bu durum fiyatın tahmin edilemez olduğunu ortaya atar. Rastgele Yürüyüş Teorisi de aynı şekilde fiyatların rastgele olduğunu ve tahmin edilmesinin güvenilir olmadığını savunur [11]. Davranışsal Finans Teorisi ise bunların aksine insanların her zaman rasyonel davranış olduğunu duyularına göre hareket ettiğini varsayar [12]. Yatırımcıların FOMO (fırsatları kaçırma korkusu) etkisine kapılıp yanlış kararlar alması buna örnek olarak verilebilir [13]. Hisse senedi fiyatının tahmini ise üç ana başlıkta ayrılır. Bunlar teknik analiz, temel analiz ve evrimsel analizdir. Teknik analizde grafikler ile indikatörler kullanılır. Indikatörler fiyat ve hacim verilerine çeşitli matematiksel fonksiyonlar uygulanarak oluşturulan istatistiksel bir analiz yöntemidir. En yaygın teknik göstergeler hareketli ortalamalardır. Hareketli ortalamalar genellikle bir hisse senedinin destek ve direnç seviyelerini belirlemede kullanılır. Geçmiş fiyatları kullandığından dolayı gecikmeli bir indikatördür. Zaman aralığı arttıkça gecikme de artar. Temel analizde mali tablolar, haberler, hisse ile ilgili gelişmeler değerlendirilir [14, 15]. Hisse senedi fiyat endeksi yönünün tahmini için yapılan

çalışmaların çoğu gelişmiş finansal piyasalar üzerinden yapılmıştır. Literatürde, Türk borsası gibi gelişmekte olan piyasalar üzerinde yapılan çalışmalar az sayıda bulunmaktadır [8].

Son yıllarda, akademik çalışmalarında yapay zekanın finans piyasalarındaki rolüne büyük bir ilgi gösterilmiştir. Bilgisayar teknolojisi ve öğrenme yöntemlerindeki ilerlemelerin etkisiyle borsa tahmini, finans ve bilgisayar bilimlerinin kesiştiği bir konu haline gelmiştir [16]. Özellikle makine öğrenmesi ve derin öğrenmenin finans alanındaki uygulamaları geleneksel zorlukların aşılmasında önemli katkılardır [17]. Yapay zeka tabanlı tahminler, geleneksel yöntemleri geride bırakarak, doğru yatırım kararları almada ve getiriyi arttırmada önemli bir avantaj sağlar [18]. Geleneksel yöntemler temel ve teknik analiz kullanır ancak bu yöntemlerin sınırlamaları vardır. Yapay zeka ise büyük veri analizi ve desen tanıma özellikleri sayesinde geleneksel yöntemlerden daha doğru sonuçlar verir [19].

Analiz yöntemleri, verilerden anlam çıkarıp karar vermeyi sağlamaktadır. Bu kapsamda sınıflandırma ve tahminleme algoritmaları öne çıkar. Sınıflandırma algoritmaları, eğitim verilerinden sınıf dağılımını öğrenerek test verilerini doğru bir şekilde sınıflandırmaya odaklanır. Tahminleme algoritmaları ise geçmiş verileri analiz ederek gelecekteki eğilimler hakkında çıkarımlar sunar [20]. Hisse senedi yön tahmini konusunda literatürde bulunan çalışmalarla özellikle Uzun Kısa Süreli Bellek (LSTM) derin öğrenme modeli, doğrusal olmayan modellemeye uygunluğu nedeniyle hisse senedi fiyatı tahmininde yaygın olarak kullanılmaktadır [9] ve diğer modellere göre daha iyi performans ve başarılı sonuçlar elde etmektedir [21, 22]. LSTM, zaman serisi verilerindeki uzun dönemli bağımlılıkları öğrenme yeteneği ile tanınan bir derin öğrenme modelidir [23]. Finansal piyasalarda, özellikle hisse senedi fiyatlarının tahmininde, geçmiş verilere dayalı güclü öngörülerde bulunabilmesi nedeniyle sıkılıkla kullanılmaktadır. LSTM, bu tür verilerdeki karmaşıklıkları ve belirsizlikleri aşmak için önemli bir araştırır. Ancak risk yönetimi ve getiri analizinde kısıtlamaları vardır [24]. Bu çalışmada LSTM, Ekstra ağaç (Extra tree) sınıflandırma algoritmasıyla birlikte hibrit bir model oluşturularak kullanılacaktır. Extra Tree yönteminin seçilmesinin sebebi Rastgele Orman (Random Forest) yöntemine göre daha başarılı sonuç vermesidir [25]. Ayrıca Extra Tree daha az aşırı uyum yapan ve daha hızlı eğitim süresine sahip bir yöntemdir [26]. Lstm ve Extra Tree yöntemlerinin kendine göre avantajlı kısımlarından faydalananarak daha başarılı bir çalışma ortaya koymak hedeflenmiştir.

Bu çalışma, LSTM ve Extra Tree yöntemlerini bir arada kullanarak kısa vadeli borsa yön tahmini yapmayı bunu yaparken çoklu sınıflandırma yaparak yatırımcılara ve finansal analistlere doğru stratejik kararlar alırmayı hedefler. Literatürde çoklu sınıflandırma kullanımının az olması bunun temel sebebidir. Makine öğrenmesi ve derin öğrenme tabanlı hisse senedi yön tahmini üzerine yapılan çalışmalar, geniş bir kitlenin ilgisini çekmektedir. Çünkü hisse senedi piyasalarındaki fiyat değişimleri direkt finansal getiri ve yatırım risklerini etkiler. 2024 yılı itibarıyla, küresel sermaye piyasalarında işlem hacmi günlük trilyon dolarlara ulaşmış durumda ve dünya genelinde milyonlarca bireysel ve kurumsal yatırımcı bulunmaktadır [27]. Ayrıca, yapay zeka destekli finansal analizlerin kullanım hızla artmaktadır bu durum, kısa vadeli tahminlerin etkinliğini artırma amacıyla çalışmaları, yatırımcılar, finans kurumları ve teknoloji şirketleri için stratejik açıdan önemli kilmaktadır.

Bu araştırmalarda karşılaşılan en büyük problemlerden biri, hisse senedi fiyatlarının birçok faktöre göre anlık olarak değişim

göstermesidir. Ayrıca, kısa vadeli tahminler yaparken yüksek doğruluk oranına ulaşmak oldukça zordur çünkü veri çok gürültülüdür. Aynı zamanda piyasada her zaman belirsizlik hakimdir. Derin öğrenme yöntemlerinden LTSİ gibi zaman serisi analizi yapan yöntemler, geçmiş piyasa verilerinden öğrenme yaparak bu belirsizlikleri gidermeye amaçlar, ancak yine de doğru sonuçlar elde etmek için doğru modelleme teknikleri ve doğru veri kaynakları kullanılmalıdır [28].

Veri kaynağı olarak Borsa İstanbul verileri kullanılacak olup Yahoo Finance ve Kaggle veri kaynaklarından yararlanılacaktır. Çalışmamızın yeniliği ve literatüre katkısı:

- 1) Literatürde yaygın olarak kullanılan "al", "sat" gibi ikili sınıflandırma yerine, yatırımcıların riskini minimize etmemi hedefleyerek "al", "tut", "sat" olmak üzere 3 sınıf kullanılcaktır. Bu yaklaşım, yatırımcılara daha hassas ve stratejik kararlar alabilme imkanı taniyacak, piyasa hareketlerine göre daha ayrıntılı sinyaller sağlayarak risk yönetimini artıracaktır[29, 30].
- 2) Lstm ve Extra Tree yöntemlerini bir arada kullanarak karlılık artıracaktır.
- 3) Diğer sınıflandırma yöntemleriyle karşılaştırılarak analiz edilecektir.

Bu konuda ele alınan problemler, yatırımcılar için daha doğru kararlar almak, finansal kurumlar için risk yönetimi sağlamak ve piyasa trendlerini tahmin etmek için kritik öneme sahiptir. Yapay zeka ve makine öğrenmesinin bu süreçlere entegrasyonu, finansal hizmet sektöründe önemli bir dönüşüm yaratmaktadır [31].

Bu çalışma, makine öğrenmesi ve derin öğrenme teknikleri kullanılarak kısa vadeli hisse senedi yön tahmininin yapıldığı ve bu tahminlere katkı sağlayan yeni bir çoklu sınıflandırma yaklaşımının incelendiği bir araştırmadır. Çalışma, şu ana başlıklardan oluşacaktır:

- **Literatür İncelemesi:** Literatürde hisse senedi yön tahminine dair kullanılan yöntemler ve mevcut sınıflandırma teknikleri nasıl kullanılmış, eksikleri neler, bu alandaki temel araştırmalar ve kullanılan veri setleri, literatüre katkıları incelenecektir.
- **Yöntemler:** Bu bölümde, çalışmanın önerdiği çoklu sınıflandırma yaklaşımının temelini oluşturan algoritma ile makine öğrenmesi ve derin öğrenme tekniklerinin nasıl uygalandığı ayrıntılı bir şekilde anlatılacaktır. Beş etiketli sınıflandırma sisteminin işleyışı, LTSİ ile ExtraTree modellerinin entegrasyonu aktarılacaktır.
- **Deneysel Çalışmalar:** Yöntemin test edilmesi için kullanılan veri setleri ile yapılan deneyler sunulacak, elde edilen sonuçlar tartışılacaktır. Bu bölümde, modelin başarı oranları ve yatırımcı riski azaltma potansiyeli üzerinde durulacaktır.
- **Tartışma ve Sonuç:** Çalışmanın genel bulguları özeti alınacak ve başarısı tartışılacaktır. Yatırımcılar için ne tür katkılar sağladığına dair bir değerlendirme yapılacaktır. Bu alanla ilgili gelecekte neler yapılabilir. Çalışmanın zayıf tarafları anlatılacaktır.

II. LITERATÜR İNCELEMESİ

Günümüzde finansal zaman serilerinin analizi ve hisse senedi fiyatlarının tahmini, literatürde sıkça ele alınan bir konu olmuştur. Çeşitli araştırmalarda, makine öğrenmesi ve derin öğrenme modellerinin de hisse senedi fiyatlarını aynı zamanda yönünü tahmin etme konusundaki başarısı vurgulanmaktadır. Bu kısımda, piyasaların fiyat ve yön tahmini yöntemleri konusundaki akademik çalışmalar ele alınmıştır. Literatürdeki çalışmalar, kullanılan veri setleri, yöntemler, elde edilen sonuçlar ve tespit edilen eksiklikler incelenmiştir. Ayrıca bu çalışmaların gelecekteki araştırmalar için sunduğu potansiyel katkıları değerlendirilmiştir.

Aşağıdaki bölümde, hisse senedi fiyat ve yön tahmini üzerine yapılan çalışmaların özetleri ve tabloları (Tablo I, Tablo II ve Tablo III) sunulmaktadır. Bu analiz, mevcut literatürün güçlü ve zayıf yönlerini ortaya koyarak, bu çalışmanın özgünlüğünü ve katkısını daha net bir şekilde ifade etmeyi amaçlamaktadır.

Gündüz (2021) [32], BIST30 Endeksinde yer alan sekiz bankacılık hissesinin saatlik verilerini kullanarak hissenin saatlik yönü tahmin edilmeye çalışılmıştır. Uzun Kısa Süreli Bellek (LSTM), Hafif Gradyan Artırma Makinesi (LightGBM), Varyasyonel Otomatik Kodlayıcılar (VAE), Özinelemeli Özellik Eleme (RFE) yöntemleri kullanılmış ve en başarılı sonuç diğer hisse özelliklerinin, ilgili hissenin kendi özellikleriyle birleştirilmesiyle bulunmuştur. Boyut azaltarak verimlilik arttırlılmış. Ancak boyut azaltma f-skor değerinde %3 oranında düşüş sağlamıştır.

Ayyıldız ve arkadaşları (2024) [33], G7'de bulunan ekonomileri gelişmiş ülkelerin endeks verileri kullanılarak endekslerin hareket yönleri tahmin edilmiş ve algoritmaların performansları karşılaştırılmıştır. Sonuçlar sırasıyla Yapay Sinir Ağları (ANN): %83.43, Lojistik Regresyon (Logistic Regression): %82.56, Destek Vektör Makineleri (SVM): %79.43, Naive Bayes: %62.60, Rastgele Orman (Random Forest): %59.00, Karar Ağaçları (Decision Trees): %56.63, K-En Yakın Komşu (KNN): %50.26 olmuştur. Farklı borsalarda farklı algoritmaların test edilmesi faydalı bir çalışma olmuş ancak makroekonomik verilerin dahil edilmemesi tahminlerin doğruluğunu sınırlamıştır.

Nabipour ve arkadaşları (2020) [34], Tahran borsasındaki 4 farklı hisse grubunun 10 yıllık veri setiyle borsadaki hareketlerin tahmin doğruluğunu artırmak için 9 makine öğrenmesi 2 de derin öğrenme yöntemini karşılaştırmışlardır. Bunları yaparken de hem sürekli veriyi hem de ikili veriyi test etmişler. En başarılı yöntem ise hem sürekli hem de ikili veride RNN ve LSTM olmuştur. F1-skor değeri %90'a kadar çıkmıştır. İkili veri diğer yöntemlerinde başarısını arttırmıştır. Ancak farklı ülkelerin borsalarında denenmediği için genelleştirme sınırlıdır.

Gür (2024) [35], Türk Hava Yolları hisse senedinin 3433 günlük veri setiyle fiyat tahmini yapmaya çalışılmıştır. Çalışmada LSTM, XGBoost ve SVM karşılaştırılmış ve LSTM başarılı olmuştur. Ancak R2 değeri diğer yöntemlere göre bir miktar düşmüştür.

Altuntaş ve arkadaşları (2023) [36], Borsa İstanbul 100 (BIST100) endeksinin 15 yıllık verisini kullanarak endeksin yönünü tahmin etmeye çalışmışlardır. Bunu görüntü sınıflandırma yöntemiyle yapmışlardır. AlexNet, GoogleNet, ResNet-50 modelleri kullanılmıştır. Teknik indikatörler görsellere dönüştürülmüş ve eğitilmiştir. Sonuç olarak ResNet-50 en başarılı sonucu vermiştir. Veri setinin sınıfal dağılımının dengesiz olmasından kaynaklı AlexNet ve GoogleNet mimarilerinin hassasiyet ve duyarlılık değerleri arasında dengesizlik vardır.

Khan ve arkadaşları (2023) [37]. Tesla Inc. 5 yıllık hisse senedi verisini kullanarak borsanın yönünü tahmin etmeye çalışılmıştır. 9 makine öğrenimi modeli kullanılmıştır. Yenilik olarak ge-

leneksel yöntemlerdeki günlük kapanış verisini kullanmak yerine piyasa açılışından sonraki 15 dakika dikkate alınmış ve geneliksel yöntemlerle karşılaştırılmıştır. 15 dakikalık Logistic Regression %90.60 doğruluk elde etmiştir. Modellerin karlılığıda hesaplanmıştır. Zaman dilimleri artırılabilir. Böylece yaklaşımın faydası daha da belirginleşecektir.

Büyükkor ve arkadaşları (2024) [38], BIST100 endeks veri setiyle borsa endeks yönünü ağaç tabanlı makine öğrenmesi teknikleri kullanarak tahmin etmeye çalışmışlardır. XGBoost %90.4 doğrulukla en başarılı yöntem olmuştur. Veri kaynağının sınırlı olması eksikler olarak söylenebilir. Genellikle derin öğrenmenin kullanıldığı bir alanda Topluluk Makine Öğrenmesi yöntemlerinin zaman serisi verilerinde başarılı olması çalışmanın güçlü taraflarıdır.

Wang ve arkadaşları (2020) [39], Çin merkezli 10 adet hisse senedinin veri setini kullanarak hisse senedi fiyat tahminlerini iyileştirmek için hibrit model yaklaşımı kullanmışlar ve bu modelin ARIMA, XGBoost gibi modellerin tek kullanılmasından daha başarılı bir sonuç elde etmişlerdir. DWT-ARIMA-GSXGB hibrit modeli en iyi sonucu vermiştir. Parametre seçiminin karmaşıklığı zaman ve hesaplama maliyetinin yüksek olması eksiklik olarak söylenebilir. Modelin genelleme kabiliyeti yüksektir. Dalga Dönüşümü (DWT) kullanılarak tahmin hataları azaltılmıştır.

Hoque ve arkadaşları (2021) [40], Suudi Arabistan borsasındaki 11 farklı hisse senediyile 8 farklı model kullanarak hisse senedi fiyat tahminine yönelik bir çalışma yapmışlardır. Çalışmanın amacı hiperparametre ayarlarının modellerin başarısına etkisini incelemektir. Sonuç olarak bazı yöntemlerde başarı oranı azalmış SVR, GPD, SGD modellerinde ise başarı oranı artmıştır. "Wilcoxon effect size" gibi güçlü bir istatistiksel araç kullanılması hiperparametremere ayarının modellere etkisini anlamak açısından faydalı olmuştur.

Naik ve arkadaşları (2021) [41], Hindistan borsasındaki birkaç hisse senedi verisini kullanarak hisselerdeki krizlerin (hisse senedi fiyatının %10 dan fazla düşmesi) tespitine yönelik bir model geliştirilmiştir. Hibrit öznitelik seçimi ile XGBoost en başarılı sonucu vermiştir. Modellerin optimizasyonunda yalnızca temel parametre ayarlarına odaklanılmıştır. Daha gelişmiş makine öğrenmesi yöntemleri kullanılabilir. Hibrit öznitelik seçimi ile gereksiz parametrelerin çıkarılması verimliliği artırmıştır.

Lin ve arkadaşları (2021) [42], Çin hisse senedi verileriyle makine öğrenmesi ve teknik analiz yöntemlerini birleştirerek daha doğru ve etkili hisse senedi tahminleri yapmak amaçlanmıştır. Bunun yanı sıra, geliştirilen yatırım stratejisinin performansının teorik olarak oldukça yüksek olduğu, ancak işlem maliyetlerinin yatırım getirisini üzerinde önemli bir etkisi olduğu belirtilmiştir. Sekiz trigram sınıflandırması gibi yeni özellik mühendisliği yöntemlerinin geliştirilmesi çalışmanın güçlü yönlerindendir.

Ampomah ve arkadaşları (2020) [43], Üç farklı borsadan (NYSE, NASDAQ ve NSE) rastgele seçilen 8 adet hisse senedi veri setiyle ağaç tabanlı makine öğrenmesi modellerinin fiyat hareketinin yön tahminine yönelik bir çalışma yapılmıştır. En başarılı sonuç Extra Tree sınıflandırma yöntemi olmuştur. Lstm gibi zaman serisinde başarılı derin öğrenme yöntemleriyle karşılaşılma yapılmaması çalışmanın eksikliklerindendir. Eğitim seti için çapraz doğrulama kullanılmış, modelin aşırı öğrenmesini azaltmış ve genelleme yeteneğine katkı sağlamıştır.

Illa ve arkadaşları (2021) [44], Haber verilerini ve DJIA endeks verilerini kullanarak fiyat tahmini yapmaya çalışmışlar. SVM ve RF makine öğrenmesi algoritmalarını kullanmış ve en başarılı sonucu %87.4 doğrulukla SVM yöntemi vermiştir. Çalışmada derin öğrenme modelleri ve hibrit yaklaşım kullanılmamış ve

karşılaştırılmamıştır. Haber verileri için multi-gram modelinin kullanılması çalışmanın başarısını arttırmıştır.

Julian ve arkadaşları (2023) [45], Endonezya hisse senedi piyasasındaki verileri kullanarak fiyat tahmini yapılmaya çalışılmıştır. Yöntem olarak çok katmanlı algılayıcı yapay sinir ağı kullanılmış ve yenilik olarak gün kaydırma yöntemi ile gelecekteki 7 günün fiyat tahmini yapılması sağlanmıştır. Daha gelişmiş teknik indikatörler kullanılarak çalışma geliştirilebilir.

Aseeri (2023) [46], Suudi Arabistan borsası özelinde kısa vadeli tahminler yapma konusunda yeni bir metodoloji öneriyor. GRU modeli ve özellik mühendisliği süreçlerinin başarıyla birleştirilmesi, bu tahminlerin doğruluğunu artırmaktadır. Ayrıca modelin VARMAX gibi geleneksel yaklaşılara göre üstün olduğu vurgulanmıştır. Diğer derin öğrenme modelleriyle karşılaştırılma yapılmaması eksiklik olarak söylenebilir.

Arslankaya ve Arkadaşları (2021) [47], Ereğli Demir ve Çelik Fabrikaları T.A.Ş. borsa kapanış verilerini kullanarak fiyat tahmini yapılmıştır. Polinom Regresyon, Random Forest Regresyon, Tekrarlayan Sinir Ağları (RNN) ve Uzun-Kısa Süreli Bellek (LSTM) olmak üzere dört farklı yöntem kullanılmıştır. Random Forest Regresyon modeli en düşük hata değerlerini vermiştir. Hisse senedi fiyatlarını etkileyen diğer faktörlerin modele dahil edilmemiştir, bu faktörlerin dahil edilmesi ve veri setinin genişletilmesiyle tahmin doğruluğu dahada artırılabilir.

Arda ve Arkadaşları (2021) [48], BIST 30 endeksindeki hisse senedi fiyatlarını tahmin etmek için 7 algoritma kullanılmıştır. Bu algoritmalar doğrusal regresyon, hızlı orman yüzdelik regresyonu, karar ağacı regresyonu, destekli karar ormanı regresyonu, Bayes doğrusal regresyon, nöral ağ regresyonu ve Poisson regresyonudur. Kısa vadeli hisse senedi fiyat tahmininde en iyi sonucu Poisson regresyonu vermiştir. Hibrit modellerin oluşturulması ile en iyi sonuçlar elde edilebilir.

Dalkiran ve Arkadaşları (2022) [49], Türkiye İş Bankası A.Ş. ye ait ISCTR hissesi verilerini kullanarak günlük fiyat tahmini üzerinde çalışma yapılmıştır. Zaman serisi verilerinin modellenmesi için etkili olduğu bilinen LSTM (Uzun Kısa Dönem Hafiza) ve GRU (Kapılı Tekrarlayan Birim) derin öğrenme algoritmalarını kullanılmıştır. Sadece ISCTR hissesinin verileri değil, aynı zamanda diğer hisse senetlerinin (VAKBN, GARAN, QNBFB, AKBNK), endekslerin (USD/TRY, BIST30, BANKX) ve ekonomik göstergelerin verileri de modele dahil edilmiştir. Çalışma, tek bir hisse üzerinde gerçekleştirilmiş ve farklı modeller ile karşılaştırılmıştır.

Özcan (2023) [50], BIST 100 endeksinin yönünü tahmin etmek için dokuz farklı yöntem kullanılmıştır. Yöntemler, Lineer Diskriminant Analizi (LDA), Lojistik Regresyon Analizi (LR), Naive Bayes Algoritması (NB), Yapay Sinir Ağları (NNET), Rastgele Orman Algoritması (RF), Sınıflandırma ve Regresyon Ağacı Algoritması (CART), K-En Yakın Komşu Algoritması (KNN), Polinomiyal Çekirdek Fonksiyonu - Destek Vektör Makineleri (SVM-POLY) ve Gauss Çekirdek Fonksiyonu - Destek Vektör Makineleri (SVM-RBF) yöntemleri kullanılmıştır. Kısa vadeli hisse senedi yön tahmininde en iyi sonucu Polinomiyal Çekirdek Fonksiyonu ile Destek Vektör Makineleri (SVM-POLY) yöntemi vermiştir. Çalışmada derin öğrenme yöntemleri kullanılmamıştır. Kullanılan yöntemlerin derin öğrenme yöntemleriyle birleştirilerek ve daha fazla parametre kullanılarak test edilmesi ile daha doğru sonuçlar elde edilebilir.

Albayrak ve Arkadaşları (2023) [51], Borsa İstanbul (BIST 100) verilerini kullanarak hisse senedi fiyatlarını tahmin edilmiş ve modellerin performansları karşılaştırılmıştır. Ayrıca, 28 teknik göstergesi ile hesaplama yapılmıştır. USD/TRY para birimi ver-

ileri de kullanılmıştır. Çalışmada Otoregresif Entegre Hareketli Ortalama (ARIMA), Uzun Kısa Süreli Bellek (LSTM) ağları, Geçitli Tekrarlayan Birim (GRU) ve Dikkat katmanlı LSTM modelleri kullanılmıştır. En iyi sonuç Geçitli Tekrarlayan Birim (GRU) modeli ile alınmıştır. Kullanılan veriler için normalizasyon uygulanmamıştır. Gelecekte çalışmaya özellik ayırtırma optimizasyonu uygulanabilir.

Çetin ve Arkadaşları (2021) [52], İslami hisse senedi piyasasını Türkiye'de temsil eden Katılım Endeksi'nin (KATLM) tahmininde Uzun Kısa Süreli Bellek (LSTM) modelini kullanarak çalışma sunmuştur. Ayrıca çalışmada, BIST 100 (XU100) endeksi, altın oynaklı endeksi (GVZ), CBOE oynaklı endeksi (VIX) ve dolar endeksi (DXY) verileri kullanılmıştır. Sonuçlar, modelin KATLM endeksi yüksek doğrulukla tahmin edebildiğini göstermiştir. Çalışma farklı piyasalarda da gerçekleştirilmemiştir. Farklı algoritmalar ile karşılaştırma yapılmamıştır.

Pabuçcu (2019) [53], Borsa İstanbul (BIST 100) endeksinin negatif ve pozitif yönlü hareketlerini, Destek Vektör Makineleri (DVM), Yapay Sinir Ağları (YSA) ve Naive Bayes (NB) algoritmalarını kullanarak tahmin edilmeye çalışılmıştır. Teknik göstergelerinin kullanıldığı çalışmada en iyi sonucu Destek Vektör Makineleri (DVM) algoritması vermiştir. Algoritmaların birleştirilmesiyle oluşturulan hibrit modeller ile daha doğru sonuçlar alınabilir.

Aydın ve Arkadaşları (2024) [54], BİST30 endeksine dahil olan dört farklı sektörden hisse senetleri (THYAO, AKBNK, KCHOL, KRDMD) fiyatlarının tahmininde Uzun Kısa Dönemli Bellek (LSTM) ve Otoregresif Entegre Hareketli Ortalama (ARIMA) modellerinin performanslarını karşılaştırılmıştır. Çalışmaya makroekonomik faktörler (faiz oranları, enflasyon, döviz kurları) veya şirketlere özgü faktörler entegre edilmemiştir. Gelecekte diğer algoritmalarla karşılaştırma yapılabilir ve farklı piyasalarda test edilebilir.

Liu ve Arkadaşları (2020) [55], Çin piyasasından rastgele seçilen 14 hisse senedinin verileriyle hisse senedi fiyatlarını tahmin etmek için teknik analiz ve duygusal yöntemlerini birlestiren yeni bir hibrit model olan Recurrent Convolutional Neural Kernel (RCNK) modeli oluşturulmuştur. RCNK-T, RCNK-S, CNK, RCNN modelin farklı versiyonlarıyla performansları karşılaştırılmıştır. En iyi sonucu RCNK modeli elde etmiştir. Oluşturulan model birden fazla algoritma ve hesaplama içermesinden dolayı karmaşık bir modeldir. Gelecekte önerilen model farklı piyasalarda test edilebilir.

Shen ve Arkadaşları (2020) [56], Çin hisse senedi piyasasından alınan verilerle kısa vadeli hisse senedi fiyat tahmini amaçlanmıştır. Çalışmada özelleştirilmiş Uzun Kısa Dönemli Bellek (LSTM) modeli kullanılmış ve Destek Vektör Makinesi (SVM), Çok Katmanlı Algılayıcı (MLP), Naive Bayes (NB), Rastgele Orman (RF), Lojistik Regresyon (LR) modelleri ile karşılaştırılmıştır. Sonuçlar, LSTM modelinin daha yüksek tahmin değerleri verdiğiğini göstermiştir. Çalışma sadece Çin piyasasında yapılmıştır. Gelecekte, kullanılan LSTM modeli ile farklı hibrit modellerinin karşılaştırması yapılabilir.

Akbulut ve Arkadaşları (2023) [3], IBk, KStar, Random Forest, Random Committee ve LSTM modelleri ile BİST 100 tahmini amaçlanmıştır. Kullanılan veri seti, döviz piyasaları ve gelişmekte olan ülkelerin borsa endekslерini içermektedir. Çalışmada kullanılan modeller arasında en iyi sonucu LSTM vermiştir. Kullanılan algoritmalar ile hibrit modellerin oluşturulması daha yüksek tahmin değerleri verebilir. Gelecekte veri setinin genişletilmesiyle çalışma test edilebilir.

Sarıkoç ve Arkadaşları (2022) [57], Faktör Analizi (FA), Temel

Makale Yazarlar (Yıl)	Veri Seti	Örnek Sayıları	Yöntemler	Sonuçlar	Eksiklikler	Gelecek Katkıları
Hakan Gündüz (2021) [32]	BIST30 Endeksi'nde yer alan sekiz bankacılık hissesinin saatlik fiyat verileri	2011 ve 2015 yılları arasında toplanan 6705 örnek	VAE, RFE, LightGBM, SVM, LSTM	LSTM Doğruluk:%68.5 F-Skor: 0.574	Hisseler arasındaki ilişkileri anlamak için zaman bağımlılıkları modellenmemiştir.	Graf tabanlı yöntemler kullanılarak hisseler arasındaki nedensel bağımlılıklar modellenmeli
Ayyıldız ve Arkadaşları (2024) [33]	G-7 ekonomileri gelişmiş ülkelerin hisse senedi piyasası endeksleri	Her ülke için ortalama 500 günlük örnek	Decision Tree, ANN, Logistic Regression, Naive Bayes, KNN, SVM, RF	ANN Doğruluk:%83.43 Logistic Regression Doğruluk:%82.56	Derin öğrenme kullanılmamıştır. Makroekonomik veriler çalışmaya dahil edilmemiştir. Teknik göstergelerin sayısı azdır.	Farklı derin öğrenme algoritmaları kullanılmalı ve faiz oranları, ekonomik göstergeler vb. makroekonomik veriler dahil edilmeli.
Nabipour ve Arkadaşları (2020) [34]	Tahran Borsa'sından 4 farklı hisse grubu	Kasım 2009 ile Kasım 2019 yılları arasındaki günlük veriler. Tahmini olarak hisse grubuna 2000-2500 örnek	Decision Tree, ANN, Logistic Regression, Naive Bayes, KNN, SVC, RF, Adaboost, XGBoost, RNN, LSTM	LSTM ve RNN Ortalama F1-Skor:%85-%90	Daha güncel derin öğrenme modelleri kullanılmamıştır. Diğer veri türleri (haberler, duyurular) entegre edilmemiştir.	Hibrit modeller kullanılmalı ve yeni veri türleri entegre edilmeli
Yunus Emre GÜR (2024) [35]	Borsa İstanbul'daki Türk Hava Yolları (THYAO)	01.01.2010-05.09.2023 tarihleri arasında 3433 günlük örnek	LSTM, XGBoost, SVM	LSTM için RMSE:0.02431 MSE:0.00059 MAE:0.01572 R2:0.990854	Çalışmanın tek bir hisse üzerine olması genellemeye yapılmasını sınırlamıştır.	Farklı modellerin ve çeşitli zaman dilimlerinin incelenmesi (kısa vade veya uzun vade) yapılmalı
Altuntaş ve Arkadaşları (2023) [36]	Borsa İstanbul 100 (BIST100) endeks verisi	01/01/2006-31/12/2020 tarihini kapsayan 15 yıllık 3761 örnek	AlexNet, GoogleNet, ResNet-50	ResNet-50 Doğruluk:%54.62 F1-Skor:0.4856	Hibrit modeller ve topluluk öğrenmesi yöntemleri entegre edilmemiştir.	Tahmin modelleri farklı finansal enstrümanlar üzerindeki başarıları ölçülmeli
Khan ve Arkadaşları (2023) [37]	Tesla Inc. Hisse Senedi verisi	2016 ile 2021 yılları arasında toplanan 2191 günlük örnek	KNN, LR, ADABOOST, XGBoost, NB, DT, SVM, RF, ANN	15 Dakikalık Random Forest Doğruluk:%91.27 F1-Skor:%91 Günlük Logistic Regression Doğruluk:%85.51 F1-Skor:%85.50	Yeterince derin öğrenme yöntemleri kullanılmamıştır. 15 dakikalık strateji diğer zaman dilimleriyle karşılaştırılmamıştır.	Zaman dilimleri çeşitlendirilmeli ve model genel geçerliliği için başka sektör veya piyasa türleri kullanılmalı
Büyükkor ve Arkadaşları (2024) [38]	Borsa İstanbul 100 Endeksine (BİST100) ait veriler	680 Örnek	Günlük XGBoost, CATBoost, RF	XGBoost Doğruluk:%90.4 F1-Skor:%93 Özgülük:%85.7 Hassasiyet:%93.5	Derin öğrenme kullanılmamıştır. Veri seti sınırlıdır.	Örnek sayısı artırılmalı ve farklı finansal metriklerin (Risk-ödül oranı, maksimum düşüş) analize dahil edilmeli
Wang ve Arkadaşları (2020) [39]	Çin merkezli 10 farklı hisse senedi verileri	05/01/2015-28/12/2018 tarihleri arasındaki ortalama 975 günlük örnek	Ayrik Dalga Dönüşümü (DWT) ARIMA Modelleri (Farklı parametrelerle) Geliştirilmiş XGBoost Modeli (GSXGB)	DWT + ARIMA(3, 1, 0) + GSXGB hibrit model Doğruluk:%86	Modelde sadece fiyat verilerine yer verilmiştir. Daha fazla özellik eklenerek başarı arttırmamıştır.	Parametre optimizasyonu için daha gelişmiş yöntemler denenmeli
Hoque ve Arkadaşları (2021) [40]	Suudi Arabistan Borsası (Tadawul) 11 farklı sektörden şirketlerin hissesi	265-4950 arasında hisseye göre değişen örnek	KNN, SVR, DT, GPR, SGD, LASSO, PLS, KRR	SVR RMSE:0.25 MAPE:0.51 Win/Lose:%58	Hiperparametre ayarı derinlemesine incelenmemiştir.	Daha fazla hassasiyet analizi yapılarak hangi hiperparametre daha etkili araştırılmalı.
Naik ve arkadaşları (2021) [41]	5 Adet NIFTY50 hisse senedi verisi	Ocak 2007 ile Nisan 2021 arasındaki zaman aralığındaki veriler	Hybrid Feature Selection, XG-Boost, DNN	HFS tabanlı XGBoost MSE:142.6998 MAE:7.918674 RMSE:11.9457	Diğer popüler modeller (SVM, Random Forest vb.) ile karşılaştırılmamıştır.	Daha fazla teknik gösterge kullanılabilir ve diğer modellerle karşılaştırılabilir.

TABLE I: Literatür Taraması Sonuçları

Makale Yazarlar (Yıl)	Veri Seti	Örnek Sayıları	Yöntemler	Sonuçlar	Eksiklikler	Gelecek Katkıları
Lin ve arkadaşları (2021)[42]	Çin Hisse Senedi Piyasa Verileri	2000-2017 yılları arasında 168 hisse senedi ve 553,028 satır örnek veri	LR, SVM, KNN, RF, GBDT, LSTM	RF ve GBDT F1-Skor:%62-%80 Doğruluk:%50 ve üzeri	Derin öğrenme modelleri etkin değildir.	Takviye öğrenme yöntemleri dahil edilmeli
Ampomah ve arkadaşları (2020) [43]	Üç farklı borsadan rastgele seçilen 8 adet hisse senedi verisi	01/01/2005 ile 30/12/2019 yılları arasında toplanan her hisse için 3477 örnek	RF, XGBoost, AdaBoost, Bagging, Extra Trees, Voting	Extra Tree Doğruluk:%83.75 F-Skor:%84.10	Yalnızca ağaç tabanlı modeller karşılaştırılmış.	Lstm gibi zaman serisi analizine dayalı modeller eklenmeli ve karşılaştırılmalı
Illa ve Arkadaşları (2021) [44]	Reddit World News Channel, DJIA endeks ve The Guardian Haber verileri	2000-2016 yılları arasındaki veri seti örnek sayısı belirtilmemiştir	SVM, RF	Doğrusal Olmayan SVM Doğruluk:%87.4	Derin öğrenme kullanılmamıştır.	Hibrit modeller kullanılmalı ve karşılaştırılmalı
Julian ve Arkadaşları (2023) [45]	Endonezya hisse senedi piyasasındaki(IDX) veri seti	4249 örnek veri	MLP	MLP RMSE:657.1796 R2:0.9955 MAE:350.7431 MAPE:0.0334	Daha gelişmiş teknik göstergeler kullanılmamıştır.	Daha geniş veri seti kullanılmalı ve teknik göstergeler artırılmalı
Ahmad O.Aseeri (2023) [46]	Suudi Arabistan borsa endeksindek şirketlerin veri seti	2001-2017 tarihleri arasındaki veri	GRU, VARMAX	GRU R2:0.90 ve üzeri	Diğer derin öğrenme modelleri ile karşılaştırma yapılmamıştır.	Farklı teknik göstergeler eklenerek daha kapsamlı bir analiz yapılabilir
Arslankaya ve arkadaşları (2021) [47]	Investing-Eregli Demir ve Çelik Fabrikaları T.A.Ş. borsa kapanış verileri	01.01.2014 - 01.06.2020 tarihleri arasındaki 1619 örnek	RNN, LSTM, RFR, PR	En iyi sonuç:RFR MSE:0.0014 MAE:0.024 RMSE:0.037	Farklı hisse senetleri üzerinde çalışma yapılmamıştır. Hisse senedi fiyatlarını etkileyen enflasyon, döviz kurları gibi faktörler kullanılmıştır.	Hisse senedi fiyatlarını etkileyen diğer faktörlerin modele dahil edilmesi ve veri setinin genişletilmesi
Arda ve arkadaşları (2021) [48]	Borsa İstanbul Datastore-BIST30 kapanış değerleri	02.01.2014 - 30.12.2016 tarihleri arasındaki 755 örnek	DR, BDR, KAR, DKOR, HOYR, NAR, PR	Kısa vadede en iyi sonuç:PR Ortalama Hata:%0.2654 R^2 :0.7183	Hisse senedi fiyatlarını etkileyen enflasyon, döviz kurları gibi faktörler kullanılmıştır.	Hibrit modeller ile test edilmesi ve veri setinin genişletilmesi
Dalkiran ve arkadaşları (2022) [49]	Yahoo Finance-Türkiye İş Bankası A.Ş. ye ait ISCTR hissesi verileri	31.12.2007 - 28.02.2021 tarihleri arasındaki örnekler (örnek sayısı belirtilmemiştir)	LSTM, GRU	MSE:0.00233 MAE:0.04068 MRE:0.00813	Modelin performansı kısa dönemde test edilmiştir. Farklı piyasa verileri (sosyal medya, haberler) entegre edilmemiştir.	Başka hibrit modeller ile karşılaştırılması ve farklı hisse senetleri üzerinde çalışma yapılması
Özcan (2023) [50]	Investing-aylık ortalama BIST 100 endeks verileri	Ocak 2002 - Eylül 2022 tarihleri arasındaki örnekler (örnek sayısı belirtilmemiştir)	LR, LDA, NB, RF, KNN, CART, NNET, SVM-RFB, SVM-POLY	Kısa vadede en iyi sonuç:SVM-POLY ACC:0.71 F1:0.82 MCC:0.23	Derin öğrenme kullanılmamıştır. Farklı piyasa verileri (sosyal medya, haberler) entegre edilmemiştir	Kullanılan algoritmaların derin öğrenme algoritmalarıyla test edilmesi ve daha fazla parametre ile test edilmesi
Albayrak ve arkadaşları (2023) [51]	Matriks Bilgi Dağıtım Hizmetleri A.Ş.-BIST'teki 100 farklı hisse senedinin saatlik verileri	2001-2020 tarihleri arasındaki 772533 örnek	ARIMA, LSTM, GRU, AB-LSTM	En iyi sonuç:GRU MSE:0,0008 MAE:0,0205	Normalizasyon kullanılmıştır. Hibrit modeller kullanılmıştır.	özellik ayıklama optimizasyonu yapılması ve yerel dikkat mekanizması kullanılarak dikkat modelinin performansı değerlendirilmesi

TABLE II: Literatür Taraması Sonuçları

Makale Yazarlar (Yıl)	Veri Seti	Örnek Sayıları	Yöntemler	Sonuçlar	Eksiklikler	Gelecek Katkıları
Cetin ve arkadaşları (2021) [52]	Borsa İstanbul-KATLM endeksi verileri	07.01.2011 - 12.07.2021 tarihleri arasındaki 2645 örnek	LSTM	MAE:0.06 RMSE:0.08 MAPE:0.02 R^2 :0.994	Çalışma sadece Türkiye piyasası üzerinde yapılmıştır. Farklı algoritmalarla karşılaştırılma yapılmamıştır.	Farklı derin öğrenme algoritmaların test edilmesi, farklı risk faktörlerini için girdi değişkenleri ile analiz yapılması ve veri setinin genişletilmesi
Pabuçcu (2019) [53]	T.C. Merkez Bankası-BIST 100 günlük kapanış verileri	2009-2018 tarihleri arasındaki örnekler (örnek sayısı belirtilmemis)	YSA, DVM, NB	En iyi sonuç: DVM DoğruPozitif:0.985 YanlışNegatif:0.014 F-İst.:0.985 Perf:0.9845	Farklı piyasalar üzerinde çalışma yapılmamıştır. Farklı piyasa verileri (sosyal medya, haberler) entegre edilmemiştir.	Farklı algoritmalarla birleştirilerek hibrit modeller oluşturulması ve test edilmesi
Aydin ve arkadaşları (2024) [54]	Yahoo Finance-BİST30 THYAO, AKBANK, KCHOL, KRDMD hisse senetlerinin günlük kapanış verileri	24.04.2020 - 24.04.2024 tarihleri arasındaki örnekler (örnek sayısı belirtilmemis)	LSTM, ARIMA	En iyi sonuç:LSTM MAPE:1,09 R^2 :0,9422	Farklı piyasa verileri (sosyal medya, haberler) ve makroekonomik faktörler entegre edilmemiştir.	Hibrit modellerin geliştirilmesi ve farklı piyasalarda test edilmesi
Liu ve arkadaşları (2020) [55]	eastmoney.com-Chinese A-share market rastgele seçilen 14 hissenin verileri	01.11.2016 - 31.03.2020 tarihleri arasındaki örnekler (örnek sayısı belirtilmemis)	RCNK, RCNK-T, RCNK-S, CNK, RCNN	En iyi sonuç: RCNK ACC:%66.26 MCC:0.3918	RCNK birden fazla algoritma ve hesaplama içermesinden dolayı karmaşık bir modeldir.	Önerilen modelin farklı ülkelerin piyasaları üzerinde test edilmesi
Shen ve arkadaşları (2020) [56]	Tushare-Chinese stock market	2017 - 2018 tarihleri arasındaki 3558 örnek	LSTM, SVM, MLP, NB, RF, LR	F1:0.93 Doğruluk:0.93 Hassasiyet:0.96 Duyarlılık:0.96	Farklı piyasa verileri (sosyal medya, haberler) ve makroekonomik faktörler entegre edilmemiştir.	Diğer hibrit modellerle karşılaştırılması, modelin farklı ülke piyasalarında test edilmesi ve veri setinin genişletilmesi
Akbulut ve arkadaşları (2023) [3]	Investing-Şanghay, Ipc, Sensex, RTSI, Bovespa ve BİST 100 borsa endeks verileri	Ocak 2017 - Ekim 2021 tarihleri arasında 973 örnek	IBK, KSTAR, RF, RC, LSTM	En iyi sonuç:LSTM MAE:10.27 RMSE:14.15 RAE:6.06	Hibrit model kullanılmamıştır. Farklı piyasa verileri (sosyal medya, haberler) entegre edilmemiştir	Algoritmaların birleştirilmesiyle hibrit model oluşturma, farklı piyasalarda testler gerçekleştirme ve veri setinin genişletilmesi
Sarıkoç ve arkadaşları (2022) [57]	Yahoo Finance-Borsa İstanbul 100 endeksi günlük verileri	20/09/2002 - 24/07/2020 tarihleri arasındaki 4422 örnek	FA-LSTM, PCA-LSTM, ICA-LSTM	En iyi sonuç:PCA-LSTM RMSE:0,027007 R^2 :0,882893	Diğer derin öğrenme ve makine öğrenmesi yöntemleriyle karşılaştırma yapılmamıştır.	LSTM daha iyi optimize edilebilir, farklı derin öğrenme modelleri ve boyut indirgeme yöntemleri kullanılabilir
Şişmanoğlu ve arkadaşları (2020) [58]	IBM-NYSE, NASDAQ ve NYSE MKT'de işlem gören hisse senetlerinin günlük fiyat verileri	2 Ocak 1968 - 9 Nisan 2018 tarihleri arasındaki 12648 örnek	LSTM, GRU, BiLSTM	En iyi sonuç: BiLSTM RMSE:0,01 MSE:0,0001 MAE:0,010 DA:63,54	Tek hisse senedi üzerinde çalışma yapılmıştır. Farklı piyasa verileri (sosyal medya, haberler) ve makroekonomik faktörler entegre edilmemiştir.	Hibrit model oluşturulması, model performansının artırılması için farklı piyasa verilerinin entegre edilmesi ve veri setinin genişletilmesi
Ustali ve arkadaşları (2021) [59]	Investing-BIST 30 endeksi verileri	31.01.2010 - 31.12.2019 tarihleri arasındaki örnekler (örnek sayısı belirtilmemiştir)	YSA, RO, XG-Boost	En iyi sonuç: XG-Boost En iyi R^2 :0,758 Ortalama R^2 :0,722	Derin öğrenme kullanılmamıştır. Hibrit modeller oluşturulmamıştır.	YSA algoritmasının optimize edilmesi, farklı algoritmaların test edilmesi

TABLE III: Literatür Taraması Sonuçları

Bileşen Analizi (PCA) ve Bağımsız Bileşen Analizi (ICA) boyut indirgeme tekniklerinin LSTM modeli ile birleştirilip Borsa İstanbul (BIST100) endeks fiyatını tahmin yapmayı amaçlanmıştır. Veri seti, BIST100 endeksine ait günlük verileri ve teknik göstergeler içermektedir. Sonuçlar, PCA+LSTM modelinin performansı diğer modellerden daha iyi olduğu görülmüştür. Çalışmada diğer derin öğrenme ve makine öğrenmesi modelleriyle karşılaştırma yapılmamıştır. Gelecekte farklı derin öğrenme modelleri ve boyut indirgeme yöntemleri kullanılarak algoritmalar karşılaştırılabilir.

Şişmanoğlu ve Arkadaşları (2020) [58], NYSE, NASDAQ ve NYSE MKT hisse senetlerinin günlük fiyat verilerini kullanarak borsa fiyatlarını tahmin etmeye amaçlamaktadır. Çalışmada Uzun-Kısa Vadeli Bellek (LSTM), Çift yönlü LSTM (BLSTM) ve Kapılı Tekrarlayan Hücre (GRU) modelleri kullanılmıştır. En iyi sonucu BLSTM modeli vermiştir. Çalışma tek hisse senedi üzerinde yapılmıştır. Gelecekte farklı algoritmalarla karşılaşılması ve model performansının artırılması için farklı piyasa verilerinin entegre edilmesi tahmini güçlendirebilir.

Ustalı ve Arkadaşları (2021) [59], Borsa İstanbul 30 Endeksi verileri kullanılarak firmaların hisse senedi fiyatlarını tahmin etmek amaçlanmıştır. Rastgele Orman (RO), Yapay Sinir Ağları (YSA) ve XGBoost algoritmaları kullanılmıştır. En iyi sonucu XGBoost algoritması vermiştir. Çalışmada derin öğrenme kullanılmamıştır. Yapay Sinir Ağları (YSA) algoritması diğer çalışmalara kıyasla kötü sonuç vermiştir. Gelecekte YSA algoritmasının optimize edilip farklı algoritmalarla testler yapılabilir.

Yapılan literatür incelemesi, finansal zaman serilerinin analizi ve hisse senedi fiyat tahmini üzerine gerçekleştirilen çalışmaların geniş bir yelpazede çeşitli yöntem ve yaklaşımalarla ele alındığını göstermektedir. İncelenen çalışmaların, makine öğrenmesi ve derin öğrenme modellerinin finansal tahminlerde geleneksel yöntemlere kıyasla daha yüksek doğruluk oranlarına ulaştığını gözler önüne sermiştir. Ancak kullanılan veri setlerinin yetersizliği, yöntemlerin genelleştirilebilirliği ve bazı çalışmalarda hibrit modellerin eksikliği gibi yönler araştırmaların hâlâ geliştirilmesi gerektigine işaret etmektedir. Çalışmamızın önerdiği yöntemler, mevcut eksiklikleri aşmayı ve literatüre katkıda bulunmayı hedeflemektedir. LSTM'in doğrusal olmayan veri modelleme kabiliyeti, Extra Tree'nin genellemeye yeteneğiyle birleştiğinde, daha yüksek doğruluk ve güvenilirlik sağlamaktadır. Özellikle kullanılan yöntemin çoklu sınıflandırma yaklaşımı, literatürdeki mevcut yaklaşımlara kıyasla daha detaylı ve stratejik kararlar sağlamayı amaçlamaktadır.

III. METOT

A. Veri Seti

1) *Veri Kaynağı:* Çalışmada kullanılan veriler Borsa İstanbul 100 endeks verisi, SP 500 endeks verisi, Ons Altın verisi olup erişimi herkese açık olan Yahoo Finance web sitesindeki ([XU100.IS](#)) veri setinden alınmıştır.

2) *Veri Tipi:* Çalışmada kullanılan BIST100 ([XU100.IS](#)) veri seti tarih, günlük bazda açılış, kapanış, en yüksek ve en düşük fiyatlar ile işlem hacmi parametrelerini ve bunlardan elde edilen [IV](#). Tablodan formülleriley birlikte gösterdiğimiz 10 adet teknik indikatörü kapsamaktadır. Ayrıca bunlardan elde edilmiş verilerde eklenerken veri seti zenginleştirilmiştir.

3) *Veri Setinin Boyutu:* Veri seti 08/02/2006 ile 10/01/2025 tarihleri arasındaki günlük verileri içerecektir. Toplamda 4587 örnek vardır. Çalışmanın yenilikçi taraflarından biri olan çoklu sınıflandırma için her bir fiyat bir önceki fiyata göre karşılaştırılmış "al", "tut", "sat", olmak üzere 3 sınıfta sınıflandırılacaktır.

B. Öznitelik Çıkarmı

Çalışmada kullanılan temel öznitelikler her günün açılış fiyatı, kapanış fiyatı, en yüksek ve en düşük fiyatlar, hacim değerlerinden oluşmaktadır. Endeks yönüyle ilgili literatürdeki çalışmaları incelediğimizde teknik göstergeler çalışmanın başarısında önemli katkı sağlamaktadır. Bundan dolayı [Tablo IV](#)'te belirtilen 10 adet teknik indikatör kullanılmıştır [60] (Kara vd., 2011; Patel vd., 2015; Büyükkor vd., 2024).

- Basit Hareketli Ortalama (SMA): n -günlük zaman diliminin fiyatlarının ortalamasının alınmasıyla bulunur. Piyasayı anlamak adına önemli indikatörlerdir.
- Ağırlıklı Hareketli Ortalama (WMA): Her veri noktasına farklı bir ağırlık atayarak güncel zaman dilimine yaklaşıkça bu ağırlığı artırır. Böylece güncel zamanın önem derecesi artar.
- Momentum: Kısaca fiyat değişimlerini birim zamanda ölçen bir göstergedir. Piyasadaki trendleri anlamaya yardımcı olur.
- Stokastik %K: Hisse senedi fiyatlarının herhangi bir zaman daki en yüksek ve en düşük fiyat aralığına göre aşırı alım ya da aşırı satım sinyalleri verir.
- Stokastik %D: Stokastik %K'nın n süre için hareketli ortalamasının alınmasıyla bulunur. Fiyat hareketlerinin doğruluğunu onaylamak ve trendin gücünü anlamak için kullanılır.
- Göreli Güç Endeksi (RSI): Momentum tabanlı aşırı alım veya aşırı satım durumlarını tespit etmek için kullanılan indikatördür ve 0-100 aralığında bir değer alır.
- Hareketli Ortalamanın Yakınsama Iraksaması (MACD): MACD, kısa ve uzun vadeli hareketli ortalamaların farkını alarak, piyasa trendlerini takip etmeye yardımcı olur.
- Larry Williams %R: Günümüz fiyatının ele alınan zaman dilimindeki en yüksek fiyata yakınlık oranını verir. Momentum göstergesidir.
- A/D Birikim/Dağıtım Osilatörü: temelde hacim verilerini kullanarak arz ve talebi ölçer, fiyatın ne kadar güçlü olduğunu gösterir.
- Emtia Kanal Endeksi (CCI): CCI fiyatın ortalama fiyat ile ne kadar sapma gösterdiğini ölçerek aşırı alış ve aşırı satış sinyalleri verir.
- Daily_Range: Günlük fiyat aralığı, en yüksek ve en düşük fiyatlar arasındaki fark.
- Daily_Range_Pct: Günlük fiyat aralığının yüzdesi, günlük aralığın açılış fiyatına oranı.
- Range_MA5: 5 günlük fiyat aralığı hareketli ortalaması.
- Volume_Change: İşlem hacmindeki değişim oranı.
- Volume_MA5: 5 günlük işlem hacmi hareketli ortalaması.
- Volume_Trend: İşlem hacmi trendi, hacim değişimlerinin yönünü gösterir.
- Upper_Shadow: Üst gölge, gün içindeki en yüksek fiyat ile kapanış fiyatı arasındaki fark.
- Lower_Shadow: Alt gölge, gün içindeki en düşük fiyat ile açılış fiyatı arasındaki fark.
- Body_Size: Mum çubuğuñun gövde boyutu, açılış ve kapanış fiyatları arasındaki fark.
- Trend_Strength: Trend gücü, fiyat hareketlerinin yönünü ve gücünü ölçer.
- Trend_Consistency: Trend tutarlığı, fiyat hareketlerinin sürekliliğini ölçer.
- Support_Level: Destek seviyesi, fiyatın düşüş eğiliminde durabileceği seviyeyi gösterir.
- Resistance_Level: Direnç seviyesi, fiyatın yükseliş eğiliminde durabileceği seviyeyi gösterir.
- Price_Position: Fiyatın belirli bir süre içindeki konumu.

İndikatör Adı	Formülü
Basit Hareketli Ortalama	$\frac{C_t + C_{t-1} + \dots + C_{t-n}}{(n)C_t + (\frac{n}{n-1})C_{t-1} + \dots + C_{t-n}}$
Ağırlıklı Hareketli Ortalama	$\frac{C_t - C_{t-n}}{\frac{H_t - L_{t-n}}{H_{t-n} - L_{t-n}}} \times 100$
Momentum	$\frac{\sum_{i=0}^{n-1} K_{t-i}}{n} \%$
Stokastik %K	$100 - \frac{\sum_{i=0}^{n-1} U_{p,t-i}/n}{\sum_{i=0}^{n-1} D_{w,t-i}/n}$
Stokastik %D	$MACD(n)_{t-1} + \frac{2}{n+1} \times (DIFF_t - MACD(n)_{t-1})$
Görelî Güç Endeksi	$\frac{H_n - C_t}{H_n - L_n} \times 100$
Hareketli Ortalamanın Yakınsaması(MACD)	$\frac{H_t - C_{t-1}}{H_t - L_t}$
Larry William's %R	$M_t = \frac{H_t + L_t + C_t}{3}, SMT_t = \frac{\sum_{i=1}^n M_{t-i+1}}{n}, D_t = \frac{\sum_{i=1}^n M_{t-i+1} - SMT_t }{n}, Up_t: t \text{ zamanındaki yukarı yönlü fiyat değişiklikleri ve } Dw_t: t \text{ zamanındaki aşağı yönlü fiyat değişikliklerini göstermektedir.}$
Birim/Dağıtım Osilatörü (A/D)	$M_t = \frac{H_t + L_t + C_t}{3}, SMT_t = \frac{\sum_{i=1}^n M_{t-i+1}}{n}, D_t = \frac{\sum_{i=1}^n M_{t-i+1} - SMT_t }{n}, Up_t: t \text{ zamanındaki yukarı yönlü fiyat değişiklikleri ve } Dw_t: t \text{ zamanındaki aşağı yönlü fiyat değişikliklerini göstermektedir.}$
Emtia Kanal Endeksi(CCI)	$0.015 D_t$

TABLE IV: Seçilen teknik indikatörler ve formülleri.

C_t : Kapamış fiyatı, L_t : t zamanındaki En Düşük Fiyat, H_t : t zamanındaki En Yüksek Fiyat, $DIFF_t = EMA(12)_t - EMA(26)_t$, EMA : Üstel Hareketli Ortalama, $EMA(k)_t = EMA(k)_t - 1 + \alpha(C_t - EMA(k)_t)$, α : Düzleştirmeye Sabiti $\frac{2}{k+1}$, k : zaman periyodu için EMA , LL_t and HH_t : Geçmiş t günde en küçüklerin $\frac{2}{k+1}$ kucuk ve en büyüklerin en büyüğü, $M_t = \frac{H_t + L_t + C_t}{3}$, $SMT_t = \frac{\sum_{i=1}^n M_{t-i+1}}{n}$, $D_t = \frac{\sum_{i=1}^n |M_{t-i+1} - SMT_t|}{n}$, Up_t : t zamanındaki yukarı yönlü fiyat değişiklikleri ve Dw_t : t zamanındaki aşağı yönlü fiyat değişikliklerini göstermektedir.

- RSI_Change: RSI değişimi, RSI değerindeki değişim oranı.
- MACD_Change: MACD değişimi, MACD değerindeki değişim oranı.
- MA5_Position: 5 günlük hareketli ortalama pozisyonu.
- MA20_Position: 20 günlük hareketli ortalama pozisyonu.
- Doji: Doji mum çubuğu formasyonu, açılış ve kapanış fiyatlarının çok yakın olduğu durumları belirtir (True/False).
- Engulfing: Engulfing mum çubuğu formasyonu, bir munun önceki mumu tamamen kapsadığı durumları belirtir (True/False).
- Volume_Log: İşlem hacminin logaritmik değeri.

Bu öznitelikler, makine öğrenmesi ve derin öğrenme yöntemlerinde girdi olarak kullanılacaktır.

C. Veri Ön işleme

Veriyi doğru şekilde işlemek, makine öğrenimi ve derin öğrenme modellerinin başarı oranını artırmak için önemlidir. Veri ön işleme, ham verileri modelin öğrenebilmesi için uygun bir formata dönüştürmek anlamına gelir. Veri genellikle üç ana kısımda ön işleme yapılır. Bunlar Veri temizleme, Ölçeklendirme, Veri ayımı bölgümleridir.

1) *Veri Temizleme*: Veri temizleme, modelin doğru ve güvenilir sonuçlar verebilmesi için eksik, hatalı, ya da anormal verilerin düzeltilmesi işlemidir. Bu aşama, özellikle finansal verilerde önem arz eder. Borsa İstanbul, 2020 yılında pay endekslерinin artan seviyelerini göz önünde bulundurarak fiyat ve getiri endekslерinden iki sıfır atılmasına karar vermiştir (Borsa İstanbul, 2020) [61]. Bu değişiklik nedeniyle, veri setindeki anlam bütünlüğünü korumak amacıyla 27/07/2020 tarihinden önceki endeks değerleri 100'e bölünmüştür. Bazi teknik indikatördeki aykırı değerler, Çeyrekler Açıklığı (IQR) yöntemi ile filtrelenmiştir. Çeyrekler açıklığı, bir veri setindeki %25'lik ve %75'lik değerler arasındaki farkı ifade eder. Yani, $IQR = Q3 - Q1$ formülü ile hesaplanır. Bu ölçüm, veri setindeki aşırı değerleri tespit etmek için sıklıkla kullanılan bir yöntemdir.

2) *Ölçekleme*: Veri setinde kullanılan farklı özniteliklerin farklı ölçeklerde olması, modelin öğrenme sürecini olumsuz etkileyebilir.

Bu durum, bazı özelliklerin diğerlerine göre daha fazla ağırlık kazanmasına yol açarak modelin doğruluğunu düşürebilir. Örneğin, yüksek değerli öznitelikler düşük değerli olanları göz ardı edebilir böylece yanlış sonuçlar ortaya çıkabilir. Bu nedenle veriler Min-Max normalizasyon yöntemi kullanılarak [0,1] aralığına normalize edilmiştir. Bu sayede indikatör değerlerindeki ölçek farkı giderilmiştir [62](Yüce, 2021).

Min-Max normalizasyon formülü

$$x' = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}}$$

Bu formülde :

- x' Normalize edilmiş değer
- x_i Normalize edilecek değer
- x_{\min} Veri setindeki en küçük değer
- x_{\max} Veri setindeki en büyük değer

3) *Veri Ayımı*: Modelin doğru bir şekilde genellenebilmesi için verinin eğitim ve test setlerine ayrılması gereklidir. K-Fold Çapraz Doğrulama (K-Fold Cross Validation) yöntemi kullanılarak veri seti 5 katmana ayrılmıştır. Bu yöntem, veriyi K eşit parçaya böler ve her birini sırayla test seti olarak kullanarak modeli eğitir. Böylece, modelin genel performansı daha güvenilir bir şekilde ölçülür. Verimiz zaman serisi olduğu için zaman sıralı bir şekilde bölünmüş olup her fold artışıda eğitim seti üstüne eklenecek artmıştır ve test setinin eğitim veri setinden tarihsel olarak sonra gelmesine dikkat edilmiştir.

D. Öznitelik Seçimi

Öznitelik seçimi veri seti içerisinde modelin eğitimine en az katkısı olan özniteliklerin tespit edilmesine ve azaltılmasına yardımcı olur. Özellikle yüksek boyutlu veri setlerinde, gereksiz veya fazla ilişkili öznitelikler modelin karmaşıklığını artırabilir ve performansı düşürebilir. Bu sebepten öznitelik seçimi, verinin boyutunu küçültürken, modelin doğruluğunu artırmaya katkı sağlar. Çalışmamızda Temel Bileşen Analizi (PCA) kullanılacaktır.

PCA Yöntemi: Boyutu fazla olan veri kümesindeki önemli verileri tutarak veriyi küçültür. Böylece model eğitiminde kolaylık sağlar.[63](Jolliffe, 2002).

$$X' = XW$$

X : Orijinal veri matrisi

W : Dönüşüm matrisi

X' : Oluşan veri boyutu azaltılmış matris

LDA Yöntemi: Linear Discriminant Analysis (LDA) yöntemi, sınıflar arasındaki ayımı artırmak ve veri boyutunu azaltmak için kullanılan denetimli bir öğrenme yöntemidir. Bu yöntem, maksimum ayımı sağlayan yeni özellikler elde etmek için veriyi lineer bir projeksiyonla dönüştür [64](Fisher, 1936).

Başlangıcta, tüm özellikler $X = \{x_1, x_2, \dots, x_n\}$ veri setini içerir.

LDA yöntemi, sınıflar arasındaki varyansı maksimum yapan projeksiyon yönlerini hesaplar:

$$w = S_W^{-1} S_B$$

Burada:

- S_W : Sınıf içi dağılım matrisi (Within-class scatter matrix).
- S_B : Sınıflar arası dağılım matrisi (Between-class scatter matrix).
- w : Projeksiyon vektörüdür.

Projeksiyon vektörleri kullanılarak veriler yeni bir uzaya dönüştürülür. Yeni uzaydaki veri Z şu şekilde ifade edilir:

$$Z = X \cdot w$$

Burada X , orijinal veri matrisi ve w , LDA ile elde edilen projeksiyon vektördür.

- X : Orijinal veri matrisi.
- w : LDA projeksiyon vektörü.
- Z : Yeni uzaya dönüştürülen veri.

LDA yöntemi, sınıflar arasındaki farkı artırırken sınıf içi farkları azaltır. Bu sayede, boyut azaltma ve ayırmayı artırma amacıyla sıkça kullanılır.

E. Model Seçimi

Makine Öğrenme Yöntemleri : Makine öğrenmesi (Machine Learning), bilgisayarların veri üzerinden öğrenme yeteneği kazanmasını sağlayan bir yapay zeka alt kümesidir. Bu yöntem, büyük miktarda veriyi analiz ederek desenleri tespit etmeye ve gelecekteki olaylar hakkında tahminler yapma imkanı tanır. Günümüzde geliştirilmiş makine öğrenmesi algoritmalarından bazıları, Extra Tree, Random Forest, XGBoost, SVM ve KNN'dır [58].

Bu çalışmada ele alınan makine öğrenmesi yöntemleri, borsa tahminlerinde doğruluğu artırmayı hedefleyerek, yatırımcılara ve finansal analistlere daha iyi karar destek araçları sunmayı amaçlamaktadır.

- **Ekstra Ağaç (Extra Tree)**: Karar ağaçları tabanlı bir topluluk öğrenme yöntemidir. Random Forest algoritmasına benzer, ancak ağaçların oluşturulmasında daha fazla rastgelelik ekler. Modelin varyansını azaltır ve genelleme kabiliyetini artırır. Extra Tree'nin en büyük avantajı, hızlı hesaplama süresi ve düşük aşırı öğrenme (overfitting) eğilimidir. Bu özellikler, özellikle büyük veri setleri ve yüksek boyutlu problemlerde avantaj sağlar.

$$\text{Gini Saflığı} = \sum_{j=1}^O f_j(1 - f_j)$$

O : Benzersiz etiket sayısı

f_j : Bir düğümdeki j etiketinin sıklığı

$$f = \sum_{j=1}^O -f_j \log(f_j)$$

- **Rastgele Orman (Random Forest)**: Random Forest, birden çok karar ağaçından oluşan topluluk öğrenme prensibine dayalı bir algoritmadır. Güçlü genelleme kabiliyeti ve aşırı öğrenmeye karşı dayanıklılığı ile bilinir. Her bir ağaç, eğitim veri setinin rastgele alt örnekleri ve özelliklerini kullanılarak eğitilir. Karar, tüm ağaçların oylanması ile belirlenir.

$$f = \frac{1}{B} \sum_{b=1}^B f_b(x')$$

B : Torbalama sayısı

f_b : Sınıflandırma ağaçları

x' : Görülmeyen örnekler için üretilmiş tahminler

$$\text{Gini}(D) = 1 - \sum_{j=1}^n p_j^2$$

- **XGBoost (Extreme Gradient Boosting)**: Zayıf öğrenicilerin bir araya getirilerek güçlü bir öğrenici oluşturulması prensibine dayanır. Algoritma, ardışık olarak ağaçlar

oluşturur ve her ağaç, önceki ağaçların hatalarını düzeltmeye çalışır. Özellikle zaman serisi analizi ve büyük veri setlerinde yüksek başarı sağlar.

$$L(\phi) = \sum_{i=1}^n \ell(y_i, \hat{y}_i^{(t)}) + \sum_{k=1}^K \Omega(f_k)$$

Hata Fonksiyonu

$\ell(y_i, \hat{y}_i^{(t)})$: Kayıp fonksiyonu

$\Omega(f_k)$: Regularizasyon terimi

$$\Omega(f_k) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$$

T : Yaprak sayısı

w_J : Yaprak ağırlığı

- **Destek Vektör Makineleri (Support Vector Machines - SVM)**: Sınıflandırma ve regresyon problemleri için kullanılan bir algoritmadır. Veriyi, sınıflar arasındaki ayrimı maksimum yapan bir hiper düzlem ile ayırmayı hedefler. Çekirdek fonksiyonları (kernel functions) kullanarak doğrusal olmayan problemleri de çözebilir. Yüksek boyutlu verilerde iyi performans gösterir. Aşırı öğrenmeye karşı dayanıklıdır.

$$w \cdot x + b = 0$$

Hiper Düzlem Denklemi

w : Ağırlık vektörü

x : Özellik vektörü

b : Sabit terim

$$W(\Lambda) = \Lambda^T 1 - \frac{1}{2} [\Lambda^T D \Lambda + \frac{\delta^2}{C}]$$

Kuadratik Optimizasyon Sorunu

$$K(u, v) = \exp\{-\frac{|u-v|^2}{\sigma^2}\}$$

Nokta Çarpımının Konvolüsyonu

- **K-En Yakın Komşu (K-Nearest Neighbors - KNN)**: Bir örneği sınıflandırmak için komşu noktaların çoğunluk sınıfını dikkate alan bir algoritmadır. K değeri, komşu sayısını ifade eder ve modelin kararını etkileyen önemli bir parametredir. Etiketlenmiş nesneler ile etiketlenmemiş nesneler arası mesafe hesaplanarak k -en yakın komşuları tanımlanır. Nesnenin sınıfını belirlemek için de en yakın komşuların sınıf etiketi kullanılır. Eğitim verileri her bir örnekle işleme alırmı. Test edilen örneğin sınıfı, eğitim veri setindeki örneğe en yakın k adet örnek seçilerek belirlenir. Öklid formülü ile örnekler arası mesafe hesaplanır.

$$d(x_i, x') = \sqrt{\sum_{r=1}^n (a_r(x_i) - a_r(x'))^2}$$

x_i ve x_j örnekleri arasındaki Öklid mesafesi

$a_r(x)$, x örneğinin r inci özelliği

- **Derin Öğrenme Yöntemleri** : Derin öğrenme (Deep Learning), makine öğrenmesinin bir alt dalı olarak, büyük veri kümeleri ve karmaşık yapılar ile çalışan bir yöntemdir. İnsan beyninin bilgi işleme ve karar verme süreçlerinden esinlenerek geliştirilmiştir. Derin öğrenme algoritmaları, katmanlar halinde düzenlenmiş yapay sinir ağlarına dayanır. Bu yöntemler, verilerin özündeki karmaşık ilişkileri modellemek ve analiz etmek için güçlü bir araçtır [58]. Günümüzde geliştirilmiş makine öğrenmesi algoritmalarından bazıları, LSTM, Bi-LSTM, RNN, CNN ve GRU'dur.

- **Uzun Kısa Süreli Bellek (Long Short-Term Memory)**

- **LSTM:** Bir tür tekrarlayan sinir ağıdır. Zaman serisi analizine uygun olarak geliştirilmiştir. Bellek hücreleri sayesinde uzun süreli bağımlılıkları öğrenme kapasitesine sahiptir. Zaman serisi verilerindeki geçmiş bilgiyi unutmadan saklayabilir. Özellikle doğal dil işleme (NLP) ve finansal tahminler gibi alanlarda yaygın olarak kullanılır. 4 katmanlı bir yapı kullanılır. Genellikle sigmoid ve tanh fonksiyonları tercih edilir. LSTM, veri bağımlılıklarını koruyabilmek için giriş kapısı (input gate), unutma kapısı (forget gate) ve çıkış kapısı (output gate) kullanır.

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

Unutma Kapısı (Forget Gate)

f_t : Unutma kapısının çıktısı

x_t : Zaman adımdındaki giriş

h_{t-1} : Önceki gizli durum

W_f : Ağırlık matrisi

b_f : Bias

σ : Sigmoid aktivasyon fonksiyonu

$$\begin{aligned} i_t &= \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \\ \tilde{C}_t &= \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \\ C_t &= f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \end{aligned}$$

Giriş Kapısı (Input Gate)

i_t : Giriş kapısının çıktısı

\tilde{C}_t : Yeni bellek hücresi

C_t : Bellek durumu

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t \odot \tanh(C_t)$$

Çıkış Kapısı (Output Gate)

o_t : Çıkış kapısının çıktısı

h_t : Şimdiki gizli durum

- **Çift Yönlü Uzun Kısa Süreli Bellek (Bidirectional LSTM - Bi-LSTM):**

LSTM mimarisinin çift yönlü bir versiyonudur. Hem geçmiş hem de gelecekteki bağlama öğrenebilir. Daha kapsamlı bir bağlam analizi sağlar; daha doğru tahminler üretebilir. Çift yönlü olduğu için iki bağımsız LSTM katmanı içerir. Tanh ve sigmoid gibi fonksiyonlar kullanılır.

$$h_t^{\text{forward}} = \text{LSTM}(x_t, h_{t-1}^{\text{forward}})$$

$$h_t^{\text{backward}} = \text{LSTM}(x_t, h_{t+1}^{\text{backward}})$$

$$h_t = h_t^{\text{forward}} \oplus h_t^{\text{backward}}$$

\oplus : Birleştirme işlemi

- **Tekrarlayan Sinir Ağları (Recurrent Neural Network)**

- **RNN:** Zaman bağımlı verilerdeki ardışık ilişkileri modellemek için tasarlanmış bir sinir ağı türüdür. Temel bir yapı sunar ve kısa dönemli bağımlılıkları iyi modelleyebilir. Uzun dönemli bağımlılıkları modellemekte zorluk çeker çünkü unutma problemi yaşar. Tipik olarak 1-3 katmanlıdır. Tanh ve ReLU kullanılır.

$$h_t = \tanh(W_h \cdot h_{t-1} + W_x \cdot x_t + b_h)$$

h_t : Şimdiki gizli durum

W_h, W_x : Ağırlık matrisleri

b_h : Bias

\tanh : Aktivasyon fonksiyonu

$$y_t = W_y \cdot h_t + b_y$$

Çıkış Hesaplama

y_t : Çıktı

- **Evrışimsel Sinir Ağları (Convolutional Neural Network)**

- **CNN:** Görüntü ve zaman serisi verilerindeki özellikleri algılamak için evrişim katmanları kullanan bir sinir ağıdır. Özellikle çıkarımı ve boyut indirgeme için etkilidir. Paralel işlemeye uygundur. Tipik olarak 4-5 arasında evrişim katmanı kullanılır. ReLU yaygın kullanılır.

$$z_{i,j} = \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} x_{i+m, j+n} \cdot w_{m,n} + b$$

Evrişim

$z_{i,j}$: Filte sonucu

$x_{i+m, j+n}$: Giriş matrisi

$w_{m,n}$: Filtre ağırlıkları

b : Bias

$$a_{i,j} = \text{ReLU}(z_{i,j})$$

Aktivasyon

$$p_{i,j} = \max_{m,n} a_{i+m, j+n}$$

Havuzlama

- **Kapılı Tekrarlayan Birim (Gated Recurrent Unit - GRU):**

LSTM'ye benzer şekilde çalışan, ancak daha basit bir mimariye sahip olan bir RNN türüdür. LSTM'nin getirdiği avantajları daha düşük hesaplama maliyetiyle sunar. Daha az parametreye sahiptir, bu nedenle daha hızlı çalışır. Zaman serisi verilerinde etkili performans gösterir. Genellikle 2-4 katmanlı bir yapıdadır. Sigmoid ve tanh kullanılır.

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t] + b_z)$$

Güncelleme Kapısı (Update Gate)

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t] + b_r)$$

Reset Kapısı (Reset Gate)

$$\tilde{h}_t = \tanh(W_h \cdot [r_t \odot h_{t-1}, x_t] + b_h)$$

Aday Durum (Candidate State)

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$$

Gizli Durum Güncellemesi

Önerilen Model : Önerilen Tahmin Modeli Adımlar ve Metodoloji

- **1. Veri Ön İşleme Aşaması**

- 1.1 27/07/2020 öncesi veriler 100'e bölünür.
- 1.2 Çeyrekler Açıklığı yöntemiyle üç noktadaki veriler silinir.
- 1.3 Min-Max normalizasyon işlemi yapılır.
- 1.4 K-Fold Çapraz Doğrulama yöntemiyle veri seti 5 katmana ayrılır ve model eğitimi için hazır hale gelir.

- **2. Veri Etiketleme Aşaması**

- 2.1 Kategoriler = { "Al", "Tut", "Sat", }

- 2.2 Etiketle (Veri Seti, Kapanış Fiyat Değişimleri, Kategoriler)
- 3. Model Eğitim Aşaması
 - 3.1 LSTM Modeli = Eğit (LSTM, Eğitim Verisi)
 - 3.2 Extra Tree Modeli = Entegre Et (LSTM Modeli, Özellikler)
- 4. Karşılaştırma Aşaması
 - 4.1 Diğer Algoritmalar ile Kıyasla
 - 4.2 Performans Metrikleri = Hesapla ({AUC-ROC, Özgüllük, F1-Skoru, Doğruluk, Duyarlılık})
- 5. Sonuç
 - 5.1 Modeli Değerlendir (Performans Metrikleri)

Algoritmamızın özgünlüğü çoklu sınıflandırma yaklaşımından gelmektedir. Her bir girdi bir önceki günün verileriyle kıyaslanarak ayrı ayrı sınıflandırılır.

Al: Gösterge değerleri %0.5 ve üzeri artış gösterdiğinde
Tut: Gösterge değerlerindeki değişim %0.5'den küçükse (pozitif veya negatif)
Sat: Gösterge değerleri %0.5 ve üzerinde düşüş gösterdiğinde

Alınan bu sınıflar modellerin eğitilmesinde kullanılır. Extra tree modeline veri setinin tamamını verilerek eğitilir. Ardından Lstm modeline sadece endeks verileri ile eğitilir. LSTM modelinin son katmanından elde edilen yoğun (dense) katman çıktıları ve Extra Trees modelinin tahmin çıktıları birleştirilir. Bu birleşik çıktı, daha sonra bir veya daha fazla yoğun katmandan geçirilir ve son olarak bir çıkış katmanına bağlanır. Böylece daha güvenilir ve doğru bir sonuç elde etmeye çalışılmıştır. Lstm ve Extra Tree yöntemlerinin bir arada kullanarak daha genellenebilir bir uygulama yapmak hedeflenmiştir. Aynı zamanda çoklu sınıflandırma yaklaşımıyla yatırımcıların riskini minimize ederek kayıp oranlarını ve ani düşüşlerden kaçmak amaçlanmıştır. Aşağıda çalışmanın ana modeli akış şemasıyla özetlenmiştir.

F. Model Eğitimi

Eğitim Süreci: Eğitim, belirlenecek epoch süresince gerçekleştirilecek ve her epoch sonunda modelin doğruluk oranı ölçülecektir. Erken durdurma (early stopping) yöntemiyle eğitim, modelin doğruluk oranı artmadığı takdirde durdurulacaktır. Çalışmanın hesaplamaları deneysel kısmında gerçekleştirilecektir.

Hiperparametre Ayarları: Eğitim sürecinde kullanılan başlıca hiperparametreler aşağıdaki gibidir:

- **Öğrenme Oranı :** Eğitim sırasında optimal değeri bulana kadar farklı değerlerde denenecektir. Modelin ne kadar hızlı öğreneceğini belirler.
- **Batch Sayısı:** Her eğitim adımında kullanılacak veri miktarı. Bütün veriyi bir anda işlemek çok zor olacağından parçalanarak işlenir.
- **Epoch Sayısı:** Epoch değeri tüm veri setinin seçilen modelde eğitilmesi sürecinin bir kez çalıştığı dönemi ifade eden hiperparametre değeridir ve her epoch modelin ağırlıklarını değiştirerek modelin başarısını artırmayı amaçlar.

Aşırı Öğrenme ve Yetersiz Öğrenme:

Aşırı Öğrenme (Overfitting): Seçilen modelin eğitim verilerine alışması ve başarılı olması ancak görülmeyen verilere karşı zayıf performans göstermesi durumudur. Bu sorunu önlemek için, modelin doğruluk oranı her epoch sonunda doğrulama seti üzerinde değerlendirilecek ve erken durdurma teknigi kullanılarak modelin aşırı öğrenmesinin önüne geçilecektir.

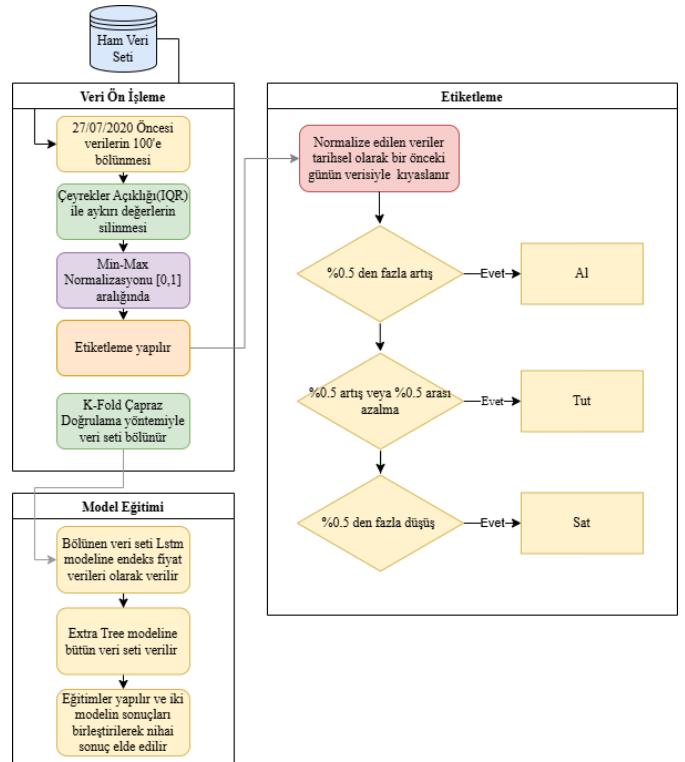


Fig. 1: Önerilen algoritmanın şeması.

Yetersiz Öğrenme (Underfitting): Yetersiz öğrenme, modelin eğitim verilerini yeterince öğrenememesi ve genel olarak düşük performans sergilemesi durumudur. Bu durumu önlemek için modelin hiperparametreleri, doğruluk oranları artırılana kadar optimize edilecektir.

G. Model Değerlendirme

Modelin performansını değerlendirmek için çeşitli metrikler kullanılmıştır. Bu metrikler, modelin doğruluğu ve genel başarısını anlamak için önemlidir. Kullanılan metrikler arasında doğruluk (accuracy), duyarlılık (recall), özgüllük (specificity), F-skor (F1 score) ve AUC-ROC (Area Under the Curve - Receiver Operating Characteristic) bulunmaktadır.

Karmaşıklık Matrisi: Karmaşıklık matrisi, modelin performansını ölçmek ve değerlendirmek için kullanılan bir tablodur. Bu tablo, modelin yaptığı tahminlerin sonuçlarını kategorilere ayıracak özetler.

TABLE V: Karmaşıklık Matrisi

	Gerçek Pozitif (TP)	Gerçek Negatif (TN)
Tahmin Pozitif (FP)	Yanlış Pozitif	Doğru Pozitif
Tahmin Negatif (FN)	Yanlış Negatif	Doğru Negatif

TP (Doğru Pozitif): Modelin pozitif olarak tahmin ettiği ve gerçekte de pozitif olan durumlar.

FP (Yanlış Pozitif): Modelin pozitif olarak tahmin ettiği, ancak gerçekte negatif olan durumlar.

TN (Doğru Negatif): Modelin negatif olarak tahmin ettiği ve其实 de negatif olan durumlar.

FN (Yanlış Negatif): Modelin negatif olarak tahmin ettiği, ancak其实 de pozitif olan durumlar.

Değerlendirme Metrikleri: Aşağıda, modelin başarı ölçütlerinin hesaplanması için kullanılan formüller verilmiştir:

1) Doğruluk (Accuracy): Doğruluk, modelin tüm tahminlerinin ne kadarının doğru olduğunu gösteren bir metiktir. Formülü şu şekilde:

$$\text{Doğruluk (Accuracy)} = \frac{TP + TN}{TP + TN + FP + FN}$$

2) Duyarlılık (Recall): Duyarlılık, modelin pozitif sınıfları doğru bir şekilde tahmin etme yeteneğini gösterir. Formülü şu şekilde:

$$\text{Duyarlılık (Recall)} = \frac{TP}{TP + FN}$$

3) Özgüllük (Specificity): Özgüllük, modelin negatif sınıfları doğru bir şekilde tahmin etme yeteneğini gösterir. Formülü şu şekilde:

$$\text{Özgüllük (Specificity)} = \frac{TN}{TN + FP}$$

4) F1-Skor (F1 Score): F-skor, duyarlılık ve özgüllüğün harmanlanmış bir ölçüsüdür ve genellikle dengesiz veri setlerinde kullanılır. Formülü şu şekilde:

$$\text{F-Skor (F1 Score)} = 2 \times \frac{\text{Duyarlılık} \times \text{Özgüllük}}{\text{Duyarlılık} + \text{Özgüllük}}$$

5) Kesinlik (Precision): Kesinlik, modelin pozitif sınıfları doğru bir şekilde tahmin etme yeteneğini gösterir. Formülü şu şekilde:

$$\text{Kesinlik (Precision)} = \frac{TP}{TP + FP}$$

6) AUC-ROC: AUC-ROC, modelin pozitif sınıfı doğru bir şekilde ayırt etme yeteneğini gösteren bir grafiktir. ROC eğrisi, modelin doğruluk oranına göre ne kadar iyi sınıflandırma yaptığına dair bilgi verir. AUC ise bu eğrinin altındaki alanı ifade eder. Yüksek bir AUC değeri, modelin iyi performans gösterdiğini gösterir.

$$\text{AUC} = \int_0^1 \text{Gerçek Pozitif Oran} d(\text{Yanlış Pozitif Oran})$$

IV. DENEYSEL SONUÇLAR

Hisse senedi piyasalarında kısa vadeli yön tahmini, yatırımcılar için stratejik karar alma süreçlerinde kritik bir rol oynar. Ancak bu problem, piyasa hareketlerinin karmaşıklığı ve belirsizlikleri nedeniyle çözümü son derece zordur. Bu zorluğu aşmak için yapay zeka yöntemlerinin sunduğu güçlü analiz ve tahmin kapasitesi değerlendirilmiştir. Çalışmamızda kullandığımız veri seti, Borsa İstanbul'dan alınan tarihsel piyasa verilerini, S&P 500 endeks verilerini ve, Ons altın verilerini içermektedir. Ancak, bu veri setini kullanmadan önce, verilerin işlenebilir hale getirilmesi için çeşitli yöntemler uygulanmıştır.

İlk olarak, veri kümesi üzerinde eksik değerleri doldurma, ceyrekler açıklığı ile uç değerleri temizleme ve Min-Max normalizasyon gibi ön işleme adımları gerçekleştirilmiştir. Daha sonra,

hisse senedi fiyatlarının dinamiklerini daha iyi anlamak için çeşitli teknik indikatörler (SMA, RSI...) çıkararak özellik mühendisliği yapılmıştır. Özellik seçimi aşamasında ise, modelin başarısını optimize etmek ve gereksiz veri yükünü azaltmak amacıyla öznitelikler belirlenmiştir. Bu veri kümesini, makine öğrenmesi, derin öğrenme ve özgün hibrit algoritmalarımızın sınıflandırma yeteneklerini test etmek amacıyla kullanılmıştır.

Bu bölümde, uygulanan sınıflandırma tekniklerinin performanslarını detaylı bir şekilde ele alacak ve sonuçları analiz edeceğiz. Ayrıca, her bir modelin güçlü ve zayıf yönlerini tartışarak, önerilen hibrit yaklaşımın diğer modellerle kıyasla nasıl sonuçlar verdiği anlatıcıcaz. Bu deneysel bulgular, yapay zeka tabanlı finansal analizlerin pratikteki değerini vurgularken, literatüre de önemli bir katkı sunmayı amaçlamaktadır.

A. Model Performansı ve Değerlendirmesi

Performans Metrikleri: Bir modelin işlevselligini değerlendirmek ve farklı taraflarını incelemek için kritik öneme sahip olan performans metrikleri sırasıyla doğruluk, modelin genel başarısını ölçerken, duyarlılık ve özgüllük, modelin pozitif ve negatif sınıfları ne kadar iyi ayırdığını gösterir. Kesinlik, pozitif tahminlerdeki doğruluğa odaklanırken, F1 skoru, duyarlılık ve kesinliği dengeleyerek özellikle dengesiz veri setlerinde faydalıdır. AUC-ROC, modelin sınıflandırma yeteneğini genel bir perspektiften değerlendirderek farklı eşiklerdeki performansı analiz eder. Bu metrikler bir arada kullanıldığında, modelin güçlü ve zayıf yönlerini daha kapsamlı bir şekilde anlamak mümkündür. Çalışmada kullanılan modellerin performans sonuçları VI, VII, VIII ve IX tablolarında detaylıca verilmiştir.

TABLE VI: Performans Karşılaştırması: Makine Öğrenmesi

Model	PCA Durumu	Doğruluk	Kesinlik	Duyarlılık	Özgüllük	F1-Skor	AUC-ROC
Önerilen Model	PCA Off	0.78	0.78	0.78	0.89	0.78	0.92
Önerilen Model	PCA On	0.70	0.73	0.70	0.69	0.68	0.88
Ekstra Ağacı	PCA Off	0.75	0.75	0.75	0.87	0.72	0.91
Ekstra Ağacı	PCA On	0.65	0.69	0.65	0.82	0.59	0.86
Rastgele Orman	PCA Off	0.78	0.77	0.78	0.89	0.77	0.93
Rastgele Orman	PCA On	0.64	0.64	0.64	0.81	0.60	0.84
XGBoost	PCA Off	0.77	0.77	0.77	0.89	0.76	0.93
XGBoost	PCA On	0.62	0.64	0.62	0.80	0.58	0.82
KNN	PCA Off	0.69	0.69	0.69	0.70	0.67	0.86
KNN	PCA On	0.69	0.69	0.69	0.85	0.67	0.85
SVM	PCA Off	0.79	0.79	0.79	0.90	0.78	0.93
SVM	PCA On	0.75	0.76	0.75	0.87	0.74	0.90

TABLE VII: Performans Karşılaştırması: Derin Öğrenme

Model	PCA Durumu	Doğruluk	Kesinlik	Duyarlılık	Özgüllük	F1-Skor	AUC-ROC
Önerilen Model	PCA Off	0.78	0.78	0.78	0.89	0.78	0.92
Önerilen Model	PCA On	0.70	0.73	0.70	0.69	0.68	0.88
LSTM	PCA Off	0.77	0.79	0.77	0.89	0.75	0.91
LSTM	PCA On	0.70	0.70	0.70	0.86	0.67	0.87
Bi-LSTM	PCA Off	0.71	0.73	0.71	0.88	0.68	0.89
Bi-LSTM	PCA On	0.69	0.70	0.69	0.83	0.65	0.85
RNN	PCA Off	0.75	0.77	0.75	0.89	0.74	0.91
RNN	PCA On	0.74	0.77	0.74	0.88	0.72	0.91
GRU	PCA Off	0.71	0.71	0.71	0.88	0.69	0.87
GRU	PCA On	0.70	0.72	0.70	0.84	0.67	0.88
CNN	PCA Off	0.67	0.68	0.67	0.84	0.65	0.82
CNN	PCA On	0.55	0.55	0.55	0.75	0.47	0.74

Model Performansına PCA Etkisi: Veri setine uyguladığımız PCA ile 40 sütunlu veriyi 15 sütuna indirerek boyut indirgeme işlemi gerçekleştirilmiştir. Bu işlem, modellerin performans metrikleri üzerinde farklı etkiler yaratmıştır. Örneğin, hibrit modelde PCA uygulanmadığında doğruluk oranı %78 olarak ölçülürken, PCA

uygulandığında bu oran %70'e gerilemiştir. Benzer şekilde, LSTM modeli için PCA, doğruluk oranını %77'den %70'e düşürmüştür. Bu sonuçlar, PCA'nın boyut indirgeme sırasında bilgi kaybına neden olduğunu ve bu kaybın model performansını etkilediğini göstermektedir.

Makine öğrenimi modellerinde de benzer bir durum gözlemlenmiştir. Rastgele Orman modeli için PCA uygulanmadığında doğruluk oranı %78 olarak ölçülmüş, ancak PCA uygulandığında bu oran %64'e gerilemiştir. Benzer şekilde, SVM modelinde doğruluk oranı %79'dan %75'e düşmüştür. Bununla birlikte, KNN modelinde PCA uygulanmadan ve uygulandıktan sonraki doğruluk oranlarının aynı (%69) kaldığı, ancak özgüllük gibi bazı metriklerde iyileşme görüldüğü gözlemlenmiştir. PCA, bazı modellerde işlem maliyetlerini azaltırken doğruluk oranında bir miktar ödün verilmesi gerektiğini ortaya koymaktadır. Model seçimi ve PCA kullanımı, uygulama gereksinimlerine göre dikkatle değerlendirilmelidir.

TABLE VIII: Performans Karşılaştırması: Makine Öğrenmesi

Model	LDA Durumu	Doğruluk	Kesinlik	Duyarlılık	Özgüllük	F1-Skor	AUC-ROC
Önerilen Model	LDA Off	0.78	0.78	0.78	0.89	0.78	0.92
Önerilen Model	LDA On	0.74	0.74	0.74	0.87	0.73	0.90
Ekstra Ağacı	LDA Off	0.75	0.75	0.75	0.87	0.72	0.91
Ekstra Ağacı	LDA On	0.75	0.74	0.75	0.87	0.72	0.90
Rastgele Orman	LDA Off	0.78	0.77	0.78	0.89	0.77	0.93
Rastgele Orman	LDA On	0.74	0.73	0.74	0.86	0.72	0.90
XGBoost	LDA Off	0.77	0.77	0.77	0.89	0.76	0.93
XGBoost	LDA On	0.75	0.74	0.75	0.87	0.73	0.90
KNN	LDA Off	0.69	0.69	0.69	0.70	0.67	0.86
KNN	LDA On	0.75	0.75	0.75	0.87	0.74	0.89
SVM	LDA Off	0.79	0.79	0.79	0.90	0.78	0.93
SVM	LDA On	0.75	0.75	0.75	0.89	0.74	0.89

TABLE IX: Performans Karşılaştırması: Derin Öğrenme

Model	LDA Durumu	Doğruluk	Kesinlik	Duyarlılık	Özgüllük	F1-Skor	AUC-ROC
Önerilen Model	LDA Off	0.78	0.78	0.78	0.89	0.78	0.92
Önerilen Model	LDA On	0.74	0.74	0.74	0.87	0.73	0.90
LSTM	LDA Off	0.77	0.79	0.77	0.89	0.75	0.91
LSTM	LDA On	0.73	0.74	0.73	0.70	0.87	0.89
BiLSTM	LDA Off	0.71	0.73	0.71	0.88	0.68	0.89
BiLSTM	LDA On	0.74	0.74	0.74	0.72	0.88	0.90
RNN	LDA Off	0.75	0.77	0.75	0.89	0.74	0.91
RNN	LDA On	0.72	0.72	0.72	0.70	0.87	0.89
GRU	LDA Off	0.71	0.71	0.71	0.88	0.69	0.87
GRU	LDA On	0.75	0.75	0.75	0.83	0.73	0.90
CNN	LDA Off	0.67	0.68	0.67	0.84	0.65	0.82
CNN	LDA On	0.71	0.71	0.71	0.69	0.86	0.87

Model Performansına LDA Etkisi: Veri setine uygulanan diğer öznitelik çıkarım yöntemi olan LDA, 40 sütunlu veriyi yalnızca 2 sütuna indirerek daha radikal bir boyut indirgeme işlemi gerçekleştirmiştir. Bu durum, doğruluk oranlarında bazı modellerde belirgin düşüşler yaratmış olsa da, özellikle KNN gibi modellerde doğruluk oranının %69'dan %75'e çıkışmasını sağlamıştır. Önerilen hibrit modelde LDA uygulanmadan önce doğruluk oranı %78 olarak ölçülmüş, LDA uygulandığında bu oran %74'e düşmüştür.

Derin öğrenme modellerinde, LDA'nın etkisi daha karmaşık bir tablo sunmaktadır. LSTM modeli için LDA uygulanmadan doğruluk oranı %77 olarak ölçülmüş, LDA uygulandığında bu oran %74'e düşmüştür. BiLSTM modeli ise doğruluk oranından küçük bir düşüş (%71'den %70'e) yaşamış, ancak genellemeye kapasitesini büyük ölçüde korumuştur. CNN modeli ise doğruluk oranı LDA uygulanmadan %67 iken, LDA uygulandığında %55'e gerilemiştir. Bu durum, LDA'nın bazı modellerde bilgi kaybına yol açabileceğini, ancak diğer metriklerde dengeli bir performans sağlayabileceğini göstermektedir.

Sonuç olarak, LDA'nın etkisi modele göre değişiklik göstermektedir. Bazı modellerde doğruluk oranını artırmış, bazı modellerde ise düşüse yol açmıştır. Boyut indirgeme tekniklerinin etkisi, model performansını optimize etmek ve işlem maliyetlerini düşürmek arasında bir denge kurmak için dikkatle değerlendirilmelidir.

Karşılaştırma: Çalışmada, önerilen model olan Extra Tree ve LSTM hibrit modeli, farklı makine öğrenimi ve derin öğrenme algoritmalarıyla karşılaştırılmıştır. Bu karşılaştırmada, doğruluk, duyarlılık, özgüllük, kesinlik, F1 skoru ve AUC-ROC gibi performans metrikleri değerlendirilmiştir. Kullanılan algoritmaların her biri, veri kümelerinin özelliklerine göre analiz edilmiş ve uygunluk durumları detaylıca incelenmiştir. Ayrıca, önerilen modelin yüksek performans sağlama potansiyeli, diğer modellerle karşılaştırıldığında avantajları ile açıklanmıştır.

Aşağıdaki bar grafiklerinde, her bir algoritmanın performans değerleri gösterilmekte ve metrikler karşılaştırılmaktadır.

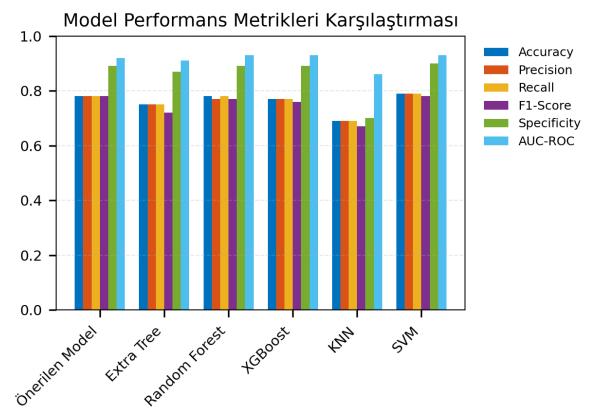


Fig. 2: Model Performans Metrikleri Karşılaştırması: Orijinal (Makine Öğrenmesi)

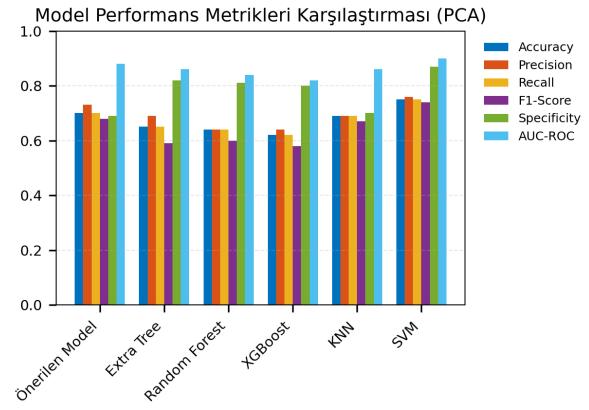


Fig. 3: Model Performans Metrikleri Karşılaştırması: PCA (Makine Öğrenmesi)

Önerilen Model: Önerilen model, doğruluk, duyarlılık, özgüllük gibi metrikler açısından dikkat çekici sonuçlar sunmuştur. PCA uygulanmadığında, model doğruluk oranı %78, duyarlılık oranı %78 ve özgüllük oranı %89 ile yüksek bir performans sergilemiştir. Bu sonuçlar, modelin hem pozitif hem de negatif sınıfları başarıyla ayırt edebildiğini göstermektedir. Ancak PCA uygulandığında, doğruluk oranı %70'e, duyarlılık %70'e ve özgüllük %69'a gerilemiştir. Bu durum, PCA'nın boyut indirgeme

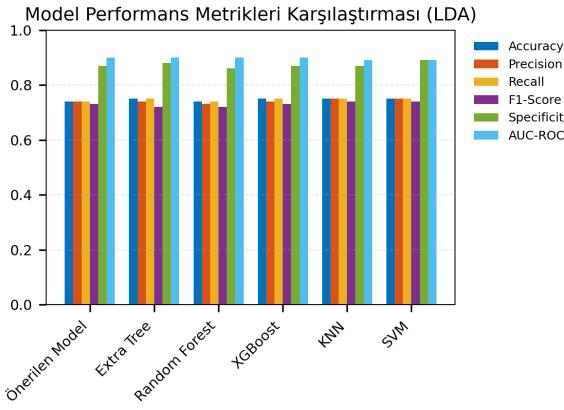


Fig. 4: Model Performans Metrikleri Karşılaştırması: LDA (Makine Öğrenmesi)

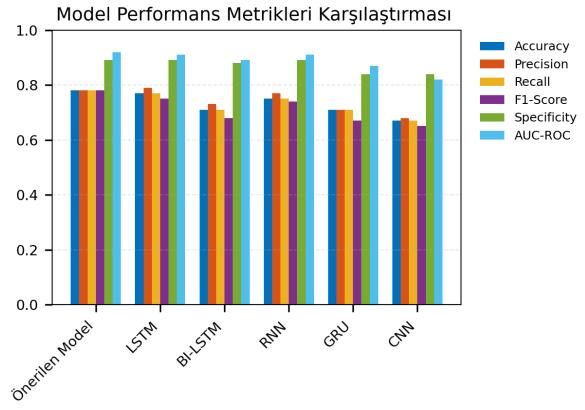


Fig. 7: Model Performans Metrikleri Karşılaştırması: Orijinal (Derin Öğrenme)

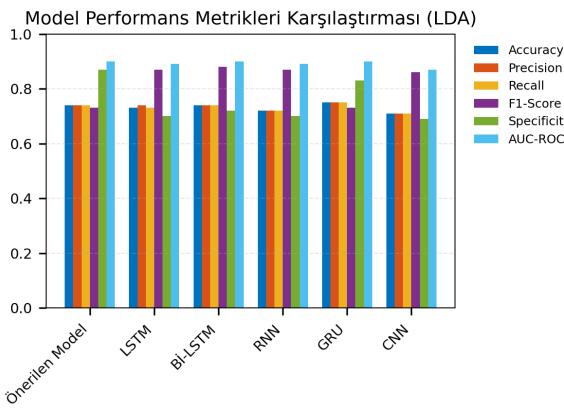


Fig. 5: Model Performans Metrikleri Karşılaştırması: LDA (Derin Öğrenme)

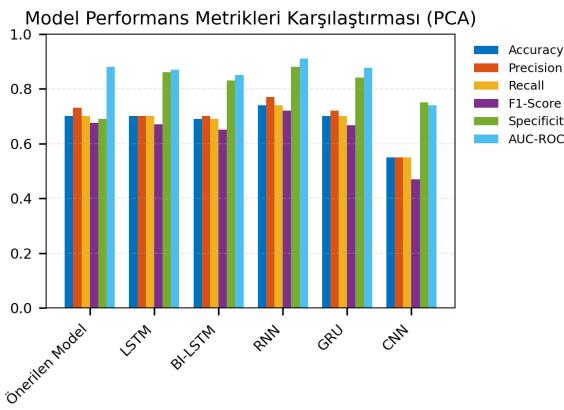


Fig. 6: Model Performans Metrikleri Karşılaştırması: PCA (Derin Öğrenme)

sırasında modelin bilgi kaybına uğramasına neden olduğunu işaret etmektedir. LDA uygulandığında, doğruluk oranı %74, duyarlılık oranı %74 ve özgüllük oranı %87 seviyesine gerilemiştir. Buna rağmen, LDA'nın eğitim süresini kısaltma avantajı, bu tür durumlarda dikkate değer bir fayda sağlamıştır.

Makine Öğrenme Modelleri: SVM algoritması, orijinal veri ile %79 doğruluk ve %90 özgüllük sağlayarak oldukça etkileyici bir performans sergiledi. Bu durum, SVM'nin yüksek boyutlu

verilerle iyi çalıştığını gösteriyor. Ancak, PCA gibi boyut indirgeme yöntemleri uygulandığında doğruluk oranı %75'e düştü. LDA kullanımı sonrası bu düşüş kısmen toparlanarak doğruluk oranı %75 seviyelerinde sabit kaldı. Yine de özgüllük ve AUC-ROC gibi kritik metriklerde önemli kayıplar yaşanmadı. Bu durum, SVM'nin özellikle dengeli veri setlerinde ve sınıflandırma problemlerinde güçlü bir seçenek olduğunu gösteriyor.

Rastgele Orman algoritması %78 doğruluk ve %89 özgüllükle güçlü bir performans gösterdi. Ancak, PCA uygulandığında doğruluk %64'e gerileyerek ciddi bir düşüş yaşadı. Bu sonuç, boyut indirgeme tekniklerinin Rastgele Orman üzerinde daha belirgin bir etkisi olduğunu ortaya koyuyor. LDA kullanımı ise doğruluğu %74'e kadar iyileştirerek daha stabil bir performans sağladı. Benzer şekilde, Ekstra Ağaç algoritması da LDA karşısında dayanıklı kalmayı başardı ve doğruluk oranında kayda değer bir düşüş yaşanmadı. Bu algoritmaların büyük veri setlerinde iyi performans sergilediği, ancak boyut indirgeme işlemlerine karşı daha hassas olabileceği gözlemlendi.

KNN algoritması, orijinal veri ile %69 doğruluk ve %70 özgüllük sağlayarak diğer modellere kıyasla daha düşük bir performans sergiledi. PCA uygulandığında ise doğruluk oranında herhangi bir değişiklik gözlenmedi (%69). Ancak, özgüllük oranında belirgin bir artış (%85) gözlemlendi. LDA kullanıldığında KNN doğruluk oranı %75'e yükselmiş ve daha dengeli bir performans sağlamıştır. Bu sonuç, KNN'nin boyut indirgeme tekniklerine olumlu tepki verdiği ve genellemeye kapasitesini artırabileceğini göstermektedir.

XGBoost algoritması, makine öğrenmesi modelleri arasında öne çıkan bir performans sergileyerek %77 doğruluk ve %89 özgüllük değerlerine ulaşmıştır. PCA uygulandığında doğruluk %62'ye, özgüllük ise %80'e gerilemiştir. LDA'nın kullanılması ise doğruluğu %75'e yükselterek PCA'ya kıyasla daha iyi bir denge sağlamıştır. XGBoost'un yüksek genellemeye kapasitesine sahip olması ve LDA gibi boyut indirgeme yöntemlerine uyum sağlayabilmesi, bu modeli özellikle karmaşık veri setleri için uygun bir seçenek haline getirmektedir.

Derin Öğrenme Modelleri: LSTM modeli, PCA kullanılmadan oldukça başarılı bir performans sergilemiştir. Doğruluk (%77.04), kesinlik (%79.46) ve AUC-ROC (%91.24) gibi metrikler, modelin veri setindeki tüm sınıflara iyi uyum sağladığını göstermektedir. Eğitim süresi de oldukça kısa (11.03 saniye) ve eğitim ile doğrulama kaybı değerleri düşük bulunmuştur. Ancak, PCA kullanıldığında performansta bir düşüş gözlemlenmiştir

(doğruluk: %70.91, AUC-ROC: %87.02). Bu sonuçlar, PCA'nın LSTM'in başarısını olumsuz etkileyebileceğini ortaya koymaktadır.

Bi-LSTM modeli, PCA'sız durumda güçlü bir performans göstermiştir. Özellikle özgüllük (%88.00) ve AUC-ROC (%89.61) gibi metriklerde dikkat çekici bir başarı sağlanmıştır. Ancak doğruluk (%71.29), LSTM'ye göre biraz daha düşük kalmıştır. PCA ile doğruluk ve F1-skorunda düşüş yaşanmış (doğruluk: %69.01, F1-skor: %65.54), ancak genel performans hala tatmin edicidir. Eğitim süresi biraz daha uzun olmuştu, bu durum modelin daha karmaşık yapısına bağlanabilir.

RNN modeli, PCA kullanılmadan dengeli bir performans sergilemiştir. AUC-ROC (%91.73) ile öne çıkmış, doğruluk (%75.97) ve özgüllük (%89.39) gibi metriklerle her iki sınıfı da iyi ayırt edebildiği gözlemlenmiştir. PCA kullanıldığında metriklerde hafif bir düşüş yaşanmış (doğruluk: %74.62, F1-skor: %72.52), ancak genel performans hala iyi seviyededir.

GRU modeli, PCA kullanılmadan stabil bir performans göstermiştir. Doğruluk (%71.21), kesinlik (%71.33) ve AUC-ROC (%87.34) gibi metrikler, modelin zaman serisi verilerine yeterince uyum sağladığını göstermektedir. PCA uygulandığında doğruluk oranı (%70.15) seviyelerine düşmüş olsa da, AUC-ROC (%88.27) gibi kritik metriklerde olumlu sonuçlar korunmuştur. Bu durum, GRU'nun boyut indirgeme tekniklerine kısmen dayanıklı olduğunu göstermektedir.

CNN modeli, diğer modellere kıyasla PCA'sız durumda daha düşük bir performans sergilemiştir. Doğruluk (%68.65), F1-skor (%65.25) ve AUC-ROC (%82.30) değerleri, CNN'in zaman serisi verilerine uyum sağlamakta zorlandığını ortaya koymaktadır. PCA kullanıldığında ise modelin performansı belirgin bir şekilde düşmüştür (doğruluk: %55.21, F1-skor: %47.10, AUC-ROC: %74.17). Bu da PCA'nın CNN yapısıyla uyumsuz olduğunu göstermektedir.

Sonuç olarak, SVM ve önerilen model, hem makine hem de derin öğrenme algoritmalarına kıyasla genel olarak yüksek performans göstermiştir. LDA, birçok algoritma için PCA'ya göre daha stabil sonuçlar sunmuş ve boyut indirgeme işlemlerine olan duyarlılığı azaltmıştır. Derin öğrenme algoritmaları özellikle LSTM ve GRU, büyük ve karmaşık veri setlerinde etkili bir seçenek olmaya devam etmektedir.

Hata Analizi: Hata analizi, bir modelin güçlü ve zayıf yönlerini belirlemek ve geliştirme sürecinde iyileştirme yapılabilecek noktaları tespit etmek için kritik bir adımdır. Yanlış sınıflandırmaların (False Positive ve False Negative) incelenmesi, modelin genel performansını anlamak ve aşırı öğrenme (overfitting) veya eksik öğrenme (underfitting) gibi problemleri belirlemek açısından önemlidir. Örneğin, sınıflandırma modellerinde yanlış pozitiflerin fazla olması, sistemin gereksiz uyarılar üretmesine neden olabilirken, yanlış negatifler kritik bilgilerin kaçırılmasına yol açabilir. Bu nedenle, karmaşılık matrisi kullanılarak her bir modelin hata analizi yapılmalı ve bu analizler, modelin veri kümesine uygunluğunu değerlendirmenin yanı sıra, iyileştirme stratejileri geliştirmek için kullanılmalıdır. Ayrıca, önerilen modelin diğer algoritmalarla kıyasla başarısını ispatlamak için hata analizi detaylı bir şekilde ele alınmalıdır. Aşağıda ortalama karmaşılık matrisleri verilmiştir.

Extra Trees: Extra Tree modelinde özellikle "Tut" sınıfında yanlış negatif (FN) oranı oldukça yüksektir. Bu durum, modelin "Tut" sınıfındaki verileri doğru şekilde sınıflandırmakta zorlandığını göstermektedir. Bununla birlikte, "Sat" ve "Al" sınıflarında yüksek doğru sınıflandırma oranlarına sahiptir. Bu sonuçlar, modelin genel performansının iyi olduğunu ancak

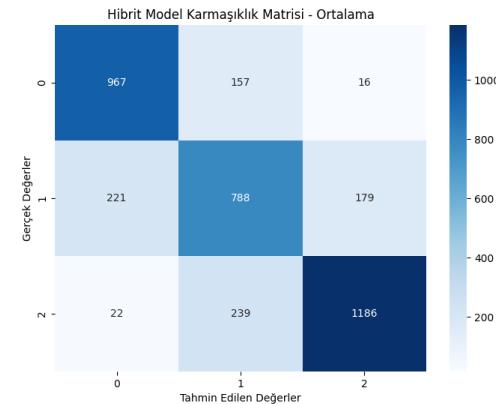


Fig. 8: Önerilen Model

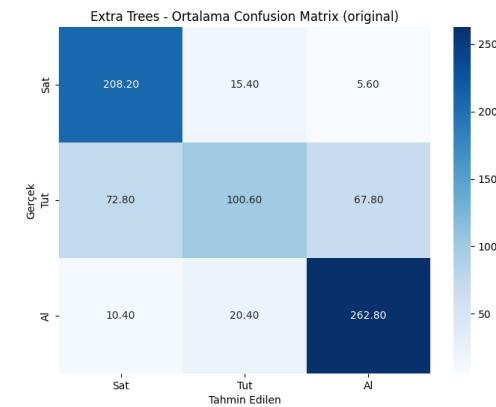


Fig. 9: Extra Tree

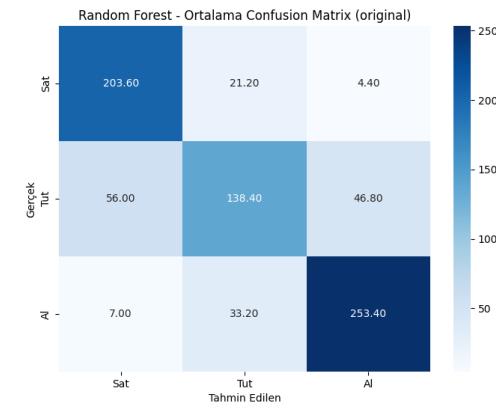


Fig. 10: Random Forest

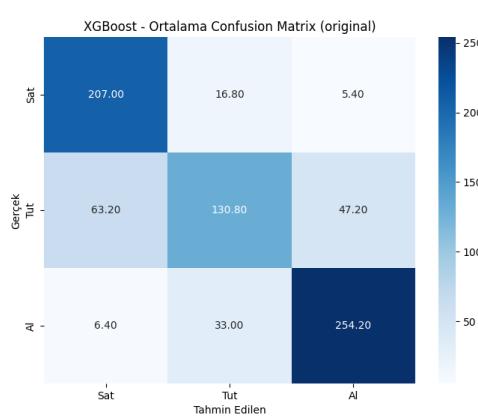


Fig. 11: XGBoost

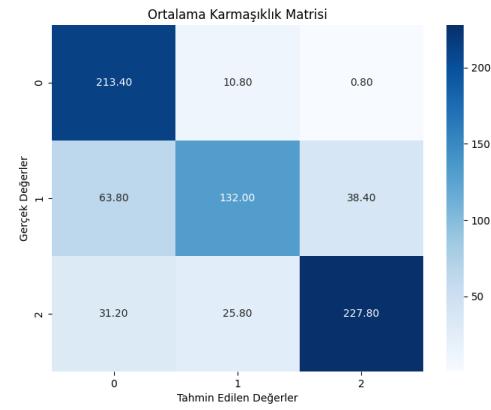


Fig. 14: LSTM

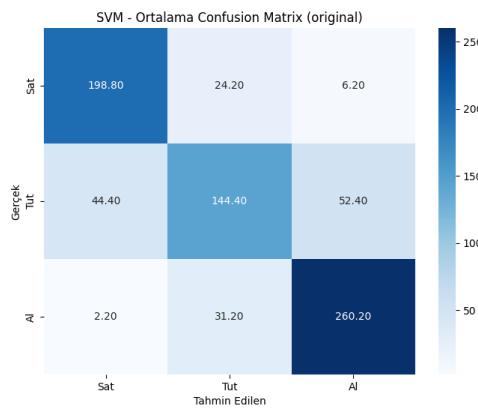


Fig. 12: SVM

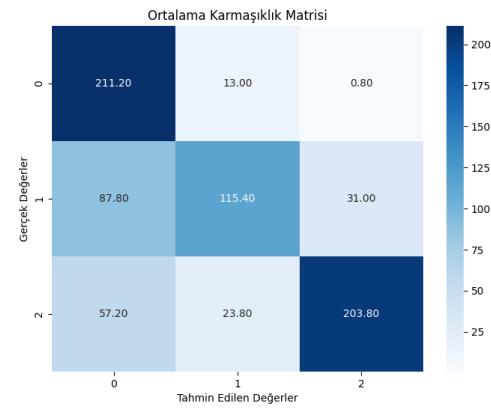


Fig. 15: Bi-LSTM

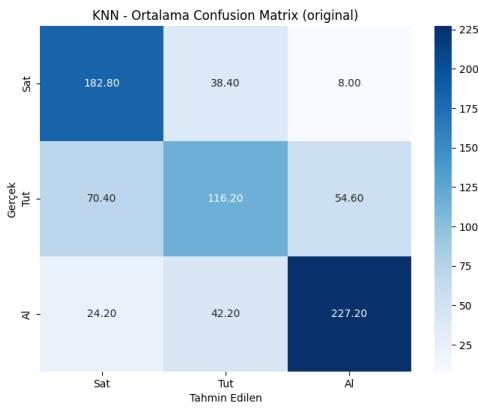


Fig. 13: KNN

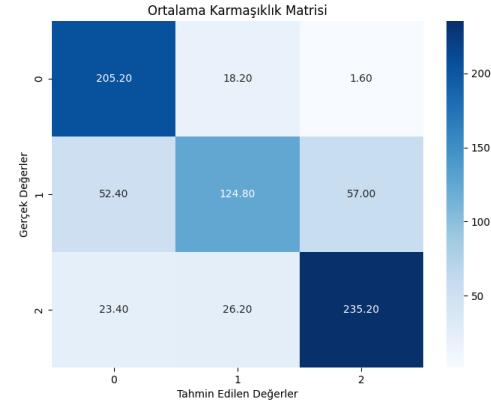


Fig. 16: RNN

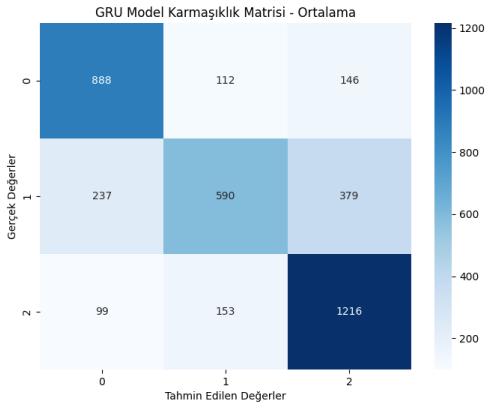


Fig. 17: GRU

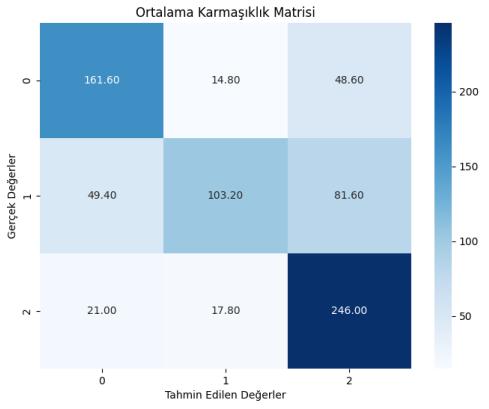


Fig. 18: CNN

özellikle "Tut" sınıfında iyileştirmeye ihtiyaç duyulduğunu gösteriyor.

Random Forest: Random Forest modeli, "Sat" ve "Al" sınıflarında yüksek doğru sınıflandırma oranları ile dikkat çekmektedir. Ancak, "Tut" sınıfında gözlemlenen yüksek yanlış pozitif (FP) oranı, modelin bu sınıfı kesinlik (precision) performansını düşürdüğünü ortaya koymaktadır. Modelin genel doğruluğu tatmin edici olsa da, "Tut" sınıfında daha iyi bir ayrim yeteneği geliştirilmelidir.

XGBoost: XGBoost modeli, "Sat" ve "Al" sınıflarında oldukça güçlü bir doğruluk ve duyarlılık sergilemiştir. Bununla birlikte, "Tut" sınıfında yüksek yanlış pozitif oranı dikkat çekmektedir. Bu durum, modelin veri setindeki belirli sınıflar arasındaki ayrim tam olarak öğrenemediğini göstermektedir. Ancak genel olarak XGBoost, çok dengeli bir performans sunmaktadır.

SVM: SVM modeli, özellikle "Al" sınıfında yüksek doğruluk ve kesinlik oranlarıyla dikkat çekmektedir. Ancak "Tut" sınıfındaki yanlış negatif (FN) oranı yüksek olduğu için duyarlılık (recall) metriği düşmüştür. Bu durum, modelin "Tut" sınıfındaki örnekleri kaçırma oranının fazla olduğunu göstermektedir. Genel olarak SVM, doğru sınıflandırma oranları açısından dengeli bir modeldir.

KNN: KNN modelinde, özellikle "Tut" sınıfında gözlemlenen yüksek yanlış pozitif oranı (FP), kesinlik (precision) metriğini olumsuz etkilemiştir. Bununla birlikte, duyarlılık (recall) metriği açısından daha dengeli bir performans sergilemiştir. KNN mod-

elinin sınıf ayrımda performansını artırmak için k değerinin optimize edilmesi faydalı olacaktır.

LSTM: LSTM modeli, zaman serisi verileri üzerinde etkili bir performans sergilemiştir. PCA uygulanmadan önce karmaşıklık matrisine göre, özellikle 0 ("Sat") ve 2 ("Al") sınıflarında yüksek başarı göstermiştir. Ancak, 1 ("Tut") sınıfında yanlış sınıflandırmaların artması modelin duyarlılık metriğini olumsuz etkilemiştir. PCA uygulandığında, modelin doğruluk oranı %70.91'e gelmiştir. Bununla birlikte, PCA'lı modelde 1 ("Tut") sınıfında yanlış pozitiflerin artması ve 0 ("Sat") sınıfında doğru tahmin sayısının azalması dikkat çekmektedir. Bu durum, PCA'nın veri boyutunu azaltırken bazı önemli özelliklerin kaybedilmesine neden olmuş olabilir. Her iki durumda da, LSTM modelinin özellikle 1 ("Tut") sınıfındaki performansının iyileştirilmesi gerekmektedir. Model, üç sınıflarda (0 ve 2) başarılı sonuçlar verse de, orta sınıfta (1) genelleme problemi yaşamaktadır.

Bi-LSTM: PCA uygulanmadan elde edilen sonuçlara göre, modelin doğruluk oranı %71.29 olarak kaydedilmiştir. Ancak, bazı sınıflarda yüksek yanlış negatif oranı nedeniyle duyarlılık metriğinde düşüş gözlemlenmiştir. Bu durum, modelin belirli sınıflarda genelleme yapma yeteneğinin sınırlı olduğunu göstermektedir. PCA uygulandığında, modelin doğruluk oranı %69.01'e düşmüştür. Bu düşüş, PCA'nın veri boyutunu azaltarak modelin bazı önemli özelliklerini kaybetmesine neden olabileceğini düşündürmektedir. Ayrıca, PCA'lı modelde yanlış pozitif oranlarının arttığı gözlemlenmiştir, bu da kesinlik metriğinin olumsuz etkilenmesine yol açmıştır.

RNN: RNN modeli, karmaşıklık matrislerine bakıldığından, özellikle uzun bağımlılıklı verilerde zayıf bir performans sergilemiştir. PCA uygulanmadan elde edilen sonuçlara göre, modelin doğruluk oranı %75.97 olarak kaydedilmiştir. Ancak, yanlış negatif oranlarının yüksek olduğu sınıflarda duyarlılık metriği düşüş göstermiştir. Bu durum, modelin belirli sınıflarda genelleme yapma yeteneğinin sınırlı olduğunu göstermektedir. PCA uygulandığında ise, modelin doğruluk oranı %74.62'ye düşmüştür. Bu düşüş, PCA'nın veri boyutunu azaltarak modelin bazı önemli özelliklerini kaybetmesine neden olmuş olabilir. Bununla birlikte, PCA'lı modelde yanlış pozitif oranlarının arttığı gözlemlenmiştir, bu da kesinlik metriğinin olumsuz etkilenmesine yol açmıştır.

GRU: GRU modeli, daha hafif bir yapı sunmasına rağmen, özellikle 2 ("Al") sınıfında güçlü bir performans sergilemiştir. Şekil incelediğinde, 1,216 adet doğru sınıflandırma ile 2 ("Al") sınıfında yüksek bir doğruluk oranına sahiptir. Bununla birlikte, 1 ("Tut") sınıfında 379 yanlış pozitif (FP) gözlemlenmiş, bu da kesinlik (precision) oranını olumsuz etkilemiştir.

Modelin 0 ("Sat") sınıfındaki başarısı da dikkate değerdir; 888 doğru tahmin yaparken, 112 örnek yanlışlıkla 1 ("Tut") sınıfına ve 146 örnek 2 ("Al") sınıfına atanmıştır. 1 ("Tut") sınıfındaki duyarlılık (recall) metriği, 590 doğru tahmin ile nispeten düşük kalmış olup, modelin bu sınıfı genelleme yapmakta zorlandığını göstermektedir. Genel olarak GRU modeli, sekans verilerinde başarılı bir yapı sunsa da, 1 ("Tut") sınıfındaki dengesizlik performansını sınırlamıştır.

CNN: PCA uygulanmadan elde edilen sonuçlara göre, modelin doğruluk oranı %68.66 olarak kaydedilmiştir. Ancak, özellikle bazı sınıflarda yüksek yanlış negatif oranı nedeniyle modelin genelleme yeteneği sınırlı kalmıştır. Bu durum, modelin belirli sınıflarda daha fazla iyileştirmeye ihtiyaç duyduğunu gösterir. PCA uygulandığında, modelin doğruluk oranı %55.22'ye düşmüştür. Bu düşüş, PCA'nın veri boyutunu azaltarak modelin bazı önemli

özellikleri kaybetmesine neden olmuş olabilir. Ayrıca, PCA'lı modelde yanlış pozitif oranlarının arttığı gözlemlenmiştir, bu da kesinlik metriğinin olumsuz etkilenmesine yol açmıştır.

Önerilen Model (Extra Tree + LSTM): Önerilen model, karmaşıklık matrisine göre sınıflandırma başarısını önemli ölçüde artırmıştır. Özellikle "Sat" (0) ve "Al" (2) sınıflarında yüksek doğruluk sağlamıştır. Model, "Sat" sınıfında 967 doğru tahmin yaparken, yalnızca 173 örnegi yanlış sınıflandırmıştır. Benzer şekilde, "Al" sınıfında 1186 doğru tahmin yapmış, sadece 261 örnegi yanlış tahmin etmiştir.

Ancak "Tut" (1) sınıfında modelin performansı diğer sınıflara göre daha düşük kalmıştır. Model 788 örnegi doğru sınıflandırırken, 400 yanlış tahmin etmiştir. Bu durum, modelin orta sınıfı (1 - "Tut") diğer sınıflara göre daha az ayırt edebildiğini ve genellemeye problemi yaşadığını göstermektedir. Genel olarak, modelin yanlış pozitif ve yanlış negatif oranları "Sat" ve "Al" sınıflarında düşük olup, modelin yüksek duyarlılık ve özgürlüğe sahip olduğunu göstermektedir. Ancak, "Tut" sınıfında yanlış sınıflandırmaların azaltılması için model optimizasyonuna ihtiyaç duyulmaktadır.

B. Eğitim ve Test Peformansının Değerlendirilmesi

Derin öğrenme modellerinin performansını değerlendirdirken, sadece genel doğruluk oranlarına bakmak yaniltıcı olabilir. Modelin gerçek dünya verilerinde nasıl performans göstereceğini anlamak için, eğitim ve test süreçlerindeki davranışını detaylı olarak incelemek kritik önem taşır. Bu karşılaşturma, modelimizin öğrenme kalitesini, genellemeye yeteneğini ve olası problemlerini anlamamızı yardımcı olur. Özellikle aşırı öğrenme (overfitting) veya yetersiz öğrenme (underfitting) gibi yaygın sorunları tespit etmemizi sağlar. Eğitim sürecinde elde edilen yüksek başarı oranları, her zaman modelin gerçek performansını yansıtmayabilir. Bu nedenle, eğitim ve test sonuçları arasındaki ilişkiye analiz etmek, modelimizin pratik uygulamalardaki başarısını öngörmemize ve gerekli iyileştirmeleri yapmamıza olanak tanır. Bu bölümde, modellerimizin eğitim ve test performanslarını karşılaştıracak ve inceleyeceğiz.

Eğitim ve Test Doğruluğu Karşılaştırması:

- Önerilen Model:** Figür 19'de görüldüğü üzere, önerilen model yaklaşık 20 epoch boyunca eğitilmiş ve eğitim doğruluğu %80 seviyelerine ulaşmıştır. Doğrulama doğruluğu ise %78-80 bandında sabit kalmıştır. Eğitim sürecinin ilk birkaç epochunda hızlı bir öğrenme gerçekleşmiş, 5. epoch'tan sonra doğruluk eğrileri dengelenmeye başlamıştır. 10. epoch'tan itibaren eğitim ve doğrulama eğrileri arasındaki fark minimal seviyeye inmiş ve model aşırı öğrenme (overfitting) belirtileri göstermemiştir. Bu sonuçlar, önerilen modelin dengeli bir öğrenme süreci geçirdiğini ve genellemeye performansının güçlü olduğunu göstermektedir. Özellikle erken epoch'larda hızlı bir öğrenme eğilimi gösteren model, ilerleyen epoch'larda doğrulama eğrisi ile eğitim eğrisini paralel şekilde sürdürerek istikrarlı bir yapı sergilemiştir.
- LSTM:** Figür 22'de görüldüğü üzere, model yaklaşık 45 epoch boyunca eğitildi ve eğitim doğruluğu %92 seviyelerine ulaştı. Doğrulama doğruluğu ise %85-90 bandında seyretti. Eğitim ve doğrulama eğrileri arasındaki makul fark, modelin kabul edilebilir düzeyde genellemeye yaptığı ve aşırı öğrenme belirtilerinin minimal düzeyde olduğunu gösteriyor.
- Bi-LSTM:** Figür 25, PCA uygulanmamış BiLSTM modeli yaklaşık 50 epoch boyunca eğitildi. Eğitim doğruluğu kademeli olarak artarak %85-87 seviyelerine ulaştı. Doğrulama doğruluğu %80-85 bandında seyretti. PCA'sız

model daha dengeli bir öğrenme eğrisi gösterdi ve eğitim-doğrulama performansları arasında daha az fark oluştu.

- RNN:** Figür 28, RNN modeli 40 epoch boyunca eğitildi ve eğitim doğruluğu %90 seviyelerine ulaştı. Doğrulama doğruluğu %80-85 bandında seyretti. İlk 10 epoch'ta hızlı bir öğrenme gerçekleşti. Son epochlarda eğitim-doğrulama arasındaki makas açılmaya başladı.
- GRU:** Figür 31, GRU modeli yaklaşık 20 epoch boyunca eğitildi. Eğitim doğruluğu hızlı bir şekilde artarak %85 seviyelerine ulaştı. Doğrulama doğruluğu ise %80-85 bandında sabit kalmıştır. Eğitim ve doğrulama eğrileri arasındaki fark, özellikle 10. epoch'tan sonra minimal düzeye inmiştir. Bu, GRU modelinin dengeli bir öğrenme süreci gösterdiğini ve aşırı öğrenme belirtilerinin olmadığını işaret etmektedir.
- CNN:** Figür 34, CNN modeli 50 epoch boyunca eğitildi. Eğitim doğruluğu kademeli olarak artarak %90 seviyelerine ulaştı. Doğrulama doğruluğu %85 civarında dengelendi. 30. epoch'tan sonra eğitim ve doğrulama eğrileri arasındaki fark minimal düzeyde kaldı.

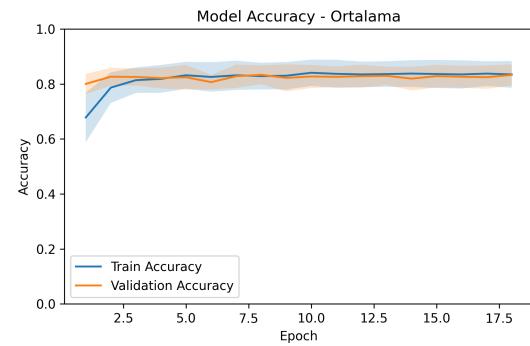


Fig. 19: Önerilen Model: Model Doğruluğu

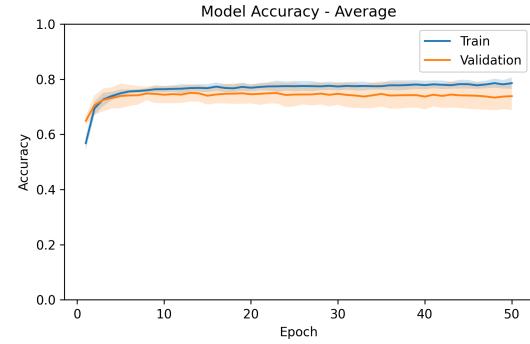


Fig. 20: Önerilen Model PCA: Model Doğruluğu

PCA Kullanımı:

- Önerilen Model:** Figür 20, PCA uygulanmış hibrit modelin öğrenme sürecini göstermektedir. İlk 5 epoch boyunca hızlı bir öğrenme gerçekleştiren model, 10. epoch sonrasında hem eğitim hem de doğrulama doğruluklarında stabil bir eğilim sergilemiştir. Eğitim doğruluğu %85-88 arasında seyretmiş, doğrulama doğruluğu ise %80 civarında kalmıştır. PCA uygulaması, modelin daha hızlı öğrenmesini sağlamış ancak doğrulama doğruluğu açısından belirgin bir iyileşme sunmamıştır. Bu durum, PCA'nın veri boyutunu azaltarak hesaplama maliyetini düşürdüğünü ancak modelin önemli özelliklerini kaybederek genellemeyi tam

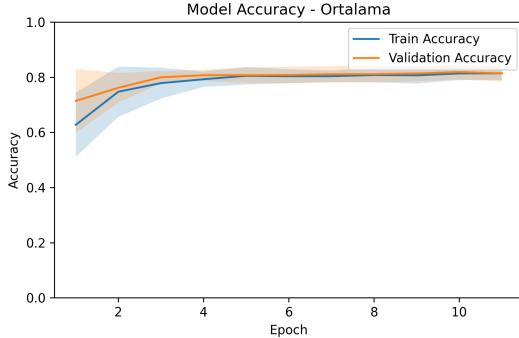


Fig. 21: Önerilen Model LDA: Model Doğruluğu

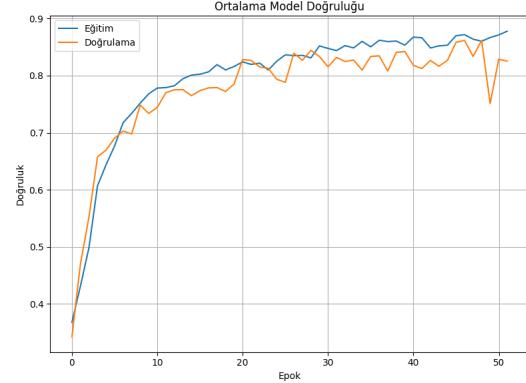


Fig. 25: Bi-LSTM: Model Doğruluğu

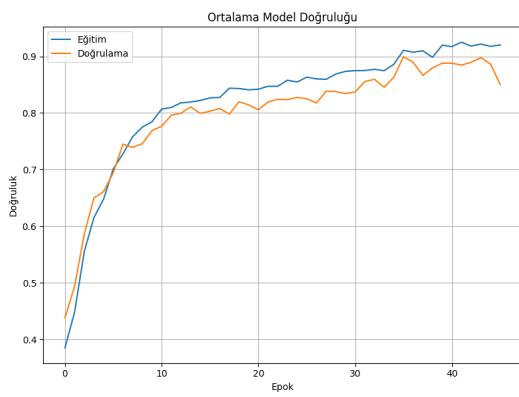


Fig. 22: LSTM: Model Doğruluğu

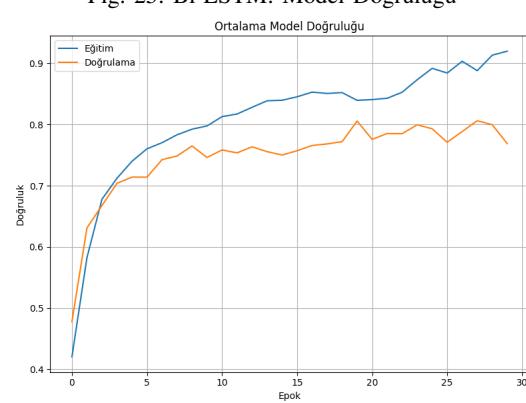


Fig. 26: Bi-LSTM PCA: Model Doğruluğu

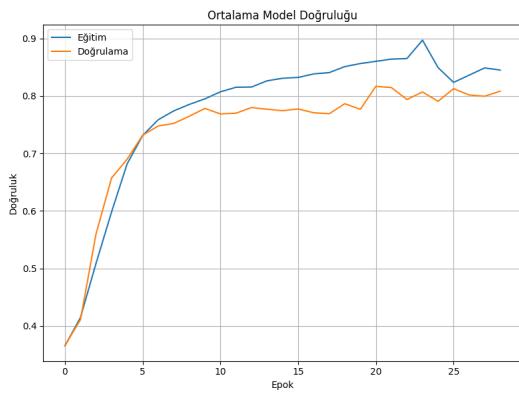


Fig. 23: LSTM PCA: Model Doğruluğu

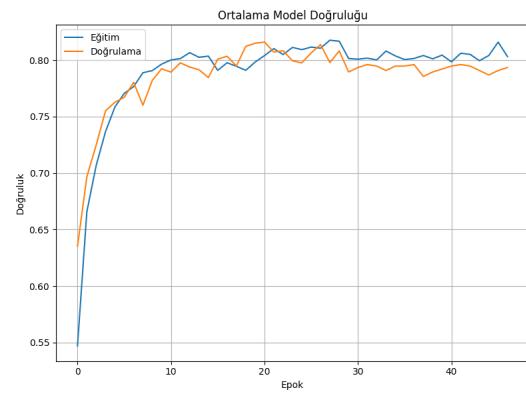


Fig. 27: Bi-LSTM LDA: Model Doğruluğu

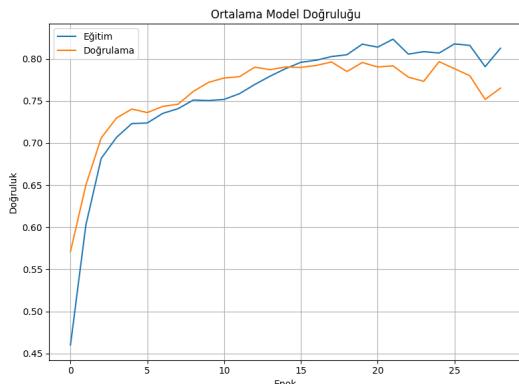


Fig. 24: LSTM LDA: Model Doğruluğu

olarak artmadığını göstermektedir. Eğitim ve doğrulama doğrulukları arasındaki farkın düşük olması, modelin aşırı öğrenme (overfitting) problemi yaşamadığını ve dengeli bir öğrenme sürecine sahip olduğunu göstermektedir. Ancak, doğrulama doğruluğundaki hafif dalgalanmalar, modelin hala belirli veri örneklerinde genelleme problemi yaşayabileceğini işaret etmektedir. Sonuç olarak, önerilen hibrit model, hem doğruluk hem de stabilizasyon açısından başarılı bir performans sergilemiş olup, PCA'nın eğitim süresini kısaltmasıyla birlikte performansını önemli ölçüde koruyabildiği görülmektedir.

- **LSTM:** Figür 23, PCA uygulanmış modelde 25-30 epoch civarında eğitim tamamlandı. Bu modelde eğitim doğruluğu

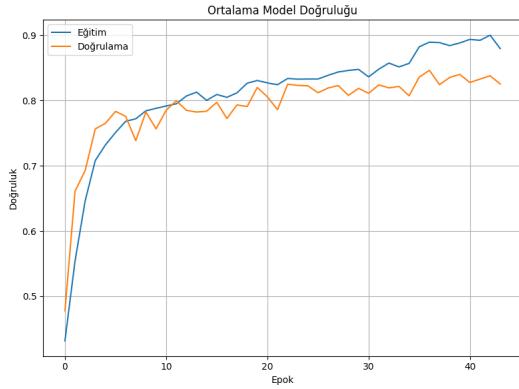


Fig. 28: RNN: Model Doğruluğu

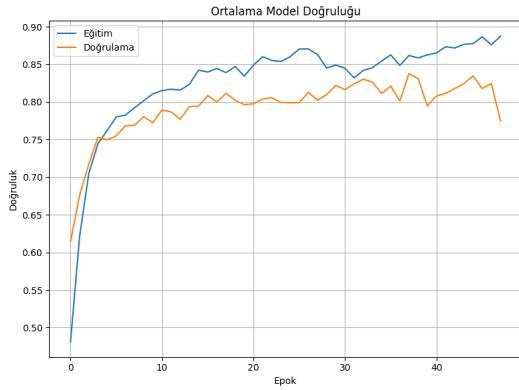


Fig. 29: RNN PCA: Model Doğruluğu

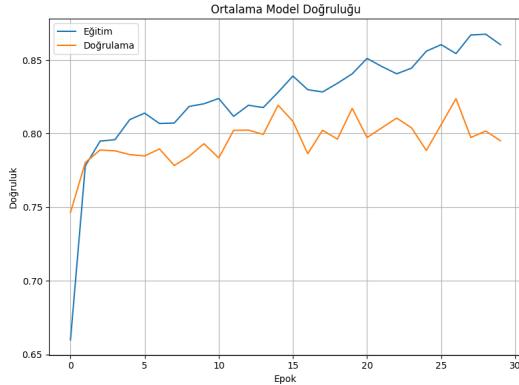


Fig. 30: RNN LDA: Model Doğruluğu

%85-90 aralığında seyredenken, doğrulama doğruluğu %80 civarında seyretti. PCA uygulaması eğitim süresini kısalttı ancak model performansında bir miktar düşüş gözlemlendi.

- **Bi-LSTM:** Figür 26, PCA uygulamış model yaklaşık 30 epoch süresince eğitildi. Eğitim doğruluğu %90-92 seviyelerine kadar yükseldi. Doğrulama doğruluğu %75-80 civarında gezdi. Eğitim ve doğrulama eğrileri arasındaki açıklık, hafif bir aşırı öğrenme eğilimine işaret ediyor.
- **RNN:** Figür 29, PCA uygulanan model yaklaşık 45 epoch süresince eğitildi ve eğitim doğruluğu %85-90 aralığında seyretti. Doğrulama doğruluğu %80 civarında seyretti. PCA'lı model daha dengeli bir öğrenme eğrisi gösterdi ve aşırı öğrenme eğilimi daha az belirgin.

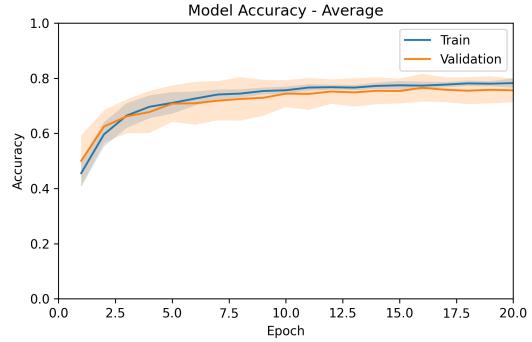


Fig. 31: GRU: Model Doğruluğu

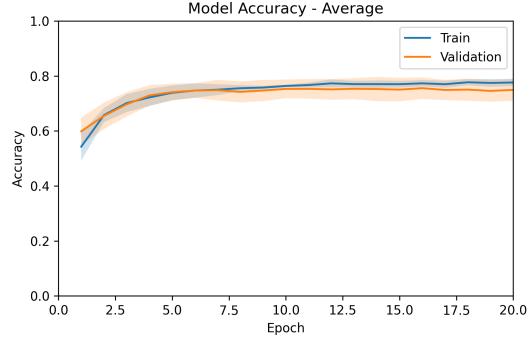


Fig. 32: GRU PCA: Model Doğruluğu

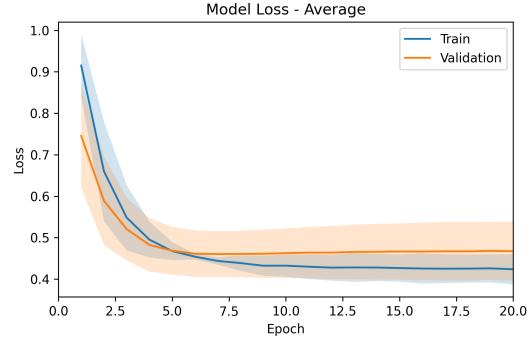


Fig. 33: Gru LDA : Model Doğruluğu

- **GRU:** Figür 32, GRU modeli PCA uygulamasıyla 20 epok boyunca eğitildi ve oldukça dengeli bir öğrenme sergiledi. İlk 5 epokta hızlı bir öğrenme gerçekleştiren model, sonraki epoklarda kademeli bir iyileşme gösterdi ve 10. epoktan sonra her iki eğrinin de stabil bir seviyede dengeye ulaştı. Eğitim ve doğrulama performansları arasındaki minimal fark, modelin aşırı öğrenme problemi yaşamadığını ve iyi bir genellemeye yeteneği kazandığını kanıtlıyor. Bu durum, GRU modelinin PCA ile birlikte kullanıldığında veri setimiz için uygun bir çözüm sunduğunu gösteriyor.
- **CNN:** Figür 35, PCA uygulanan model de 50 epoch boyunca eğitildi. Eğitim doğruluğu %80-85 bandında seyretti. Doğrulama doğruluğu %75-77 civarında gezdi. Öğrenme süreci daha yavaş ve kademeli gerçekleşti. Eğitim ve doğrulama performansları arasında belirgin bir fark oluştı.
- **LDA Kullanımı:**
- **Önerilen Model:** Figür 21, LDA uygulanan hibrit mod-

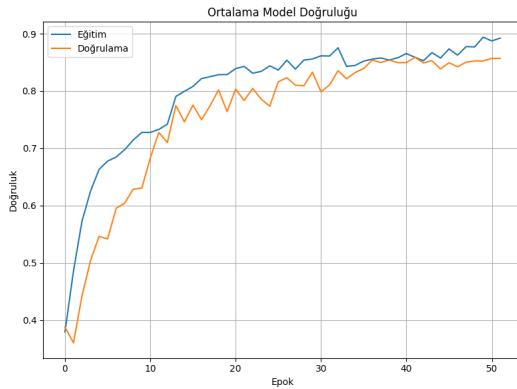


Fig. 34: CNN: Model Doğruluğu

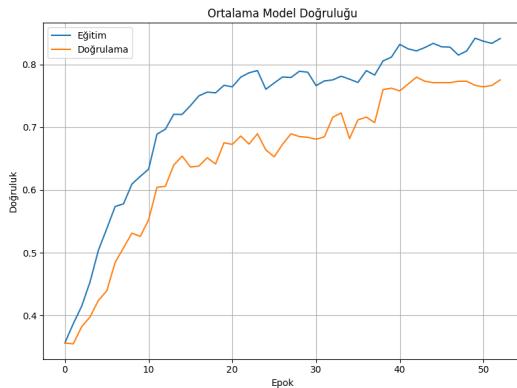


Fig. 35: CNN PCA: Model Doğruluğu

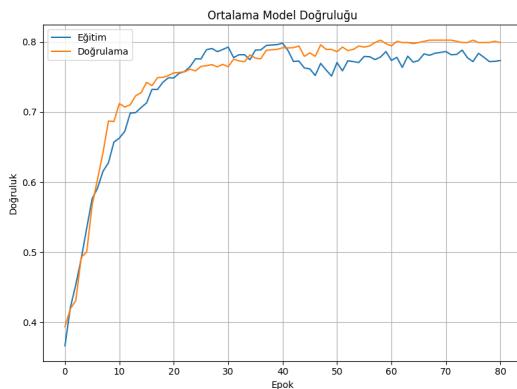


Fig. 36: CNN LDA: Model Doğruluğu

elin eğitim sürecini göstermektedir. LDA uygulaması sonrasında model yaklaşık 10 epoch süresince eğitilmiş olup, eğitim doğruluğu %80-82 bandında seyredenken doğrulama doğruluğu %80 seviyesinde sabitlenmiştir. İlk birkaç epoch boyunca hızlı bir öğrenme gerçekleşmiş, ardından doğruluk değerleri daha stabil bir hale gelmiştir.

LDA uygulanmasıyla modelin öğrenme süresi kısalırken, modelin performansında belirgin bir fark gözlemlenmemiştir. Ancak, eğitim ve doğrulama doğrulukları arasındaki farkın az olması, modelin aşırı öğrenme problemi yaşamadığını ve genel olarak dengeli bir öğrenme gerçekleştirdiğini göstermektedir. LDA'nın etkisiyle modelin hesaplama süresi düşmüştür ve daha kompakt bir özellik kümesiyle çalışması sağlanmıştır. Ancak,

belirli karmaşık ilişkilerin kaybolması nedeniyle, doğruluk açısından PCA ile karşılaştırıldığında küçük bir performans kaybı yaşanmıştır. Genel olarak, LDA'nın uygulanması, modelin eğitim sürecini hızlandırmış ve daha az hesaplama kaynağı gerektirerek verimli bir öğrenme süreci sağlamıştır.

- **LSTM:** Figür 24, LSTM modelimiz LDA uygulamasıyla yaklaşık 30 epok boyunca eğitildi ve oldukça dengeli bir öğrenme eğrisi sergiledi. Eğitim ve doğrulama doğrulukları arasındaki farkın minimal düzeyde kalması (her ikisi de %75-80 bandında), modelin aşırı öğrenme problemi yaşamadığını gösteriyor. Özellikle 15. epoktan sonra her iki eğrinin de birbirine yakın seyretmesi, modelin iyi bir genelleme yeteneği kazandığını işaret ediyor.

- **Bi-LSTM:** Figür 27, BiLSTM modelinde LDA uygulaması ile eğitim ve doğrulama performansları neredeyse örtüsen bir grafik elde edildi. Model 45 epok boyunca eğitildi ve %80 civarında stabil bir doğruluk oranına ulaştı. Eğitim ve doğrulama eğrilerinin bu kadar yakın seyretmesi, modelin veri setini optimal düzeyde öğrendiğini ve aşırı öğrenme problemi yaşamadığını gösteriyor.

- **RNN:** Figür 30, RNN modelinde LDA uygulaması, 30 epok boyunca süren eğitim sürecinde ilginç bir öğrenme dinamigi ortaya koydu. İlk 5 epokta hızlı bir öğrenme gerçekleşti ve sonrasında eğitim doğruluğu %85'e kadar yükselsirken, doğrulama doğruluğu %80 civarında seyretti. Bu makul fark, modelin kabul edilebilir düzeyde bir genelleme yeteneği kazandığını gösteriyor.

- **GRU:** Figür 33, GRU modeli için LDA uygulanmış ve uygulanmamış durumlar kıyaslandığında, modelin farklı öğrenme dinamikleri sergilediği gözlemlenmiştir. Figür 'de gösterildiği gibi, LDA uygulanmayan GRU modeli, 10. epoktan sonra doğruluk açısından %80 seviyesine ulaşarak stabil bir hale gelirken, LDA uygulanmış modelde bu stabilizasyon daha geç gerçekleşmiştir.

LDA uygulandığında, modelin başlangıçtaki öğrenme hızı artmış olsa da, sonrasında doğruluk seviyesinin LDA uygulanmayan modele kıyasla daha düşük olduğu gözlemlenmiştir. Bu durum, LDA'nın özellikle GRU gibi sekans tabanlı modellerde bazı kritik zaman bağımlı bilgileri kaybetmesine neden olabileceğini göstermektedir. Ayrıca, LDA'lı modelde doğrulama doğruluğu ile eğitim doğruluğu arasındaki farkın artması, modelin aşırı öğrenme eğilimine daha yatkın hale geldiğini işaret etmektedir.

- **CNN:** Figür 36, CNN modelinde LDA uygulaması, 80 epok gibi uzun bir eğitim sürecinde dikkat çekici bir performans sergiledi. İlk 30 epokta hızlı bir öğrenme gösterdikten sonra, eğitim ve doğrulama doğrulukları %75-80 bandında stabilize oldu. İlginç bir şekilde, 40. epoktan sonra doğrulama performansının eğitim performansını hafifçe aşması, modelin test verisinde daha iyi genelleme yaptığı gösteriyor.

Aşırı Öğrenme ve Eksik Öğrenme Durumları:

- **LSTM:** Figür 38, LSTM modelinin eğitim ve doğrulama kayıp eğrileri incelendiğinde, başlangıçta hızlı bir öğrenme gösterdiği ve yaklaşık 20. epoch'tan sonra her iki eğrinin de kararlı bir seviyeye ulaştığı görülmektedir. Eğitim ve doğrulama kayipları arasındaki farkın minimal olması, modelin aşırı öğrenme problemi yaşamadığını göstermektedir. Model, 0.4 civarında bir kayıp değeriyle dengeli bir öğrenme gerçekleştirmiştir.

- **Bi-LSTM:** Figür 39, Çift yönlü LSTM modelinde, eğitim ve

doğrulama eğrileri birbirine oldukça yakın seyretmektedir. 30. epoch'tan sonra doğrulama kaybının eğitim kaybından biraz yüksek seyretmesi, hafif bir aşırı öğrenme eğilimi olduğunu gösterse de, bu fark kritik düzeyde değildir. Model genel olarak 0.4-0.5 aralığında kararlı bir performans sergilemiştir.

- **RNN:** Figür 40, RNN modelinde, eğitim ve doğrulama kayipları arasında belirgin bir ayrışma gözlemlenmektedir. 30. epoch'tan sonra eğitim kaybı düşmeye devam ederken doğrulama kaybının yatay seyretmesi, modelin aşırı öğrenme problemi yaşadığını göstermektedir. Bu durum, RNN'in karmaşık yapıları öğrenmede zorlandığına işaret edebilir.
- **GRU:** Figür 41, GRU modelinin performansı, LSTM'e benzer bir karakteristik göstermiştir. Eğitim ve doğrulama kayipları birbirine yakın seyretmiş ve model kararlı bir öğrenme sergilemiştir. Eğitim kaybı, yaklaşık 10. epoch'tan sonra sabit bir düzeye inerek öğrenmenin tamamlandığını işaret ederken, doğrulama kaybında 15. epoch sonrasında hafif dalgalanmalar gözlemlenmiştir. Bu durum, modelin eğitim verisine oldukça iyi uyum sağladığını, ancak doğrulama verisi üzerinde tamanen genelleştirme yapamadığını göstermektedir.
- **CNN:** Figür 42, CNN modelinin kayıp eğrileri, eğitim sürecinin başlarında hızlı bir düşüş göstermiş ve yaklaşık 20. epoch'tan sonra kararlı bir seviyeye ulaşmıştır. Eğitim ve doğrulama kayipları arasındaki minimal fark, modelin dengeli bir öğrenme gerçekleştirdiğini ve aşırı öğrenme problemi yaşamadığını göstermektedir.
- **Önerilen Model:** Figür 37, Önerilen modelin kayıp eğrileri, diğer modellere kıyasla daha düşük bir kayıp değerine ulaşmıştır. Eğitim ve doğrulama kayipları arasındaki uyum, modelin genelleme yeteneğinin iyi olduğunu göstermektedir. Extra Tree'nin LSTM ile kombinasyonu, modelin öğrenme kapasitesini artırmış ve daha dengeli bir performans elde edilmesini sağlamıştır.

Modeller genellikle aşırı öğrenme problemi yaşamamıştır. Özellikle hibrit model ve LSTM tabanlı modeller, veri setindeki örtütüleri başarılı bir şekilde öğrenmiş ve iyi bir genelleme performansı göstermiştir. Eksik öğrenme problemi ise hiçbir modelde gözlemlenmemiştir, bu da model mimarilerinin ve hiperparametrelerin uygun seçildiğini göstermektedir.

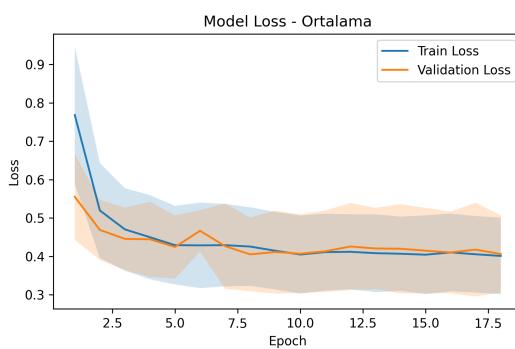


Fig. 37: Önerilen Model: Model Kaybı

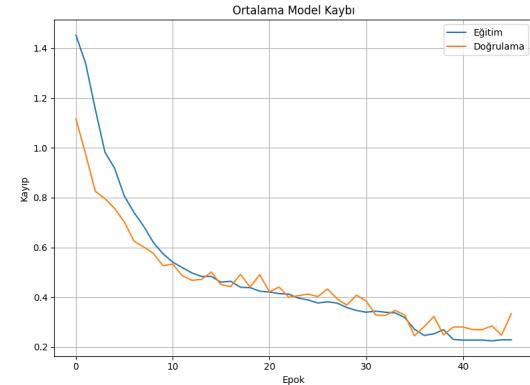


Fig. 38: LSTM: Model Kaybı

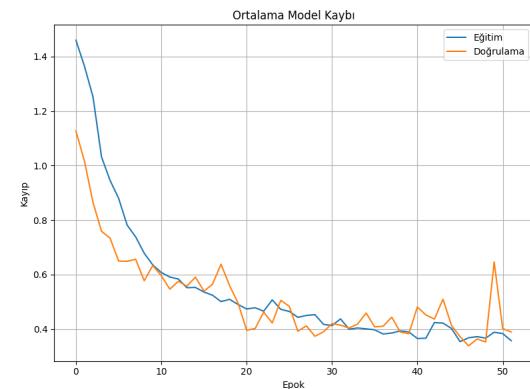


Fig. 39: Bi-LSTM: Model Kaybı

C. Zaman ve Kaynak Kullanımı Değerlendirilmesi

Eğitim ve Test Süresi:

Eğitim ve Test Performansı: PCA Kullanımı: PCA'nın model eğitim ve test süreleri üzerindeki etkisini incelediğimizde, özellikle yüksek boyutlu veri setlerinde eğitim süresini kayda değer şekilde azalttığı gözlemlenmiştir. Hibrit modelde PCA uygulanmadığında eğitim süresi 10,319 saniye, test süresi ise 5 saniye olarak ölçülmüştür. PCA kullanıldığındaysa eğitim süresi 727 saniyeye, test süresi ise 1 saniyeye düşmüştür. Bu durum, özellikle kompleks yapıya sahip modellerde PCA'nın işlem maliyetlerini ciddi ölçüde azalttığını göstermektedir. Ancak, doğruluk gibi per-

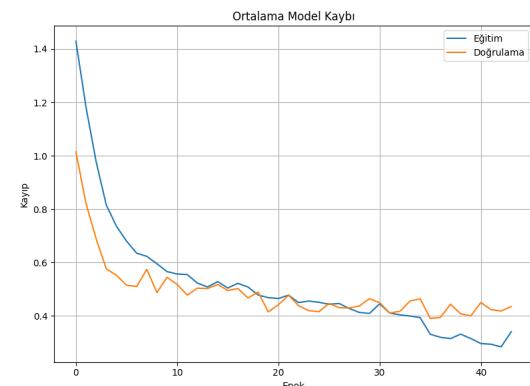


Fig. 40: RNN: Model Kaybı

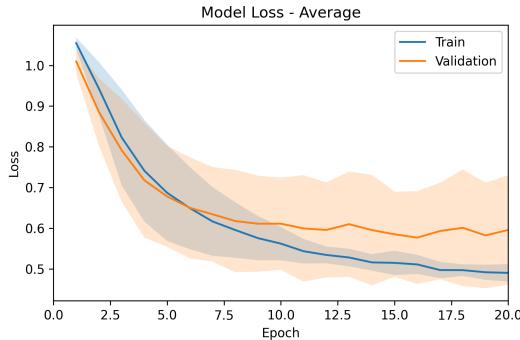


Fig. 41: GRU: Model Kaybı

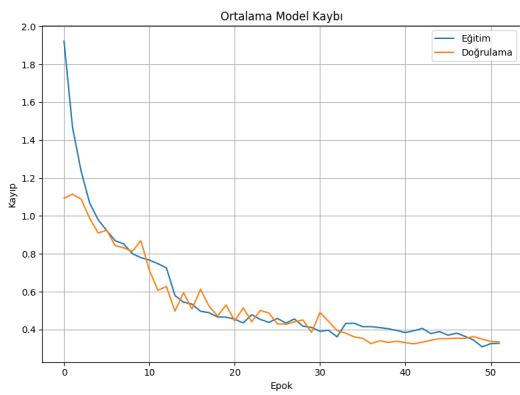


Fig. 42: CNN: Model Kaybı

TABLE X: Eğitim ve Test Süreleri

Model Adı	Eğitim Süresi	Test Süresi	PCA Süresi	LDA Süresi
Hibrit Model	10319	5	727	4983
LSTM Model	1320	0.44	1200	1080
Bi-LSTM Model	2640	0.92	2127	1637
CNN Model	1110	0.20	866	1564
GRU Model	24	0.50	25	20
RNN Model	3947	0.27	2858	2846
Random Forest	1200	0.10	960	230
Extra Trees	240	0.10	219	91
XGBoost	360	0.10	158	67
SVM	120	0.10	38	20
KNN	19	0.10	12	7

formans metriklerinde düşüş yaşandığı için bu azalmalar dikkatle değerlendirilmelidir.

Benzer şekilde, derin öğrenme modellerinden LSTM'de PCA, eğitim süresini 1,320 saniyeden 1,200 saniyeye, Bi-LSTM'de ise 2,640 saniyeden 2,127 saniyeye düşürmüştür. Bu süre kazanımları, özellikle büyük veri setlerinde eğitim sürecinin hızlandırılması gereğinde önemli avantajlar sağlamaktadır. RNN modeli için PCA, eğitim süresini 3,947 saniyeden 2,858 saniyeye, test süresini ise anlamlı bir şekilde düşürmüştür. CNN modelinde ise PCA uygulanması, eğitim süresini 1,110 saniyeden 866 saniyeye indirmiştir. GRU modelinde PCA'nın etkisi nispeten daha düşük olup eğitim

süresi 24 saniyeden 25 saniyeye çıkmıştır. Bununla birlikte, test sürelerinde de dikkat çekici bir azalma yaşanmıştır. Random Forest, Extra Trees ve XGBoost gibi geleneksel makine öğrenmesi algoritmalarında da benzer şekilde eğitim süreleri azalmış olup, Random Forest için 1,200 saniyeden 960 saniyeye, Extra Trees için 240 saniyeden 219 saniyeye, XGBoost için 360 saniyeden 158 saniyeye düşmüştür. Bu veriler, PCA'nın hem eğitim hem de test sürelerini optimize etmede etkili bir araç olduğunu göstermektedir.

Eğitim ve Test Performansı: LDA Kullanımı: LDA'nın eğitim ve test süreleri üzerindeki etkileri incelendiğinde, özellikle eğitim süresini kısaltmada etkili olduğu ancak PCA'ya kıyasla daha az fayda sağladığı gözlemlenmiştir. Hibrit modelde LDA uygulanmadan önce eğitim süresi 10,319 saniye ve test süresi 5 saniye iken, LDA ile eğitim süresi 4,983 saniyeye, test süresi ise 3.12 saniyeye düşmüştür. Bu durum, LDA'nın özellikle büyük modellerde eğitim süresini önemli ölçüde hızlandırmayı göstermektedir.

LSTM modelinde LDA, eğitim süresini 1,320 saniyeden 1,080 saniyeye indirmiştir ancak test sürelerine doğrudan bir etkisi gözlemlenmemiştir. Bi-LSTM'de ise LDA, eğitim süresini 2,640 saniyeden 1,637 saniyeye çekerek işlem maliyetlerini önemli ölçüde azaltmıştır. GRU modeli için ise LDA'nın etkisi daha belirgin olmuş ve eğitim süresi 24 saniyeden 20 saniyeye düşmüştür. RNN modelinde LDA, eğitim süresini 3,947 saniyeden 2,846 saniyeye düşürerek önemli bir hız avantajı sağlamıştır. CNN modelinde ise LDA, eğitim süresini 1,110 saniyeden 1,564 saniyeye çıkarmıştır, bu durum LDA'nın her modelde aynı etkiye göstermediğini göstermektedir.

Ayrıca, geleneksel makine öğrenmesi modellerinde Random Forest için LDA süresi 230 saniye, Extra Trees için 91 saniye, XGBoost için 67 saniye, SVM için 20 saniye ve KNN için 7 saniye olarak hesaplanmıştır. Genel olarak, LDA düşük boyutlu veri setlerinde hız avantajı sunarken doğruluk değerinde düşüş gözlemlenmiştir. Bu yüzden, modelin karmaşıklığına ve veri setinin boyutuna bağlı olarak LDA'nın etkisi dikkatlice değerlendirilmelidir.

Hesaplama Kaynakları Kullanımı:

GPU ve CPU Kullanımı: Makine öğrenmesi için AMD Ryzen 7 7840HS w/ Radeon 780M Grafikler, 3801 Mhz, 8 Çekirdek, 16 Mantıksal İşlemci, NVIDIA GeForce RTX 4060 ekran kartı ve 32 gb ram'e sahip bir donanım derin öğrenmesinde ise 12'nci nesil Intel(R) Core(TM) i5-12400F (12 CPUs), 2.5GHz, NVIDIA GeForce RTX 3060 ve 16 gb ram kullanılmıştır. LSTM modelinin eğitim sürecinde %70 GPU kullanımı kaydedilirken, Bi-LSTM modelinde bu oran %88'e kadar çıkmıştır. GRU ve CNN modellerinde ise GPU kullanımı sırasıyla %60 ve %75 olarak gözlemlenmiştir. Eğitim sırasında CPU kullanımı nispeten daha azdır %10-%20 arasında değerler görülmüştür. Özellikle CNN ve LSTM gibi modellerde test sırasında CPU kullanımı %15 civarındadır. LSTM ve Bi-LSTM modelleri, uzun sekans verilerini işlemek için bellek kullanımını oldukça önemlidir. 32 gb ram'in %90'ı hibrit modelde ve derin öğrenme modellerinde kullanılmıştır. Makine öğrenimi algoritmaları, genellikle CPU tabanlı çalışır. Eğitim sırasında %55'e kadar CPU kullanımı gözlemlenirken, test süreçlerinde bu oran %10 civarına düşmektedir. XGBoost ve Rastgele Orman modelleri eğitimde %50-55 arasında CPU kullanırken, SVM ve KNN modelleri %30 seviyelerinde çalışmaktadır. Hibrit model ise %95 ile performans sınırlarını zorlamıştır. Makine öğrenimi modellerinde bellek gereksinimi daha düşük olduğu görülmüştür. Eğitim süreçlerinde 2-4 GB RAM kullanımı yeterli olurken, test süreçlerinde bellek tüketimi genellikle 1 GB'in altına düşmektedir.

Zaman ve Kaynak Kullanımı: PCA Kullanımı: PCA, veri setinin boyutunu düşürerek eğitim ve test sürelerini önemli

ölçüde kısaltmıştır. Özellikle yüksek boyutlu veri setlerinde işlem hızını artırırken, modellerin eğitim süresini kayda değer ölçüde azaltmıştır. Ancak bazı modellerde doğruluk gibi metriklerde ufak kayıplara neden olabileceği görülmüştür. PCA, işlem maliyetini düşürmek isteyen projelerde etkili bir yöntemdir.

Zaman ve Kaynak Kullanımı: LDA Kullanımı: LDA, PCA'ya kıyasla daha yoğun bir boyut indirgeme sağlamış ve modellerin eğitim sürelerini önemli ölçüde azaltmıştır. Ancak bu yöntem, performans metriklerinde bazı düşüslere yol açabilir. LDA, özellikle işlem hızını artırmak ve eğitim süreçlerini optimize etmek için kullanışlıdır. Ancak doğruluk ve diğer performans kriterleri üzerindeki etkisi nedeniyle dikkatli bir şekilde değerlendirilmelidir.

D. Çapraz Geçerleme Sonuçları

Bir modelin gerçek hayatı performansını değerlendirmek, makine öğrenmesi sürecinin en kritik aşamalarından biridir. Tek bir eğitim-test bölünmesi, modelin performansı hakkında sınırlı bir bakış açısı sunarken, bazı durumlarda yanlıltıcı sonuçlara da yol açabilir. Bu noktada, K-Fold Çapraz Geçerleme (Cross Validation) teknigi, daha güvenilir ve kapsamlı bir değerlendirme imkanı sunuyor.

K-Fold Çapraz Geçerleme, veri setimizi sistematik bir şekilde farklı parçalara bölgerek, modelin farklı veri kombinasyonları üzerindeki performansını test etmemize olanak sağlar. Bu yaklaşım, modelin sadece belirli bir veri alt kümesine aşırı uyum (overfitting) gösterip göstermediğini anlamamızı yardımcı olurken, aynı zamanda modelin genelleme yeteneği hakkında da değerli bilgiler sunar.

Modellerimizin K-Fold Çapraz Geçerleme (Cross Validation) sonuçları [43](#), [44](#), [45](#), [46](#), [48](#). figürlerde belirtilmiştir.

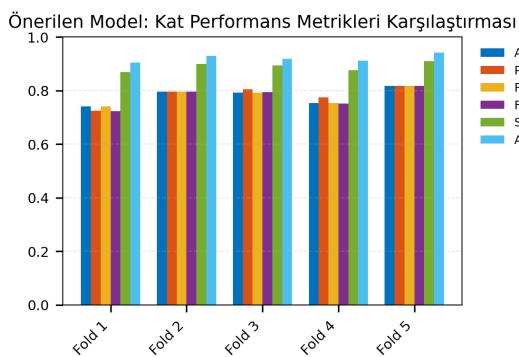


Fig. 43: Önerilen Model: Çapraz Geçerleme

Her model için beş farklı katta (fold) gerçekleştirilen testlerde, genel olarak tutarlı bir performans sergilendiğini görmekteyiz. LSTM ve Bi-LSTM modelleri, özellikle 2., 3. ve 4. katlarda oldukça benzer ve yüksek performans göstermiştir. Bu katlarda doğruluk (accuracy), hassasiyet (precision) ve F1-skor değerleri yaklaşık 0.80-0.85 aralığında seyretmektedir. AUC-ROC değerlerinin de bu katlarda 0.90'ın üzerine çıkması, modellerin sınıflandırma kabiliyetlerinin güçlü olduğunu göstermektedir. RNN modeli de benzer bir performans çizgisini izlemiştir, ancak özellikle 5. katta diğer modeller gibi bir performans düşüşü yaşamıştır. CNN modeli ise ilk katta diğer modellere göre daha düşük performans göstermesine rağmen, sonraki katlarda toparlanarak iyi sonuçlar elde etmiştir. İlginç bir şekilde, tüm modellerde 5. katta görülen performans düşüşü, veri setindeki bazı örneklerin diğerlerine göre daha zorlu olabileceğine işaret etmektedir.

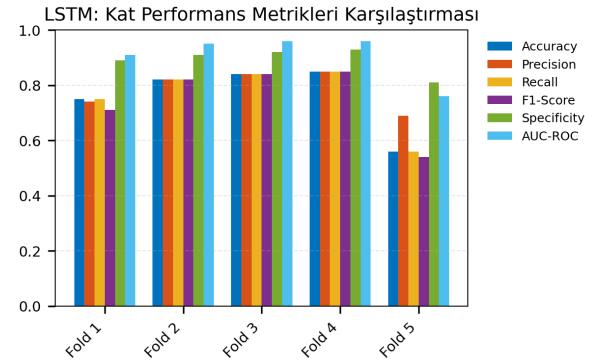


Fig. 44: LSTM: Çapraz Geçerleme

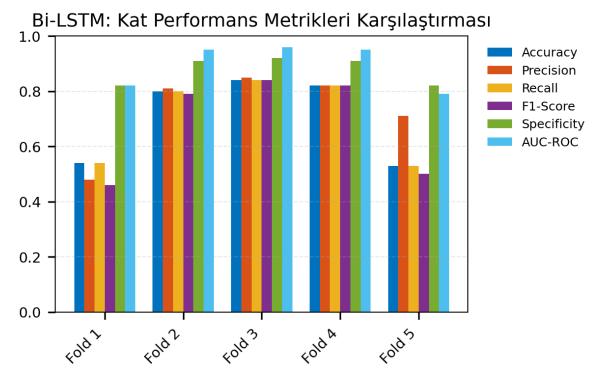


Fig. 45: Bi-LSTM: Çapraz Geçerleme

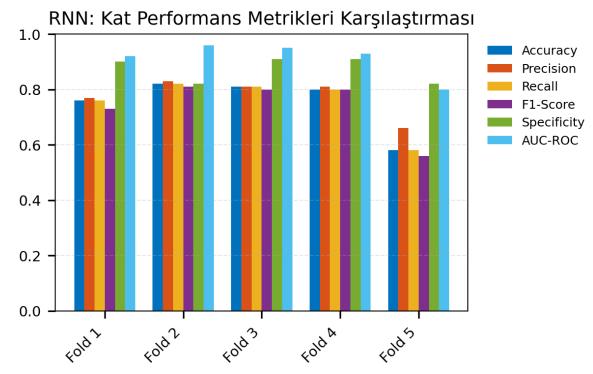


Fig. 46: RNN: Çapraz Geçerleme

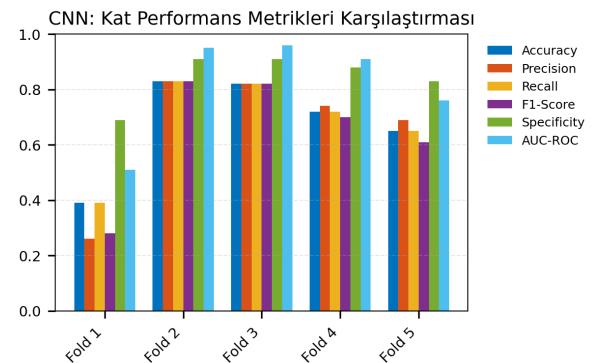


Fig. 47: CNN: Çapraz Geçerleme

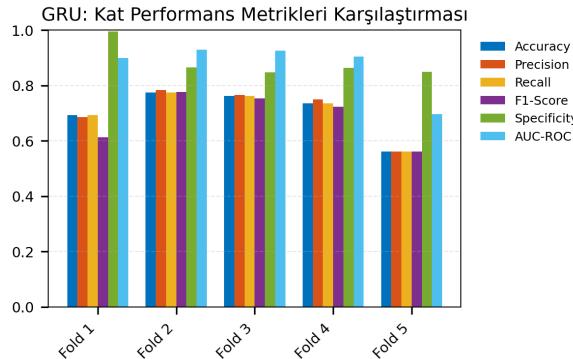


Fig. 48: GRU: Çapraz Geçerleme

Özgüllük (specificity) ve AUC-ROC değerleri açısından bakıldığından, tüm modeller genellikle 0.80'in üzerinde değerler elde etmiştir, bu da modellerin yanlış pozitifleri başarıyla filtreleyebildiğini göstermektedir. Özellikle 2., 3. ve 4. katlardaki yüksek ve tutarlı performans, modellerin genellemeye yeteneklerinin güclü olduğuna işaret etmektedir.

Bu sonuçlar ışığında, geliştirilen modellerin genel olarak güvenilir ve dengeli bir performans sergilediğini söyleyebiliriz. Ancak 5. kattaki performans düşüşü, modellerin bazı spesifik veri örneklerinde zorluk yaşayabileceğini ve bu durumun gelecekteki iyileştirmeler için bir odak noktası olabileceğini göstermektedir.

E. Hiperparametre Ayarları ve Model Performansı

Hiperparametreler, bir modelin eğitimi sırasında öğrenme sürecini doğrudan şekillendiren, eğitim öncesinde belirlenmesi gereken ayarlardır. Bu parametreler, modelin performansını optimize etmede kritik bir rol oynar. Çalışmamızda çeşitli optimizasyon araçlarından ve deneysel testler ile en iyi hiperparametreler bulunmaya çalışılmıştır.

Batch Size, Epoch Sayısı ve Öğrenme Oranı Ayarları:

- BatchSize:** Modelin eğitim sırasında işlemeye aldığı veri örneklerinin sayısını ifade eder. Veriler genelde parçalara (batch'lere) bölünerek işlem yapılır. Örneğin, batch size 32 ise her seferinde 32 veri örneği işlenir. Önerilen model batch size değeri 32 seçilmiştir. LSTM ve BiLSTM modelleri için 16-64 aralığında Bayesian optimizasyon ile aranmıştır. Bu aralık, bellek kullanımı ve eğitim hızı arasında iyi bir denge sağlamaktadır. CNN modeli için 32-64 aralığında optimize edilmiştir. CNN'ler için daha büyük batch size değerleri tercih edilmiştir çünkü CNN'ler paralel işleme daha uygun yapıdadır. GRU modeli için 64 batch size seçilmiştir. RNN modeli için 16-64 aralığında optimize edilmiştir. RNN yapıları için küçük batch size değerleri genellikle daha iyi sonuç vermektedir.
- Epoch Sayısı:** Modelin öğrenme sürecini doğrudan etkileyen ve eğitim sürecinde doğruluk ile genellemeye yeteneği arasında bir denge kurmada kritik bir rol oynayan temel bir hiperparametredir. Önerilen model için 50 epoch seçilmiştir. Derin öğrenme modellerinin hepsinde 100 epoch seçilmiştir ama tüm modeller için early stopping mekanizması kullanılmıştır. Bu mekanizma ile model performansı izlenerek optimal epoch sayısı dinamik olarak belirlenmiştir.
- Öğrenme Oranı:** Modelin ağırlıklarının, her yineleme (iteration) sonrasında ne kadar değiştirileceğini belirleyen bir hiperparametredir. Azaltılırsa eğitim süresi uzar ve genellemeye artar. Önerilen model için öğrenme oranları 1e-4 ile 1e-2

aralığından seçilmiştir. LSTM ve BiLSTM modelleri için 1e-4 ile 1e-2 aralığında optimize edilmiştir. CNN modeli için 0.0001 ile 0.001 aralığında daha dar bir aralık kullanılmıştır. CNN'lerin daha stabil eğitim sürecine sahip olması nedeniyle daha küçük öğrenme oranları tercih edilmiştir. RNN modeli için LSTM'lerle benzer şekilde 1e-4 ile 1e-2 aralığında optimize edilmiştir. GRU için öğrenme oranı 0.001 seçilmiştir. CNN modelinde ek olarak ReduceLROnPlateau callback'i kullanılarak öğrenme oranı dinamik olarak ayarlanmıştır.

- Optimize:** Optimizasyon algoritmaları, bir modelin kayıp fonksiyonunu minimize ederek daha iyi tahminler yapmasını sağlamak için kullanılır. Bu algoritmalar, ağırlıkları güncelleterek modelin öğrenmesini yönlendirir. Farklı algoritmalar, farklı hız ve doğruluk seviyeleriyle çalışır. Başlangıç için genelde Adam tercih edilir, çünkü hem hızlı öğrenir hem de daha az ayar gerektirir. Ancak, problem türüne ve model yapısına bağlı olarak SGD veya RMSprop gibi alternatifleri denemek gerekebilir. RNN'ler (ör. LSTM, GRU) gibi zaman serisi veya sıralı veriler üzerinde RMSprop daha etkilidir. Çalışmamızda makine öğrenmesinde Optuna ve GridSearchCV derin öğrenmede ise Keras Optimizer ,Adam ,RMSprop kullanılmıştır. Hiperparametre optimizasyonu için Bayesian Optimization yaklaşımı tercih edilmiştir.

TABLE XI: Hiperparametre Tablosu

Model	Epoch	Batch Size	Learning Rate	Eğitim Doğruluğu	Test Doğruluğu	Eğitim Kaybı	Test Kaybı
Önerilen Model	50	32	0.0001 - 0.01	0.85	0.78	0.51	0.58
LSTM	100	16 - 64	0.0001 - 0.01	0.87	0.83	0.35	0.38
Bi-LSTM	100	16 - 64	0.0001 - 0.01	0.85	0.81	0.39	0.45
RNN	100	16 - 64	0.0001 - 0.001	0.85	0.82	0.38	0.42
GRU	20	64	0.001	0.78	0.70	0.50	0.98
CNN	100	32 - 64	0.0001 - 0.001	0.82	0.77	0.51	0.51

TABLE XII: Hiperparametre Tablosu 2

Model	Hiperparametreler
Önerilen Model	lstm_1_units: (64, 96), dropout_1: (0.3, 0.5), lstm_2_units: (32, 48), dropout_2: (0.2, 0.4), dense_lstm_units: (8, 32), dense_tree_units: (16, 32), dense_combined_units: (16, 48), dropout_combined: (0.1, 0.3), optimizer: (adam, rmsprop)
LSTM	lstm units: (32, 128), dropout rate: (0.1, 0.5)
Bi-LSTM	lstm units: (32, 128), dropout rate: (0.1, 0.5)
RNN	rnn units: (32, 128), dropout rate: (0.1, 0.5)
GRU	gru units: 64, dense(32, activation="relu"), dropout rate: (0.2)
CNN	n filters: (32, 128), kernel size: (3, 5), dropout rate: (0.2, 0.5)

V. TARTIŞMA

Önerilen hibrit model, makine öğrenmesi ve derin öğrenme tekniklerinin güçlü yanlarını birleştirerek sınıflandırma problemleri için etkili bir çözüm sunmaktadır. Modelin AUC-ROC değeri (%92), hem Ekstra ağaç, KNN hem de LSTM, CNN algoritmalarına kıyasla daha üstün bir performans sergilemiştir. Hibrit yapının, sekansiyel (LSTM) ve bağımsız (Ekstra ağaç) özelliklerini aynı anda analiz edebilme kabiliyeti, bu başarısının temel kaynağı olarak öne çıkmaktadır. Ayrıca, PCA ve LDA uygulanmadan

TABLE XIII: Hiperparametreler ve Değerler

Model	Hiperparametreler
Random Forest	max_depth: 6, min_samples_leaf: 6, min_samples_split: 15, n_estimators: 100
Extra Trees	max_depth: 6, min_samples_leaf: 8, min_samples_split: 10, n_estimators: 200
XGBoost	colsample_bytree: 0.8, learning_rate: 0.01, max_depth: 4, min_child_weight: 5, n_estimators: 100, subsample: 0.7
SVM	C: 91.01, max_iter: 1205, class_weight: balanced
KNN	n_neighbors: 27, weights: uniform, metric: minkowski

elde edilen doğruluk (%78) ve özgüllük (%89) değerleri, modelin genel sınıflandırma başarısını destekleyen önemli metriklerdir. Modelin F1-Skor (%78) ve doğruluk değerlerinin diğer yöntemlere göre daha dengeli olması ise farklı veri türlerinde güvenilir sonuçlar üretebileceğini göstermektedir. Özellikle yanlış pozitif oranını düşürmede etkili olan model, sınıflandırma problemlerinde yüksek kararlılık ve esneklik sunmaktadır. Çalışmadaki diğer modellere bakıldığında SVM (%79) doğruluk ve (%93) AUC-ROC değerleriyle önerilen modelden bir miktar yüksek sonuçlar almıştır. En düşük sonucu ise %67 ile CNN modeli almıştır.

Ancak modelin bazı zayıf yönleri de bulunmaktadır. PCA veya LDA uygulandığında, doğruluk değerlerinde belirgin bir düşüş gözlemlenmiştir (PCA ile %70, LDA ile %74). Bu durum, modelin yüksek boyutlu özellikler üzerinde daha etkili çalıştığını, ancak boyut indirgeme yöntemlerinden olumsuz etkilendiğini göstermektedir. Ayrıca, eğitim doğruluğu (%84) ile test doğruluğu (%74) arasındaki fark, modelde aşırı öğrenme eğilimi olduğunu ortaya koymaktadır. Bu durum, modelin eğitim verisine fazla uyum sağladığını ve genellemeye kabiliyetinin sınırlı olabileceğiğini düşündürmektedir.

Bu çalışmada kullanılan veri kümelerinin özellikleri, uygulanan algoritmaların performansını önemli ölçüde etkilemiştir. 4.500'den fazla kayıt ve 42 özelliğe sahip olan veri kümlesi, makine öğrenimi modelleri için oldukça zengin bir veri noktası sağlamaktadır. Ancak, yüksek boyutluluk, özellikle özelliklerin tekrarlılığı veya gürültüsüne duyarlı algoritmalar için aşırı öğrenme riskini ve artan hesaplama karmaşıklığını da beraberinde getirmektedir. Çalışmadada kullanılan etiket dağılımı 1456 adet sat, 1373 adet tut, 1757 adet al şeklindedir. al etiketinin nispeten fazla olması modelin başarısında düşüre sebep olmuştur. Ancak gerçek hayatı kullanılabılırlığını daha net ölçmek için müdahale edilmemiştir. Öznitelik sayısı başlangıçta sadece IV tablosundaki indikatörler olup öğrenim için korelasyonun fazla olduğu tespit edilip arttırılmıştır.

Veri setine yapılan ön işleme aşaması olarak ilk başta BIST100 endeksinin sıfır atıldığı tarihten önceindeki verileri de 100'e bölgerek veri uyumsuzluğunun önüne geçilmeye çalışılmıştır. Ardından min max normalizasyonu ve çeyrekler açıklığı yöntemiyle son haline getirilmiştir. Öznitelik seçim yöntemleri olarak PCA ve LDA kullanılmış olup modelin başarısına olumsuz etkisi olsa da eğitim süresini oldukça hızlandırdığı gözlemlenmiştir. Deneysel sonuçlarımız, hibrit modelin temel GRU modeline kıyasla çeşitli öütüler açısından üstün performans sergilediğini göstermektedir. Hibrit mimarı, %77.99 (± 0.0285) doğruluk oranı elde ederek GRU modeline kıyasla %7.5'lik bir

iyileşme sağlamıştır. Ayrıca, doğruluk ölçümllerindeki daha düşük standart sapma, modelin daha istikrarlı bir performans sergilediğini ortaya koymaktadır.

Hibrit modelin AUC-ROC skoru 0.9213 olarak hesaplanmış olup, bu değer GRU modelinin 0.8708 değerine kıyasla daha yüksek ayrım gücü ve sağlamlık göstermektedir. Ek olarak, F1-Skoru yaklaşık %9 oranında artış göstererek 0.6852 seviyesinden 0.7762 seviyesine ulaşmıştır. Bu durum, modelin kesinlik ve duyarlılık arasında daha iyi bir denge sağladığını göstermektedir. Bu çalışmanın en önemli katkısı, ağaç tabanlı (Extra Trees) ve sekansiyel öğrenme (LSTM) yaklaşımlarının yenilikçi bir şekilde birleştirilmesidir. Çift akışlı mimarı, LSTM ağlarının sekans tanımı yetenekleri ile Ekstra ağaç sınıflandırıcılarının özellik öğrenme kabiliyetlerini bir araya getirerek, hem zamansal bağımlılıkları hem de karmaşık özellik etkileşimlerini aynı anda yakalamaktadır. Ayrıca, her iki model bileşeni için otomatik hiperparametre optimizasyonu uygulanması önemli bir gelişme olarak öne çıkmaktadır. Bu yaklaşım, modelin performansını artırmayı yanı sıra, modelin tekrarlanabilirliğini sağlamış ve manuel ayarlama ihtiyacını azaltmıştır. Modelin "al", "tut", "sat" sınıflandırması yatırımcılara ve finans uzmanlarına karlılık potansiyeli ve duygulardan uzak bir şekilde risk yönetimi yapmayı sağlıyor.

Hibrit modelin iyileştirilmiş performansına rağmen, bazı sınırlamalar mevcuttur. Modelin eğitim süresi (10,319.69 saniye), Diğer modellerin eğitim süresine kıyasla oldukça uzundur. Bu hesaplama maliyeti, modelin sürekli güncellenmesi veya gerçek zamanlı öğrenme gerektiren uygulamalarda kullanımını sınırlayabilir. Çift akışlı mimari ve çok sayıda hiperparametre, modelin yönetimini ve dağıtımını daha karmaşık hale getirebilir. Hibrit modelin bellek tüketimi, daha basit modellere kıyasla önemli ölçüde yüksektir. Bu durum, kısıtlı kaynaklara sahip ortamlarda kullanım açısından bir dezavantaj oluşturabilir.

Modellerin performans değerlendirilmesinde farklı metrikler kullanılmıştır, çünkü her metrik model başarısını farklı açılarından ölçer. Doğruluk (Accuracy) genel başarıyı gösterse de, dengesiz veri kümelerinde yaniltıcı olabilir. Bu nedenle, Kesinlik (Precision) yanlış pozitif oranını, Duyarlılık (Recall) ise modelin kaç gerçek pozitif tahmin edebildiğini değerlendirmek için kullanılmıştır. Finansal zaman serisi tahminlerinde yanlış sinyallerin etkisi büyük olduğundan, Özgüllük (Specificity) ve F1-Skoru gibi metrikler de dikkate alınmıştır.

Onerilen modelin genel tahmin gücünü değerlendirmek için AUC-ROC metriği kullanılmıştır. Ayrıca, Train Loss ve Test Loss metrikleri modelin aşırı öğrenme (overfitting) yapıp yapmadığını analiz etmek için incelenmiştir. Tüm bu metriklerin birlikte değerlendirilmesi, modelin hem tahmin doğruluğu hem de genellemeye kapasitesinin anlaşılmasını sağlamaktadır.

Gelecekte yapılacak çalışmalar kapsamında, önerilen modelin genellemeye kabiliyeti daha geniş veri kümeleri ve farklı piyasa koşulları altında test edilmelidir. Mevcut çalışmada BIST100 endeks verileri kullanılmıştır, ancak modelin performansının farklı finansal piyasalar, sektörler veya bölgesel borsalar üzerinde değerlendirilmesi, modelin güvenilirliğini artıracaktır. Ayrıca, modelin sadece fiyat hareketlerine dayalı olmaktan ziyade, haber duyarlılığı, sosyal medya verileri ve makroekonomik göstergeler gibi ek veri kaynaklarıyla desteklenmesi, tahmin doğruluğunu daha da artırabilir. Derin öğrenme tabanlı modellerin, özellikle hibrit yapıların optimizasyonu için daha gelişmiş hiperparametre ayarlama yöntemleri araştırılmalıdır.

Çalışmanın mevcut sınırlamaları arasında, hesaplama maliyetinin yüksek olması ve modelin aşırı uyuma (overfitting) karşı hassasiyeti

bulunmaktadır. Bu nedenle, gelecekte modelin karmaşıklığını azaltmaya yönelik teknikler, daha hafif ağ yapıları araştırılabilir. Ayrıca, yüksek hesaplama gücü gerektiren derin öğrenme modelleri için paralel işlem ve donanımsal hızlandırma teknikleri uygulanarak eğitim süresi optimize edilebilir. Son olarak, finansal zaman serisi verilerinin doğası gereği değişken ve gürültülü olması nedeniyle, daha dayanıklı ve adaptif öğrenme stratejileri geliştirerek modelin değişen piyasa koşullarına daha hızlı uyum sağlama hedeflenmelidir. Özetle, önerilen hibrit model, hem ML hem de DL algoritmalarına kıyasla SVM ve Random Forest haricinde üstün sınıflandırma performansı ve daha geniş uygulama potansiyeli sunmaktadır. Ancak gelecekteki çalışmalar, modelin genellemeye yeteneklerini artırmaya ve boyut indirgeme yöntemleriyle daha iyi uyum sağlamasını hedeflemelidir. Bu sayede, hibrit modelin farklı veri türlerinde daha yüksek başarıyı elde etmesi sağlanabilir.

VI. SONUÇ

Çalışmada ele alınan temel problem, Borsa İstanbul 100 (BIST100) endeksinin kısa vadeli yön tahmini yaparak yatırımcılara stratejik karar desteği sağlamaktr. Finansal piyasaların karmaşaklısı ve belirsizliği, geleneksel tahmin yöntemlerinin yetersiz kalmasına neden olmaktadır. Bu nedenle, makine öğrenmesi ve derin öğrenme (tekniklerinin sunduğu veri odaklı yaklaşımlar, finansal tahmin modellerinde giderek daha fazla tercih edilmektedir. Ancak bu modellerin yüksek doğruluk oranları sağlama ve aşırı öğrenme gibi olası problemlerden kaçınması için etkili veri işleme ve modelleme yöntemlerinin geliştirilmesi gerekmektedir.

Bu çalışma, BIST100 endeks fiyatının günlük yön tahminini gerçekleştirmek amacıyla “al-tut-sat” şeklinde çok sınıflı bir sınıflandırma problemi olarak ele alınmıştır. Literatürde genellikle ikili sınıflandırma (al-sat) yöntemleri kullanılmaktır, bu çalışmada yatırımcılara daha kapsamlı karar desteği sunabilmek adına üçlü sınıflandırma yaklaşımı benimsenmiştir. Farklı modellerin bu problem üzerinde karşılaştırılarak en iyi performans gösteren modelin belirlenmesi hedeflenmiştir. Özellikle, zaman serisi verilerinin analizi için LSTM gibi sekans bazlı derin öğrenme yöntemleri ile Extra Trees gibi karar ağaçları tabanlı ML modelleri bir arada kullanılarak hibrit bir model önerilmiştir.

Önerilen modelin metodolojisi ise Lstm modelinin keras tuner, ekstra ağaç modelinin ızgara araması(Grid Search) ile hiperparametre optimizasyonunun yapılması ve eğitilmesi ile başlamıştır. Elde edilen çıktılar iki modelin güçlü yönlerini birleştirerek daha kapsamlı bir analiz sağlamıştır. Elde edilen sonuçlar test setinde ortalama %78 doğruluk oranı elde etmiştir. Bu, modelin veri setindeki sınıfları doğru bir şekilde ayırt edebildiğini göstermektedir. %92 gibi yüksek bir AUC-ROC skoru, modelin sınıflandırma yeteneğinin güçlü olduğunu ve pozitif sınıfları etkili bir şekilde ayırt edebildiğini göstermektedir. %77 F1-Score değeri ise modelin hem kesinlik hem de duyarlılık açısından dengeli bir performans sergilediğini ortaya koymaktadır. Modelin toplam eğitim süresi 10,319.69 saniye olarak ölçülmüştür. Bu süre, modelin karmaşaklısı ve kullanılan veri setinin büyütülüğü göz önüne alındığında makul bir değerdir. Diğer modelleride incelediğimizde en başarılı sonuçları sırasıyla SVM (%79), Önerilen model (%78) ve Rastgele Orman (%78) doğruluk değerleriyle almaktadır.

Veri setinin kalitesine bakıcaz olursak III kısmında anlatılan ön işleme adımları ile veriyi daha iyi hale getirdik. Korelasyon matrisi oluşturup S&P 500, Ons altın kapanış verisi ve ek indikatör hesaplamalarıyla performansı önemli derecede arttırdı. Ayrıca PCA ve LDA ile öznitelik çıkarımı yaparak eğitim sürelerinin düşmesi sağlandı ancak doğruluk değerlerinde de düşüş

gözlemlendi. Gelecekteki çalışmalar, modelin performansını daha da artırmak ve genellemeye yeteneğini geliştirmek amacıyla farklı veri setleri ve daha gelişmiş algoritmalar üzerine yoğunlaşabilir. Finansal zaman serisi verilerinin daha geniş kapsamlı bir analizi için farklı borsa endeksleri (örn. S&P 500, DAX, FTSE 100 gibi uluslararası piyasalar) veya makroekonomik göstergeler (faiz oranları, enflasyon, para politikası değişkenleri gibi) ile zenginleştirilmiş veri setleri kullanılabilir. Bu tür genişletilmiş veri kaynakları, modelin küresel piyasa trendlerini daha iyi anlamasını sağlayarak tahmin gücünü artırabilir.

Ayrıca, daha ileri düzey derin öğrenme yaklaşımlarının entegre edilmesi de modelin doğruluğunu ve genellemeye kabiliyetini artırabilir. Transformer tabanlı modeller (örn. Temporal Fusion Transformer - TFT, Attention-based LSTM modelleri), zaman serisi verilerinde uzun vadeli bağımlılıkları daha iyi yakalayarak mevcut LSTM tabanlı modellerin sınırlamalarını aşabilir. Bunun yanı sıra, ensemble (topluluk) öğrenme yöntemleri kullanılarak farklı makine öğrenmesi ve derin öğrenme modellerinin çıktıları birleştirilebilir ve böylece modelin öngörü gücü artırılabilir.

Çalışmadan elde edilen bulguların finans sektöründe pratik uygulamaları oldukça genişir. Borsa yatırımcıları ve algoritmik işlem sistemleri, hibrit modelin sağladığı tahminleri kullanarak risk yönetiminini optimize edebilir ve daha bilinçli alım-satım kararları verebilir. Önerilen modelin yanlış pozitif oranlarını azaltarak daha güvenilir sinyaller üretmesi, yatırımcıların spekulatif kararlar yerine daha sağlam temellere dayalı işlem yapmasını sağlayabilir.

ÇIKAR ÇATIŞMASI BEYANI

Yazarlar arasında herhangi bir çıkar çatışması bulunmamaktadır.

REFERENCES

- [1] Güner Koç Aytekin. Türkiye'de sermaye piyasaları ve borsaların gelişim süreci. *Uluslararası Beşeri Bilimler ve Eğitim Dergisi*, 4(9):150–176, 2018.
- [2] Ali Doğan and Mehmet Erçek. Emergence of chambers in the turkish history: the case of dersaadet chamber of commerce (dcc) as a public-agent meta-organization, 1882–1929. *Journal of Management History*, 2024.
- [3] Serap Akbulut and ADEM Kemal. Derin öğrenme ve makine öğrenmesi yöntemleri kullanılarak gelişmekte olan ülkelerin finansal enstrümanlarının etkileşimi ile bist 100 tahmini. *Niğde Ömer Halisdemir Üniversitesi Mühendislik Bilimleri Dergisi*, 12(1):1–1, 2023.
- [4] Somenath Mukherjee, Bikash Sadhukhan, Nairita Sarkar, Debajyoti Roy, and Soumil De. Stock market prediction using deep learning algorithms. *CAAI Transactions on Intelligence Technology*, 8(1):82–94, 2023.
- [5] Nazif Ayyıldız. Bankacılık sektörüne derin öğrenme yöntemiyle bakış: Bist banka endeksi hareket yönlerinin tahmini. *İnsan ve Toplum Bilimleri Araştırmaları Dergisi*, 13(3):1277–1291, 2024.
- [6] Ritika Chopra and Gagan Deep Sharma. Application of artificial intelligence in stock market forecasting: a critique, review, and research agenda. *Journal of risk and financial management*, 14(11):526, 2021.
- [7] Nan Jing, Zhao Wu, and Hefei Wang. A hybrid model integrating deep learning with investor sentiment analysis for stock price prediction. *Expert Systems with Applications*, 178:115019, 2021.
- [8] Zeynep Hilal Kılımcı. Borsa tahmini için derin topluluk modelleri (dtm) ile finansal duygusal analizi. *Gazi Üniversitesi*

- Mühendislik Mimarlık Fakültesi Dergisi*, 35(2):635–650, 2020.
- [9] Payal Soni, Yogya Tewari, and Deepa Krishnan. Machine learning approaches in stock price prediction: a systematic review. In *Journal of Physics: Conference Series*, volume 2161, page 012065. IOP Publishing, 2022.
- [10] Simon A. Levin and Andrew W. Lo. Introduction to pnas special issue on evolutionary models of financial markets. *Proceedings of the National Academy of Sciences*, 118(26):e2104800118, 2021.
- [11] Patel Jay, Vasu Kalariya, Pushpendra Parmar, Sudeep Tanwar, Neeraj Kumar, and Mamoun Alazab. Stochastic neural networks for cryptocurrency price prediction. *IEEE Access*, 8:82804–82818, 2020.
- [12] Pinar Demir. Yapay sinir ağları kullanılarak hisse senedi fiyatı değişim yönünün tahmininin yapılması. Master's thesis, Maltepe Üniversitesi, 2021. Bilgisayar Mühendisliği Ana Bilim Dalı, Lisansüstü Eğitim Enstitüsü.
- [13] Timothy Potsaid and Shankar Venkataraman. Trading restrictions and investor reaction to non-gains, non-losses, and the fear of missing out: Experimental evidence. *Journal of Behavioral and Experimental Finance*, 33:100597, 2022.
- [14] Gözde Şişmanoğlu, Furkan Koçer, Mehmet Ali Önde, and Ozgur Koray Sahingoz. Derin öğrenme yöntemleri ile borsada fiyat tahmini. *Bitlis Eren Üniversitesi Fen Bilimleri Dergisi*, 9(1):434–445, 2020.
- [15] Seyda Kalyoncu. Deep learning networks for stock market analysis / borsa analizi ve tahmini için derin Öğrenme ağları. Master's thesis, İstanbul Sabahattin Zaim Üniversitesi, Lisansüstü Eğitim Enstitüsü, Bilgisayar Mühendisliği Ana Bilim Dalı, Bilgisayar Bilimleri Bilim Dalı, 2024.
- [16] Hadi Rezaei, Hamidreza Faaljou, and Gholamreza Mansourfar. Stock price prediction using deep learning and frequency decomposition. *Expert Systems with Applications*, 169:114332, 2021.
- [17] Onur Kantar and Zeynep Hilal Kılımcı. Derin öğrenme temelli hibrid altın endeksi (xau/usd) yön tahmin modeli. *Gazi Üniversitesi Mühendislik Mimarlık Fakültesi Dergisi*, 38(2):1117–1128, 2023.
- [18] Bilal Hassan Ahmed Khattak, Imran Shafi, Abdul Saboor Khan, Emmanuel Soriano Flores, Roberto García Lara, Md. Abdus Samad, and Imran Ashraf. A systematic survey of ai models in financial market forecasting for profitability analysis. *IEEE Access*, 11:125359–125380, 2023.
- [19] Yahya Altuntaş and Fatih Kocamaz. Derin öğrenme tabanlı görüntü sınıflandırma yaklaşımı ile borsa istanbul 100 endeks yönünün tahmini. *Computer Science*, 8(2):93–101, 2023.
- [20] Uğur Kaya, Fırat Akba, İhsan Medeni, and Tunç Medeni. Covid-19 öncesi ve sonrasında bitcoin fiyat değişimlerinin makine öğrenmesi, zaman serileri analizi ve derin öğrenme yöntemleriyle değerlendirilmesi. *Bilişim Teknolojileri Dergisi*, 13(3):341–355, 2020.
- [21] Mehmet Sarıköç and Mete Çelik. Boyut indirgeme teknikleri ve lstm derin öğrenme ağı ile bst100 endeksi fiyat tahmini. *Avrupa Bilim ve Teknoloji Dergisi*, (34):519–524, 2022.
- [22] Man Li, Ye Zhu, Yuxin Shen, and Maia Angelova. Clustering-enhanced stock price prediction using deep learning. *World Wide Web*, 26(1):207–232, 2023.
- [23] Yong Yu, Xiaosheng Si, Changhua Hu, and Jianxun Zhang. A review of recurrent neural networks: Lstm cells and network architectures. *Neural Computation*, 31(7):1235–1270, 2019.
- [24] A. W. Li and G. Bastos. Stock market forecasting using deep learning and technical analysis: A systematic review. *IEEE Access*, 8:185232–185242, 2020.
- [25] Antonio Pagliaro. Forecasting significant stock market price changes using machine learning: Extra trees classifier leads. *Electronics*, 12(21), 2023.
- [26] Farbod Farhangi, Abolghasem Sadeghi-Niaraki, Seyed Vahid Razavi-Termeh, and Soo-Mi Choi. Evaluation of tree-based machine learning algorithms for accident risk mapping caused by driver lack of alertness at a national scale. *Sustainability*, 13(18):10239, 2021.
- [27] Statista Research Department. Largest stock exchanges worldwide in 2024, by trading volume, 2024.
- [28] Nuh Yurduseven and Ahmet Anıl Müngen. Finansal zaman serilerini tahminlemede kullanılan yöntemlere genel bir bakış. *Bilecik Şeyh Edebali Üniversitesi Fen Bilimleri Dergisi*, 9(1):653–671, 2022.
- [29] Jaideep Singh and Matloob Khushi. Feature learning for stock price prediction shows a significant role of analyst rating. *Applied system innovation*, 4(1):17, 2021.
- [30] Abdulrahman Abdi, Rebwar Mala Nabi, M Sardasht, and Raouf Mahmood. Multiclass classifiers for stock price prediction: A comparison study. *J. Harbin Inst. Technol*, 54(3):32–39, 2022.
- [31] Akib Mashrur, Wei Luo, Nayyar A. Zaidi, and Antonio Robles-Kelly. Machine learning for financial risk management: A survey. *IEEE Access*, 8:203203–203223, 2020.
- [32] Hakan Gunduz. An efficient stock market prediction model using hybrid feature reduction method based on variational autoencoders and recursive feature elimination. *Financial innovation*, 7(1):28, 2021.
- [33] Nazif Ayyıldız and Omer Iskenderoglu. How effective is machine learning in stock market predictions? *Heliyon*, 10(2):e24123, 2024.
- [34] Mojtaba Nabipour, Pooyan Nayyeri, Hamed Jabani, Shahab S., and Amir Mosavi. Predicting stock market trends using machine learning and deep learning algorithms via continuous and binary data; a comparative analysis. *IEEE Access*, 8:150199–150212, 2020.
- [35] Yunus Emre Gür. Stock price forecasting using machine learning and deep learning algorithms: A case study for the aviation industry. *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, 36(1):25–34, 2024.
- [36] Yahya Altuntas and Fatih Kocamaz. Derin Öğrenme tabanlı görüntü sınıflandırma yaklaşımı ile borsa İstanbul 100 endeks yönünün tahmini. *Computer Science*, Vol:8(Issue:2):93–101, 2023.
- [37] Azaz Hassan Khan, Abdullah Shah, Abbas Ali, Rabia Shahid, Zaka Ullah Zahid, Malik Umar Sharif, Tariqullah Jan, and Mohammad Haseeb Zafar. A performance comparison of machine learning models for stock market prediction with novel investment strategy. *Plos one*, 18(9):e0286362, 2023.
- [38] Tamerlan Mashadihasanlı. Stock market price forecasting using the arima model: an application to istanbul, turkiye. *İktisat Politikası Araştırmaları Dergisi*, 9(2):439–454, 2022.
- [39] Yan Wang and Yuankai Guo. Forecasting method of stock market volatility in time series data based on mixed model of arima and xgboost. *China Communications*, 17(3):205–221, 2020.
- [40] Kazi Ekramul Hoque and Hamoud Aljamaan. Impact of hyperparameter tuning on machine learning models in stock

- price forecasting. *IEEE Access*, 9:163815–163830, 2021.
- [41] Nagaraj Naik and Biju R Mohan. Novel stock crisis prediction technique—a study on indian stock market. *IEEE Access*, 9:86230–86242, 2021.
- [42] Yaohu Lin, Shancun Liu, Haijun Yang, and Harris Wu. Stock trend prediction using candlestick charting and ensemble machine learning techniques with a novelty feature engineering scheme. *IEEE Access*, 9:101433–101446, 2021.
- [43] Ernest Kwame Ampomah, Zhiguang Qin, and Gabriel Nyame. Evaluation of tree-based ensemble machine learning models in predicting stock price direction of movement. *Information*, 11(6):332, 2020.
- [44] Pavan Kumar Illa, Balakesavareddy Parvathala, and Anand Kumar Sharma. Stock price prediction methodology using random forest algorithm and support vector machine. *Materials Today: Proceedings*, 56:1776–1782, 2022. International Conference on Applied Research and Engineering 2021.
- [45] Timothy Julian, Theodorus Devrison, Varian Anora, and Kristien Margi Suryaningrum. Stock price prediction model using deep learning optimization based on technical analysis indicators. *Procedia Computer Science*, 227:939–947, 2023. 8th International Conference on Computer Science and Computational Intelligence (ICCSCI 2023).
- [46] Ahmad O Aseeri. Effective short-term forecasts of saudi stock price trends using technical indicators and large-scale multivariate time series. *PeerJ Computer Science*, 9:e1205, 2023.
- [47] Seher Arslankaya and Şevval Toprak. Makine Öğrenmesi ve derin Öğrenme algoritmalarını kullanarak hisse senedi fiyat tahmini. *International Journal of Engineering Research and Development*, 13(1):178–192, 2021.
- [48] Efe Arda and Güray Küçükkocaoglu. Yapay zeka yöntemleri ile hisse senedi fiyat Öngörüleri. *Ekonomi Politika ve Finans Araştırmaları Dergisi*, 6(2):565–586, 2021.
- [49] İlker Dalkiran and Mehmet Ozan. Derin Öğrenme teknikleri kullanılarak borsadaki hisse değerlerinin tahmin edilmesi. *Avrupa Bilim ve Teknoloji Dergisi*, (39):143–148, 2022.
- [50] Kübra Akyol Özcan. Borsa endeksi yönünün makine Öğrenmesi yöntemleri ile tahmini: Bist 100 Örneği. *Gümüşhane Üniversitesi Sosyal Bilimler Dergisi*, 14(3):1001–1018, 2023.
- [51] Emre Albayrak and Nurdan Saran. İstatistiksel ve derin Öğrenme modellerini kullanarak hisse senedi fiyat tahmini. *Türkiye Bilişim Vakfı Bilgisayar Bilimleri ve Mühendisliği Dergisi*, 16(2):161–169, 2023.
- [52] Dilşad Tülgen Çetin and Sedat Metlek. Türkiye'deki İslami hisse senedi endeksinin, endeks tabanlı Öznitelikler kullanılarak derin Öğrenme yöntemi ile tahmini. *Acta Infologica*, 5(2):287–298, 2021.
- [53] Hakan Pabuçcu. Borsa endeksi hareketlerinin tahmini: Trend belirleyici veri. *Selçuk Üniversitesi Sosyal Bilimler Meslek Yüksekokulu Dergisi*, 22(1):246–256, 2019.
- [54] Yıldız Aydin, Gizem Varol, Eyyüb Ensari Gökdenez, and Hakan Manus. Hisse senedi fiyatlarının lstm ve arima modelleri kullanılarak tahmin edilmesi. *Fırat Üniversitesi Mühendislik Bilimleri Dergisi*, 36(2):903–911, 2024.
- [55] Suhui Liu, Xiaodong Zhang, Ying Wang, and Guoming Feng. Recurrent convolutional neural kernel model for stock price movement prediction. *Plos one*, 15(6):e0234206, 2020.
- [56] Jingyi Shen and M Omair Shafiq. Short-term stock market price trend prediction using a comprehensive deep learning system. *Journal of big Data*, 7:1–33, 2020.
- [57] Mehmet Sarıkoc and Mete Çelik. Boyut İndirgeme teknikleri ve lstm derin Öğrenme ağı ile bist100 endeksi fiyat tahmini. *Avrupa Bilim ve Teknoloji Dergisi*, (34):519–524, 2022.
- [58] Gözde Şişmanoğlu, Furkan Koçer, Mehmet Ali Önde, and Ozgur Koray Sahingoz. Derin Öğrenme yöntemleri ile borsada fiyat tahmini. *Bitlis Eren Üniversitesi Fen Bilimleri Dergisi*, 9(1):434–445, 2020.
- [59] Nesrin Koç Ustalı, Nedret Tosun, and Ömür Tosun. Makine Öğrenmesi teknikleri ile hisse senedi fiyat tahmini. *Eskişehir Osmangazi Üniversitesi İktisadi ve İdari Bilimler Dergisi*, 16(1):1–16, 2021.
- [60] Yakup Kara, Melek Acar Boyacioglu, and Ömer Kaan Baykan. Predicting direction of stock price index movement using artificial neural networks and support vector machines: The sample of the istanbul stock exchange. *Expert Systems with Applications*, 38(5):5311–5319, 2011.
- [61] Borsa İstanbul. İki sıfır atılması duyurusu, 2020.
- [62] Hakan Yüce and Ali Osman Özkan. Normalizasyon yöntemlerinin biyomedikal verilerde sınıflandırma性能ına etkisi. *Avrupa Bilim ve Teknoloji Dergisi*, (30):35–43, 2021.
- [63] Ian T Jolliffe. *Principal component analysis for special types of data*. Springer, 2002.
- [64] R. A. FISHER. The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2):179–188, 1936.